260326_Misalign_정리

Misalign_compensation 전체 실험 종합 보고서

Repository: /home/chanyoungko/IIT/Misalign_compensation

Updated: 2026-04-02

이 문서는 Misalign_compensation 프로젝트에서 수행한 season1/season2 실험 전체를 다시 정리한 확장판 보고서이다. 데이터 구조, 전처리, 입력 feature 생성, 모델 구조, 학습 전략, archive별 가설과 결과, full LOSO 검증, 재현성, 실시간 추론 가능성, 논문화 시 contribution까지 한 번에 파악할 수 있도록 구성했다.

Contents

1 요약 2

2 먼저 알아야 할 용어와 읽는 법 2

3 문제 정의와 데이터 3

4 역사적 전체 성능 순위와 살아남은 모델 3

5 입력 feature, 전처리, 출력 구성 5

6 모델 구조와 학습 전략 7

7 전체 archive 흐름 요약 7
- 7.1 Archive 1-3: representation과 body-frame 탐색 . . . 9
- 7.2 Archive 4-5: biomechanical feature screening . . . 10
- 7.3 Archive 6: deployability로의 수렴 . . . 11
- 7.4 Archive 7-8: physics feature 재검증 . . . 14

8 Season3 target 재정의 실험 17

9 대표 trajectory와 정성 분석 18

10 실시간 추론 가능성 20

11 논문화 시 contribution과 메시지 21

12 한 페이지 최종 메시지 22

13 Archive Season4 설계에 바로 쓸 정리 23

A Archive별 실험 인벤토리 23
- A.1 역사적 전체 single-LOSO 성능 순위 . . . 23
- A.2 Season3 archive 1 inventory . . . 25
- A.3 Archive 1 실험 목록 . . . 25
- A.4 Archive 2 실험 목록 . . . 25
- A.5 Archive 3 실험 목록 . . . 26
- A.6 Archive 4 실험 목록 . . . 26
- A.7 Archive 5 실험 목록 . . . 26
- A.8 Archive 6 screening 실험 목록 . . . 27
- A.9 Archive 7 screening 실험 목록 . . . 27
- A.10 Archive 8 screening 실험 목록 . . . 27

A.11 Archive 6 full LOSO inventory 27
A.12 Archive 7 full LOSO inventory 28
A.13 Archive 8 full LOSO inventory 28

1 요약

이 프로젝트는 wearable hip exoskeleton에서 발생하는 human-robot misalignment/compliance로 인해 robot이 측정한 hip/thigh 신호와 실제 human hip angle 사이에 생기는 체계적 오차를 소프트웨어적으로 보정하는 문제를 다룬다. 핵심은 단순 regression이 아니라 'robot이 이미 알고 있는 것'과 'mocap이 알려주는 실제 값' 사이의 residual을 학습하는 것이다.

지금까지의 전체 흐름을 한 문장으로 요약하면 다음과 같다. 초반에는 body-frame과 heading normalization 같은 '더 물리적인 좌표계'를 탐색했지만, 중반 이후 결과는 orientation-preserving sensor fusion과 경량 biomechanical feature가 더 안정적이라는 쪽으로 수렴했다. 후반에는 accuracy breakthrough보다 deployability와 full LOSO generalization을 같이 만족하는 구성을 찾는 것으로 방향이 바뀌었다.

historical strongest single-LOSO reference는 exp_A5_res_noise_001 (MAE 1.8848, RMSE 2.3999)이고, final validated full LOSO 결과에서는 archive_6 Tiny가 MAE 2.6344, Teacher가 MAE 2.6369로 가장 강한 두 기준점으로 남았다. latest archive_8 full LOSO에서는 physics feature가 internal teacher baseline 대비는 개선을 만들었지만, 아직 project-wide strongest baseline을 넘지는 못했다.

2 먼저 알아야 할 용어와 읽는 법

이번 보고서는 실험 수가 많고 용어가 자주 바뀌기 때문에, 먼저 몇 가지 핵심 용어를 고정해서 읽는 것이 좋다. 아래 표는 이후 모든 section에서 반복해서 나오는 표현을 같은 뜻으로 쓰기 위한 사전이다.

용어	정의	보고서에서의 의미
Robot angle	로봇 센서가 직접 측정한 hip / thigh 관련 관절각	입력의 기본 뼈대
Calibrated robot angle	offset/스케일 보정 후 robot angle	사람 hip angle에 더 가깝게 맞춘 기준선
Ground-truth human hip angle	mocap/kin_q에서 얻은 실제 hip flexion	최종 supervision
Residual target	ground truth - calibrated robot reference	모델이 직접 예측하는 보정량
Single LOSO	한 subject만 test로 두는 screening setup	빠른 가설 검증용
Full LOSO	8 subjects 전체를 각각 test로 두는 최종 검증	논문용 일반화 평가
Teacher	큰 TCN_MLP baseline	정확도 기준 strong reference
Tiny	경량 TCN_MLP baseline	deployable reference
Physics feature	worksplit, load_coupling, trunk_consistency 등	물리 해석 가능한 derived feature family

Table 1: 핵심 용어 정리

특히 residual target과 calibrated robot angle의 관계를 이해하는 것이 중요하다. 이 프로젝트는 절대 hip angle을 처음부터 끝까지 직접 맞추는 문제로 보지 않고, calibrated robot angle을 기준선으로 두고 그 위에 남는 오차를 예측하는 보정 문제로 본다. 즉 모델 출력은 '사람 hip angle 그 자체'가 아니라 '기준선에서 얼마나 더 보정해야 하는가'다.

3 문제 정의와 데이터

문제는 hip assistive wearable robot이 측정한 robot-side hip/thigh angle과 torque만으로는 실제 사람의 hip flexion angle을 정확히 알 수 없다는 데서 시작된다. 실제 착용 환경에서는 sensor가 사람이 아니라 로봇에 붙어 있고, 사람과 로봇이 완전히 강체처럼 붙어 있지 않기 때문에 상대운동과 compliance가 존재한다. 따라서 오차는 단순 노이즈가 아니라 human-robot interface dynamics에서 생기는 구조적 residual로 보는 것이 맞다.

데이터는 combined_data.h5이고, subject는 8명(S001-S008), condition은 7개(level 0.75/1.0/1.25 mps, accel sine, decline 5 deg, incline 10 deg, stop-and-go), misalignment level은 lv0/lv4/lv7이다. 샘플링은 100 Hz이며 출력은 mocap/kin₩{}_q의 hip₩{}_flexion₩{}_l, hip₩{}_flexion₩{}_r이다.

항목	값
피험자 수	8
조건 수	7
misalignment level	lv0 / lv4 / lv7
총 trial 수	169
샘플링 주파수	100 Hz
출력	mocap/kin_q의 hip_flexion_l, hip_flexion_r
screening 방식	single LOSO (주로 m2_S008)
최종 검증 방식	full LOSO 8 folds + 일부 seed 재현성

Table 2: 데이터셋과 검증 프로토콜 요약

실험 결과를 읽을 때는 single LOSO와 full LOSO를 반드시 구분해야 한다. screening 단계에서 좋아 보였던 feature가 full LOSO에서 사라진 사례가 여러 번 나왔기 때문이다. 따라서 single LOSO는 어디까지나 'signal detection' 단계로 읽어야 하고, full LOSO가 최종 결론을 결정한다.

구분	Single LOSO screening	Full LOSO validation
목적	가설 방향성 빠르게 확인	subject generalization 최종 검증
test subject	주로 m2_S008	m2_S001 ~ m2_S008 전체
validation	고정된 1개 subject	각 fold마다 test 제외 나머지 중 val 설정
해석 방식	상대 비교와 가설 선별	논문 메인 수치와 평균±표준편차
위험	subject-specific gain 착시	계산량 증가

Table 3: single LOSO와 full LOSO의 역할 구분

4 역사적 전체 성능 순위와 살아남은 모델

archive_season4를 설계하려면 먼저 '무엇이 역사적으로 실제로 살아남았는가'를 한눈에 봐야 한다. 아래 표는 season1-season2에서 동일한 shared hip-angle target 기준으로 평가된 모델들을 성능 순으로 정렬한 것이다. season3는 target 자체가 human thigh residual로 바뀌므로 이 표와 직접 섞지 않고 뒤에서 별도로 정리한다.

순위	실험	MAE	RMSE	R2	lag(ms)	비고
1	res noise 001	1.8848	2.3999	0.9823	6.00	공유 hip-angle target
2	ctrl quat residual	1.9848	2.5449	0.9801	6.00	공유 hip-angle target
3	res dropout 01	2.0432	2.6047	0.9792	6.00	공유 hip-angle target
4	bodyframe biomech fusion	2.0595	2.6481	0.9765	-0.36	공유 hip-angle target
5	quat dropout 015	2.0625	2.5960	0.9793	1.00	공유 hip-angle target
6	res mech power	2.1062	2.6523	0.9784	6.00	공유 hip-angle target
7	bodyframe mechpower kinematics	2.1259	2.7245	0.9772	2.50	공유 hip-angle target
8	res kin power	2.1363	2.7643	0.9765	1.00	공유 hip-angle target
9	feat quat mech kin	2.1385	2.7080	0.9775	2.00	공유 hip-angle target
10	quat k7	2.1434	2.7906	0.9761	5.50	공유 hip-angle target
11	ctx bodyframe mech kin win300 k7	2.1495	2.7002	0.9776	0.50	공유 hip-angle target
12	res k7	2.1578	2.7608	0.9766	4.00	공유 hip-angle target
13	mech power	2.1589	2.7509	0.9768	2.50	공유 hip-angle target
14	quat dropout 01	2.1706	2.7157	0.9774	6.00	공유 hip-angle target
15	feat bodyframe mech kin	2.1789	2.7290	0.9771	1.50	공유 hip-angle target
16	residual	2.1808	2.7235	0.9772	5.50	공유 hip-angle target
17	res deflection	2.1900	2.6995	0.9776	5.00	공유 hip-angle target
18	model bodyframe mech kin small	2.1962	2.7455	0.9769	0.50	공유 hip-angle target
19	ctrl hybrid bodyframe quat	2.1963	2.7652	0.9765	5.00	공유 hip-angle target
20	quat win300	2.2091	2.7867	0.9762	2.00	공유 hip-angle target
21	model bodyframe gated	2.2159	2.7502	0.9768	3.00	공유 hip-angle target
22	quaternion	2.2230	2.8388	0.9753	2.50	공유 hip-angle target
23	bodyframe core dropout005	2.2366	2.8175	0.9756	3.00	공유 hip-angle target
24	pre bodyframe mech kin lpf5	2.2433	2.8774	0.9746	-1.50	공유 hip-angle target
25	ctrl bodyframe core	2.2608	2.8561	0.9750	3.50	공유 hip-angle target

Table 4: 역사적 상위 25개 모델 성능 순위 (shared hip-angle target)

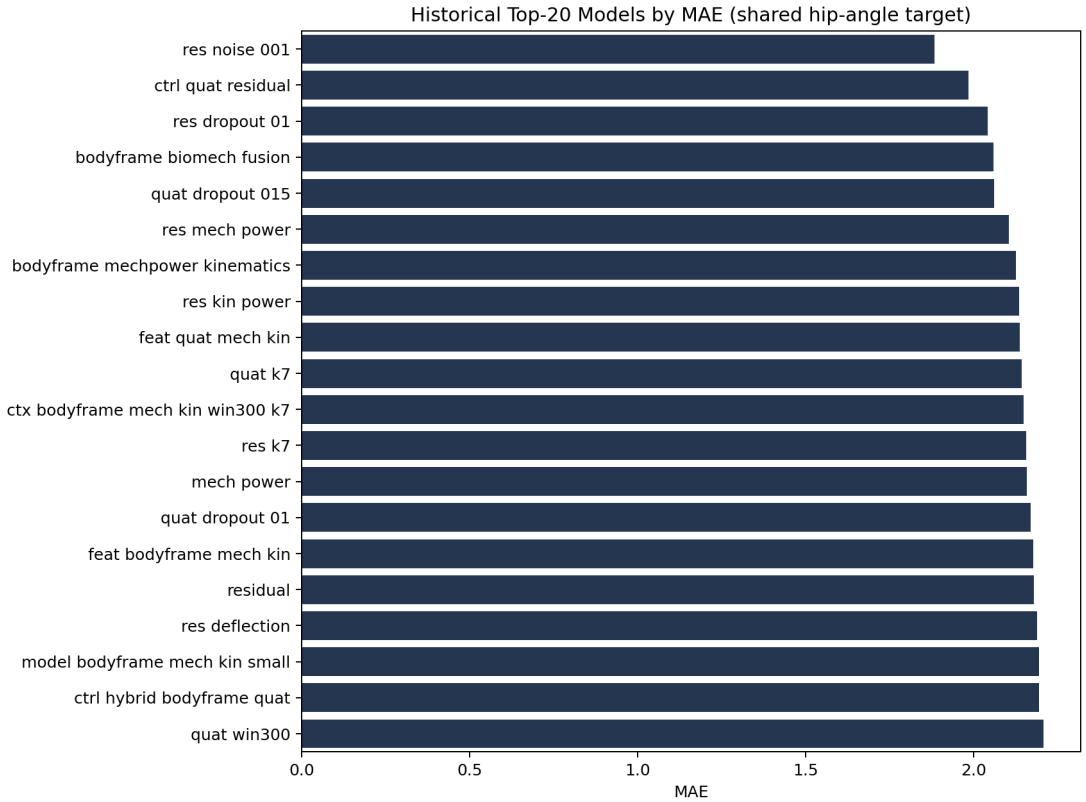

Figure 1: historical top-20 models by MAE

이 순위를 보면 상위권은 일관되게 orientation-preserving 입력을 유지한 residual TCN 계열이 차지한다. 즉 역사적으로 살아남은 축은 body-frame 대체가 아니라 Euler + quaternion + robot hip/thigh/torque + 경량 derived feature 구조다.

대표 모델	모델 구조	입력 구성	구조 세부	왜 좋은 결과를 보였는가
A5_res_noise_001	TCN residual baseline	Euler + quat + robot hip/thigh/torque	window 200, channels [32,64,64,128], kernel 5	historical single-LOSO strongest
A6 Teacher	TCN_MLP teacher	Euler + quat + robot hip/thigh/torque + derivatives + mech_power	window 200, channels [32,64,64,128], kernel 5	full-LOSO accuracy anchor
A6 Tiny	TCN_MLP tiny	same as teacher	window 100, channels [16,24,24,48], kernel 3	full-LOSO best deployable model
A8 Norm Worksplit Teacher	teacher + physics feature	teacher input + normalized interface worksplit	teacher backbone + interface_workloop 6ch	physics-feature full-LOSO best
S3 Factorized Tiny Full	FactorizedBranchTCN tiny	raw/orientation branch + geometry/compliance/hysteresis branches	window 100, factorized branches, channels [12,16,16,24]	season3 human-thigh target best

Table 5: 좋은 결과를 보인 대표 모델과 구조 요약

5 입력 feature, 전처리, 출력 구성

입력은 크게 네 계층으로 나눌 수 있다. (1) trunk IMU raw signal과 quaternion, (2) robot hip/thigh/torque 원천 신호, (3) 미분 및 power 같은 경량 derived feature, (4) body-frame, load-coupling, trunk-consistency처럼 특정 가설을 반영한 실험용 derived feature다.

공통 전처리는 quaternion sign continuity, complementary filter 기반 Euler angle, finite difference+저역통과 기반 derivative, calibration offset 추정, 그리고 residual target 구성이다. 특히 residual target은 이 프로젝트의 핵심 설계다. 모델이 직접 절대 hip angle을 맞추는 대신, calibrated robot reference와 실제 human hip angle 사이의 차이를 예측함으로써, 문제를 '보정량 추정'으로 바꾼다.

feature group	예시 채널	생성 방식	계산 부담	프로젝트 내 역할
derived/euler	roll, pitch, yaw	complementary filter	낮음	최종 teacher/tiny 핵심
robot kinematics	hip_angle, thigh_angle, torque	raw signal	매우 낮음	모든 archive의 기본 골격
quat	quat_wxyz	raw signal	매우 낮음	orientation-preserving baseline
derivative	thigh_angle_dot, torque_dot	finite diff + LPF	낮음	A4 이후 꾸준히 채택
mech_power	left/right power	torque × hip_angle_dot	낮음	A5/A6 최종 후보에 포함
body_frame_imu	acc/gyro in body frame	global rotation + gravity remove + PCA heading	높음	A1-A3 실험용
gravity_aligned_imu	gravity-only aligned acc/gyro	z_up만 정렬	중간	A3 실험용
symmetry_heading_imu	symmetry-yaw aligned IMU	yaw 후보 search	중간	A3 실험용
load_coupling	torque × gap	torque와 gap의 곱	낮음	A5/A8 physics family
interface_workloop	pos/neg/net work	rolling work split	낮음	A7/A8 physics family
trunk_consistency	gyro minus thighdot / pitchdot	trunk-robot consistency residual	낮음	A7/A8 physics family
effective_impedance	k,c,b,pred_err	online RLS	중간	A7 physics family

Table 6: 입력 feature 계층과 프로젝트 내 역할

입력/출력	채널 예시	계산식/생성 방법	왜 썼는지
quat_wxyz	quat_w, quat_x, quat_y, quat_z	raw quaternion	절대 orientation 보존
derived/euler	roll, pitch, yaw	complementary filter	직관적 orientation state
robot hip/thigh/torque	left/right hip_angle, thigh_angle, torque	raw sensor	misalignment 보정의 기본 관측량
thigh_angle_dot	left/right thigh angular velocity	finite difference + smoothing	동역학 변화율 반영
torque_dot	left/right torque derivative	finite difference + smoothing	부하 변화율 반영
mech_power	left/right mechanical power	torque × hip_angle_dot	일/에너지 흐름 반영
load_coupling	torque-weighted gap features	torque × (pitch-gap / hip-thigh-gap)	부하와 mismatch의 결합
interface_workloop	W+, W-, Wnet	rolling positive/negative work split	에너지 손실과 hysteresis 요약
trunk_consistency	gyro-vs-kinematics residual	trunk orientation과 robot motion의 불일치	sensor fusion consistency 반영
effective_impedance	k, c, b, pred_err	online RLS	인터페이스 동역학 상태 근사
target	left/right hip residual	GT - calibrated robot angle	직접 각도 대신 보정량 예측

Table 7: feature dictionary: 무엇을 어떻게 만들었고 왜 넣었는가

중요한 해석은 이것이다. 최종적으로 살아남은 feature는 대부분 O(1) 또는 짧은 rolling 통계 수준이다. body-frame PCA heading, symmetry-yaw, heavy latent-state 추정처럼 계산량이 더 큰 표현은 final candidate에서 제외되었다. 즉 이 프로젝트는 후반으로 갈수록 accuracy와 함께 실시간성 제약을 더 강하게 반영하게 되었다.

6 모델 구조와 학습 전략

기본 backbone은 TCN_MLP다. dilation이 증가하는 temporal convolution block으로 context를 인코딩한 뒤, 마지막 시점 feature를 작은 MLP head에 넣는다. teacher는 window 200, channels [32,64,64,128], kernel 5를 쓰고, tiny는 window 100, channels [16,24,24,48], kernel 3으로 경량화한다.

학습 공통 설정은 batch 128, epochs 30, lr 0.001, wd 0.01, AMP, cosine scheduler, early stopping이다. screening archive는 single LOSO로 방향성을 빠르게 확인하고, 최종 후보 archive는 full LOSO와 seed 재현성까지 본다.

모델	구조	입력 window	channels	kernel	head	파라미터	모델 크기(MB)
Teacher	TCN_MLP	200	[32,64,64,128]	5	[64]	224,072	0.8548
Tiny	TCN_MLP	100	[16,24,24,48]	3	[32]	22,720	0.0867
Tiny+LoadGate	LoadGatedTCN	100	[16,24,24,48]	3	[32]	23,597	0.0900

Table 8: 최종 모델 family 구조 비교

LoadGatedTCN은 load-related 입력에서 게이트를 계산해 전체 입력을 time-step별로 scaling하는 구조였다. 하지만 full LOSO와 재현성 검증에서 standard tiny를 넘지 못했다. 따라서 gating은 흥미로운 negative result로 남았고, 최종 메인 모델은 standard tiny causal TCN으로 수렴했다.

모델 구조를 읽는 가장 쉬운 방법은 teacher와 tiny를 같은 backbone의 두 스케일 버전으로 보는 것이다. teacher는 '이 정도면 충분히 강한 큰 모델'을 의미하고, tiny는 같은 입력 표현을 유지하되 window와 채널 수를 줄여 배포성을 노린 버전이다. 따라서 두 모델의 차이는 아이디어 차이보다 '같은 문제를 얼마나 작은 계산량으로 풀 수 있느냐'에 있다.

7 전체 archive 흐름 요약

archive를 시간순으로 보면 프로젝트의 가설 정제 과정이 보인다. A1-A3는 representation과 좌표계 문제, A4-A5는 biomechanical/misalignment feature 문제, A6는 deployability 문제, A7-A8은 physics feature의 직접적 효과를 다시 검증하는 문제였다.

Archive	기여 축	최고 실험	MAE	RMSE	핵심 해석
A1	body-frame + biomech screening	bodyframe biomech fusion	1.9862	2.5760	body-frame 단독은 약했고 mech+kin 보조가 가장 유의미
A2	controlled representation / architecture	feat quat mech kin	2.0297	2.5799	controlled 비교에서도 body-frame replacement는 실패
A3	representation study	Euler + quaternion reference	2.0336	2.6182	orientation-preserving representation이 더 안정적
A4	biomechanical feature screening	quat + kinematic derivatives	2.0425	2.5945	기존 biomech feature 중 derivative 계열만 약하게 유효
A5	misalignment-aware feature screening	quat residual kin+power baseline	2.0229	2.5763	load_coupling만 부분적으로 가능성, 나머지는 불안정
A6(screen)	deployable model screening	teacher kinpower baseline	1.9980	2.5475	deployability 중심으로 tiny가 최종 후보군에 진입
A7(screen)	physics feature screening	teacher + interface worksplit	1.9660	2.4881	physics feature가 single-LOSO에서 강한 신호를 보임
A8(screen)	physics feature re-screening	teacher + short-window worksplit	2.0043	2.5795	physics feature를 재설계했더니 S008에서는 baseline을 확실히 이김

Table 9: archive별 최고 결과와 핵심 해석

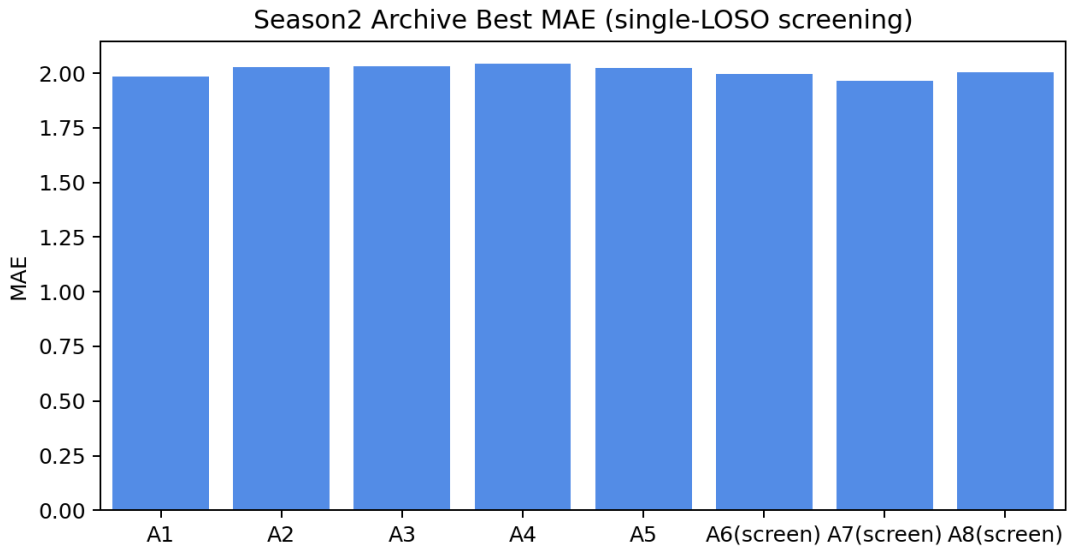

Figure 2: season2 archive별 최고 single-LOSO MAE 진행

A1과 A2의 핵심 질문은 'body-frame이나 더 물리적인 표현이 더 좋을까'였다. 결과는 아니었다. A3는 이 질문을 더 엄격하게 검증했고, raw+quat 또는 gravity+quat가 더 강했다. A4와 A5는 '그러면 misalignment-aware biomechanical feature가 핵심 아닐까'를 시험했지만, additive gain은 약했다. A6는 방향을 바꿔 tiny deployable model을 찾는 단계였다. A7과 A8은 다시 physics feature를 정교하게 다듬어, 정말 physics-informed feature가 baseline을 이길 수 있는지를 재검증한 단계다.

항목	내용
가설	더 물리적으로 정렬된 body-frame / heading-normalized IMU가 raw/orientation-preserving 입력보다 좋을 것이다
실험 설계	body-frame, gravity-only, symmetry-yaw, hybrid, context 확장 등 비교
성공/실패	body-frame 단독 대체는 실패, raw+quat / euler+quat가 더 안정적
판단	이 문제는 aggressive normalization보다 orientation 정보 보존이 중요

Table 10: Archive 1-3: 가설-설계-결과-판단

7.1 Archive 1-3: representation과 body-frame 탐색

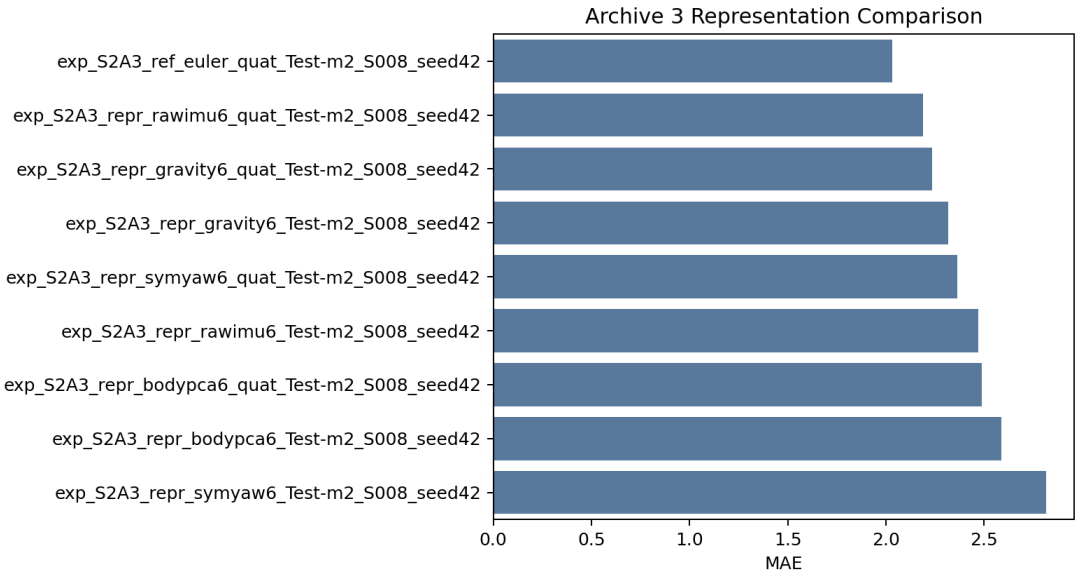

Figure 3: archive 3 representation comparison

A1과 A2에서는 body-frame, gait/asymmetry, biomech fusion, longer context, hybrid representation 등을 비교했다. 결론은 body-frame 단독 대체는 강하지 않고, quat/euler를 보존한 baseline이 더 안정적이라는 점이었다. A3에서 raw trunk IMU, gravity-only, symmetry-yaw, PCA body-frame을 통제해서 비교했을 때도 같은 메시지가 반복되었다. 특히 treadmill 환경에서는 heading normalization이 생각만큼 유효하지 않았다.

7.2 Archive 4-5: biomechanical feature screening

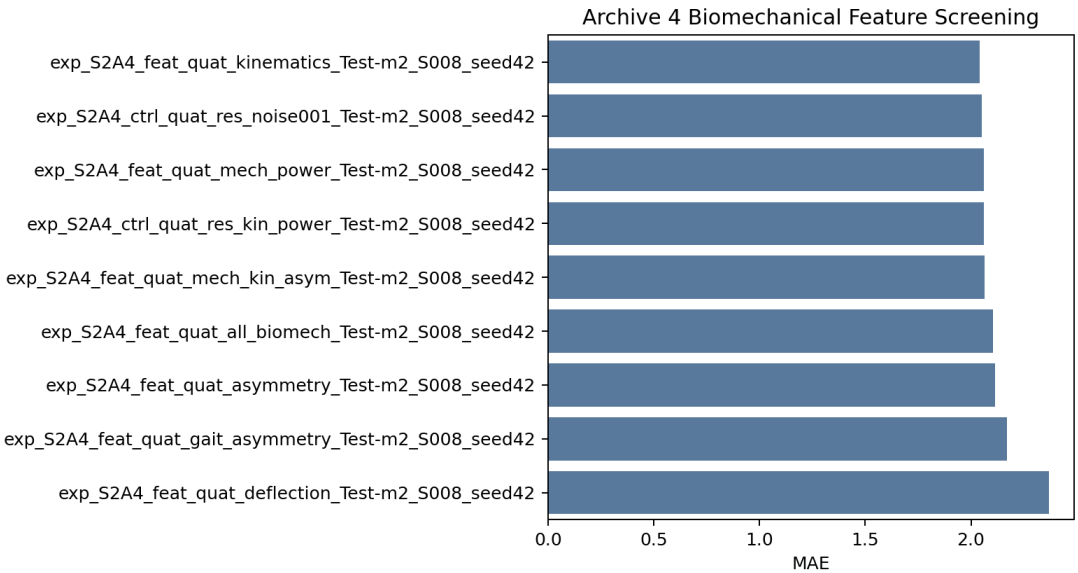

Figure 4: archive 4 biomechanical feature screening

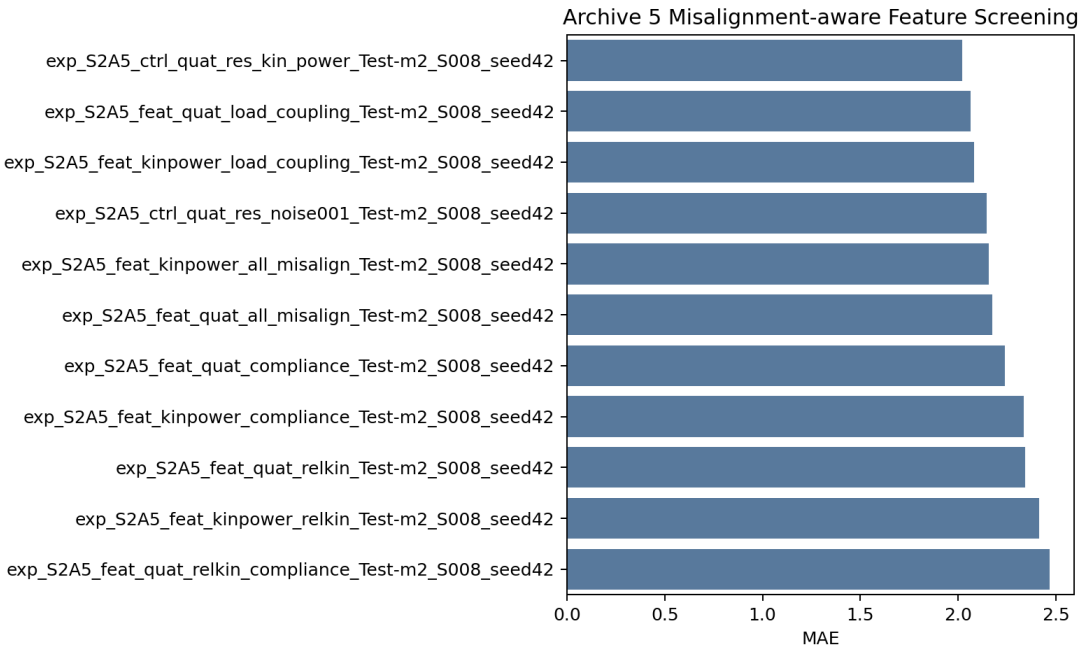

Figure 5: archive 5 misalignment-aware feature screening

A4에서는 kinematics, mech_power, deflection, asymmetry 등을 teacher-style baseline 위에 올려봤다. 이 단계에서 derivative와 mech_power는 살아남았지만, feature를 많이 넣는다고 자동으로 좋아지지는 않았다. A5에서는 relative_kinematics, compliance_proxy, load_coupling처럼 misalignment-specific feature를 설계했지만, 그중 generalization 가능성이 있었던 것은 load_coupling 정도였다.

항목	내용
가설	biomechanical / misalignment-aware handcrafted feature를 strong baseline 위에 얹으면 additive gain이 날 것이다
실험 설계	kinematics, mech_power, asymmetry, deflection, load_coupling, relkin, compliance proxy 비교
성공/실패	derivative와 일부 load_coupling만 부분 성공, 대량 concat은 반복적으로 실패
판단	feature family는 선별적으로 써야 하고, 많이 합친다고 좋아지지 않음

Table 11: Archive 4-5: 가설-설계-결과-판단

7.3 Archive 6: deployability로의 수렴

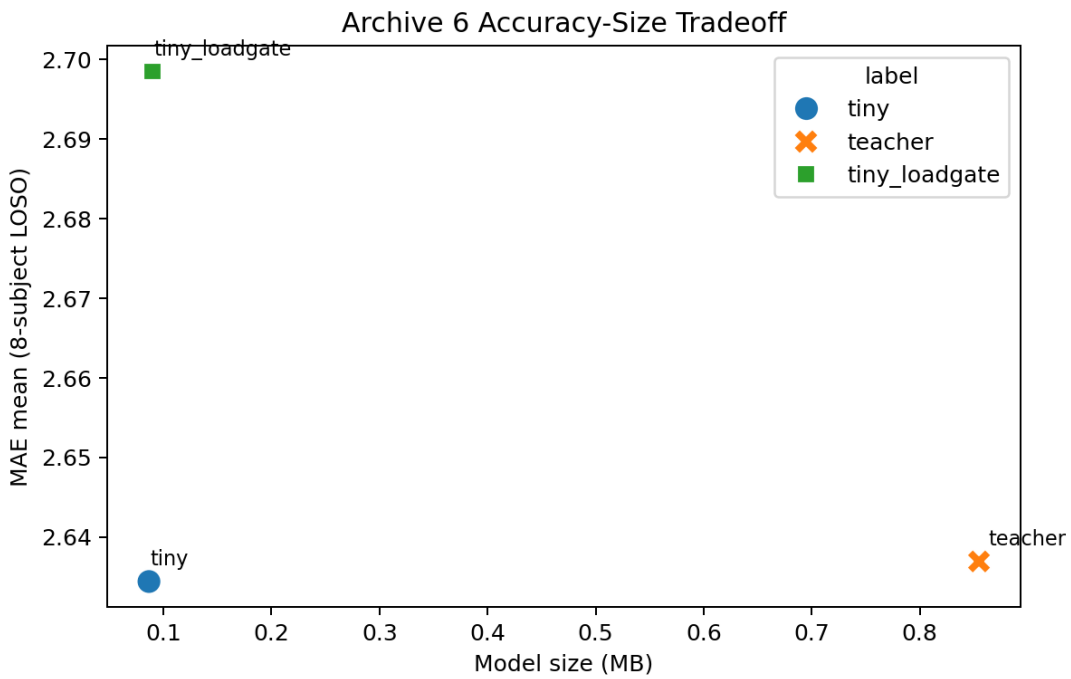

Figure 6: archive 6 accuracy-size tradeoff

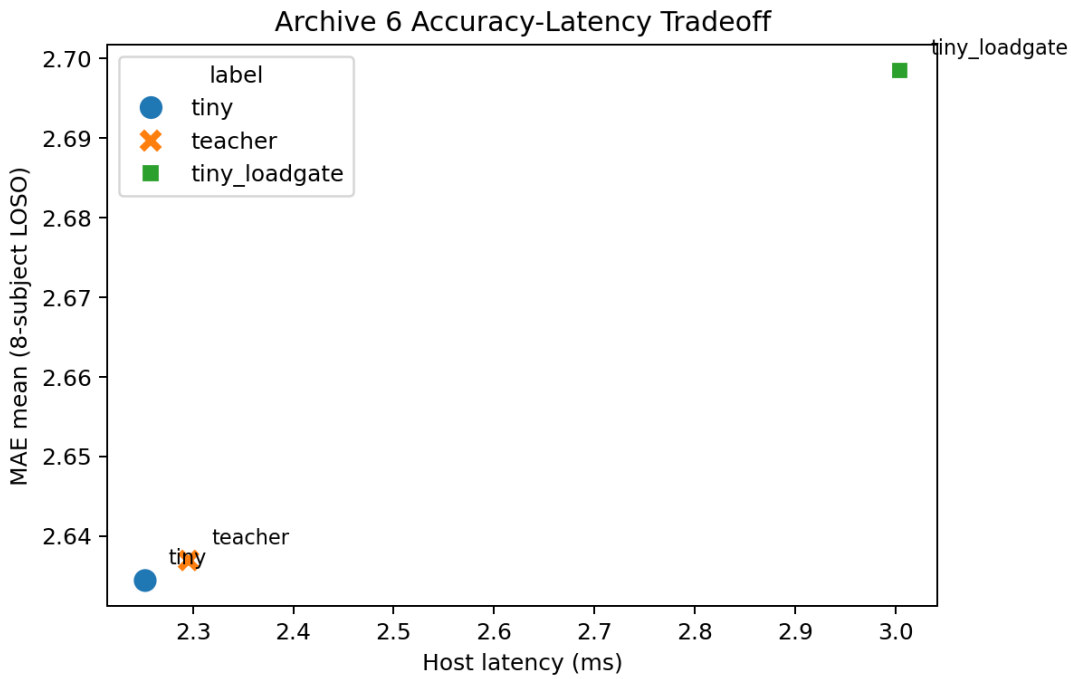

Figure 7: archive 6 accuracy-latency tradeoff

A6의 목표 축은 명확했다. accuracy만이 아니라 latency, parameter count, deployability를 같이 본다. 결과적으로 tiny는 teacher보다 약 90% 작은 모델 크기와 훨씬 작은 parameter count를 가지면서, full LOSO에서 accuracy 손해를 작게 유지했다. 이 결과 때문에 프로젝트의 strongest claim은 정확도 absolute best보다, deployable misalignment compensation 시스템 쪽으로 이동했다.

모델	n_folds	MAE mean	MAE std	RMSE mean	Params	Size(MB)	Latency(ms)	Max freq(Hz)
Tiny	8	2.6344	0.4658	3.6293	22,720	0.0867	2.2525	446.1
Teacher	8	2.6369	0.5847	3.6068	224,072	0.8548	2.2957	442.4
Tiny+LoadGate	8	2.6985	0.5284	3.7292	23,597	0.0900	3.0045	349.3

Table 12: archive 6 final full LOSO 결과

모델	n_runs	n_seeds	MAE mean	MAE std	RMSE mean	Latency(ms)	Size(MB)
Teacher	24	3	2.6494	0.6067	3.6146	2.3491	0.8548
Tiny	24	3	2.7057	0.5678	3.6964	2.0984	0.0867

Table 13: archive 6 3-seed 재현성 요약

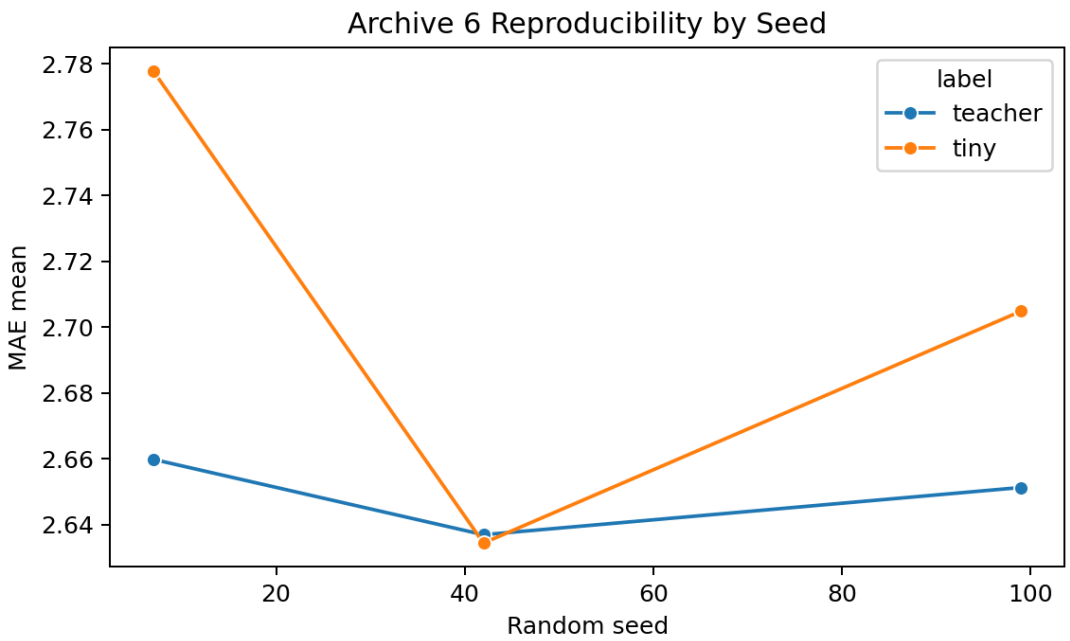

Figure 8: archive 6 seed별 MAE mean

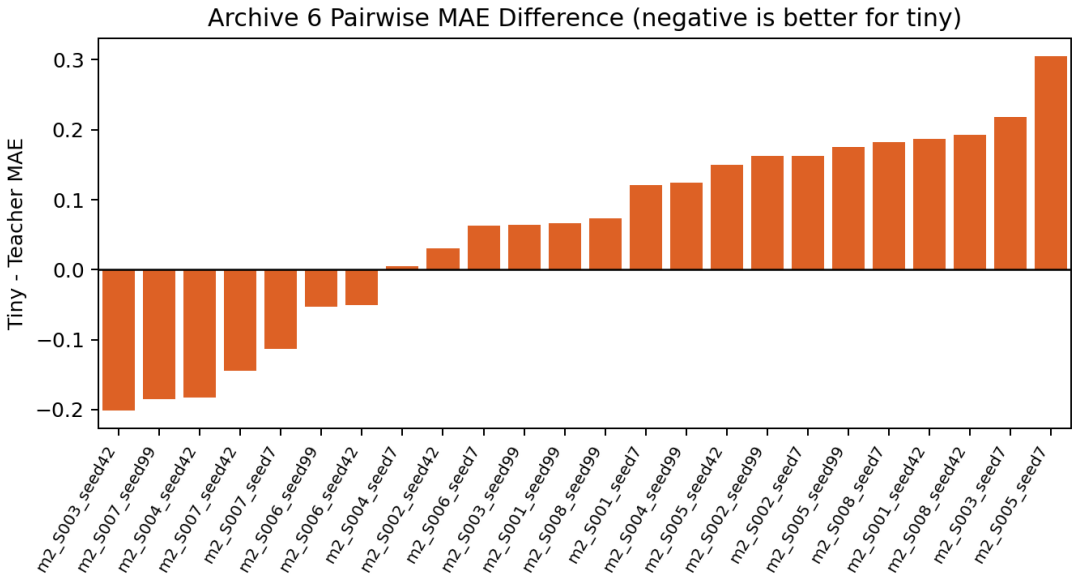

Figure 9: subject×seed pair별 Tiny-Teacher MAE 차이

재현성까지 포함하면 tiny가 teacher를 완전히 이긴다고 말하긴 어렵다. 총 24쌍의 subject×seed 비교에서 Tiny가 더 좋은 경우는 7회, Teacher가 더 좋은 경우는 17회였다. 하지만 Tiny는 accuracy 손해를 매우 작게 유지하면서 모델 크기와 배포 부담을 크게 줄였기 때문에, 논문 메인 proposed model로는 오히려 더 설득력 있다.

항목	내용
가설	정확도를 크게 잃지 않으면서도 훨씬 가벼운 deployable 모델을 만들 수 있다
실험 설계	teacher / tiny / loadgate 비교, full LOSO + 3-seed 재현성
성공/실패	tiny는 teacher와 거의 비슷한 정확도로 10배 작은 모델을 달성, loadgate는 최종 winner 실패
판단	deployability 관점의 strongest story는 tiny causal TCN

Table 14: Archive 6: 가설-설계-결과-판단

7.4 Archive 7-8: physics feature 재검증

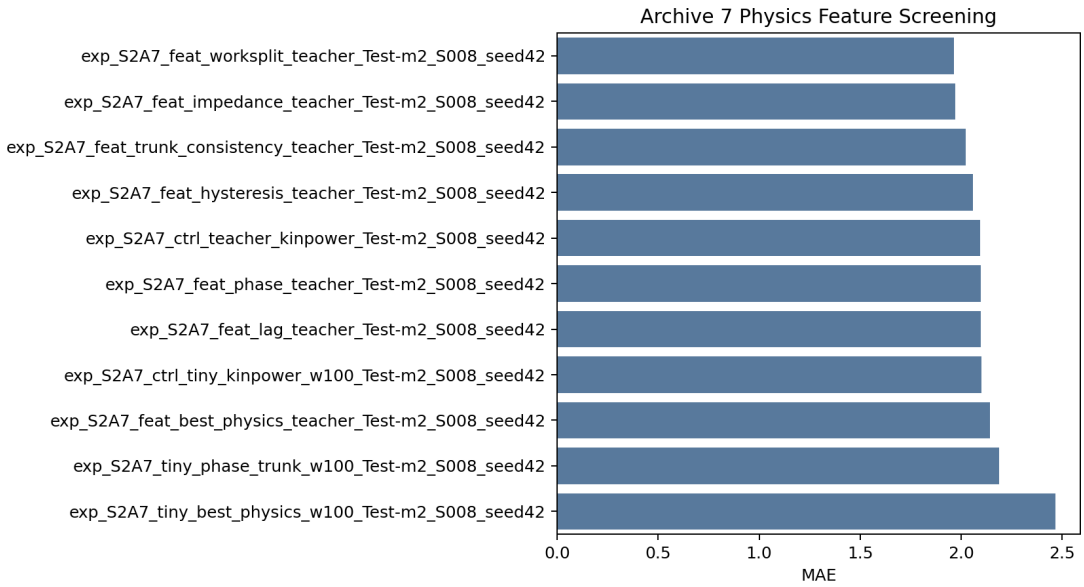

Figure 10: archive 7 physics feature screening

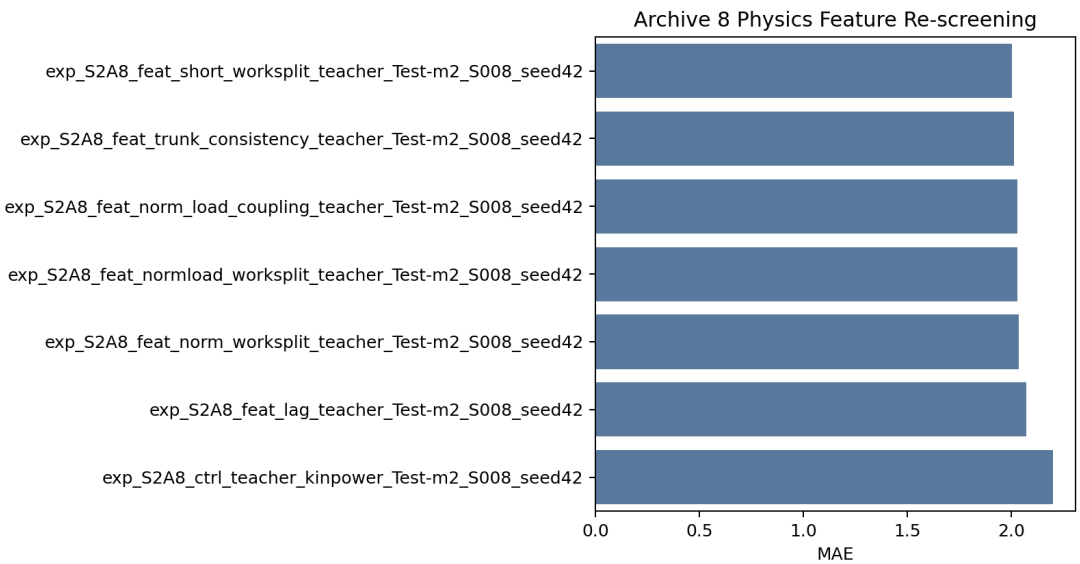

Figure 11: archive 8 physics feature re-screening

A7은 interface work split, hysteresis, effective impedance, lag, phase, trunk consistency를 직접 비교한 archive였다. single-LOSO에서는 worksplit과 impedance가 매우 강해 보였다. 하지만 full LOSO로 올리면 그 gain이 줄어들었다. 이 때문에 A8에서는 worksplit과 load_coupling을 정규화/짧은 window로 재설계하고, trunk consistency와 lag를 다시 좁게 검증했다.

A8 single-LOSO에서는 physics feature가 정말로 baseline을 크게 이겼다. short worksplit, normalized load coupling, trunk consistency, normalized worksplit가 모두 baseline 대비 13% 이상 개선을 보였다. 하지만 A8 full LOSO에서는 그 신호가 줄어들었다. 그럼에도 normalized worksplit와 trunk consistency는 archive_8 내부 baseline보다 조금 더 좋은 평균을 보였다.

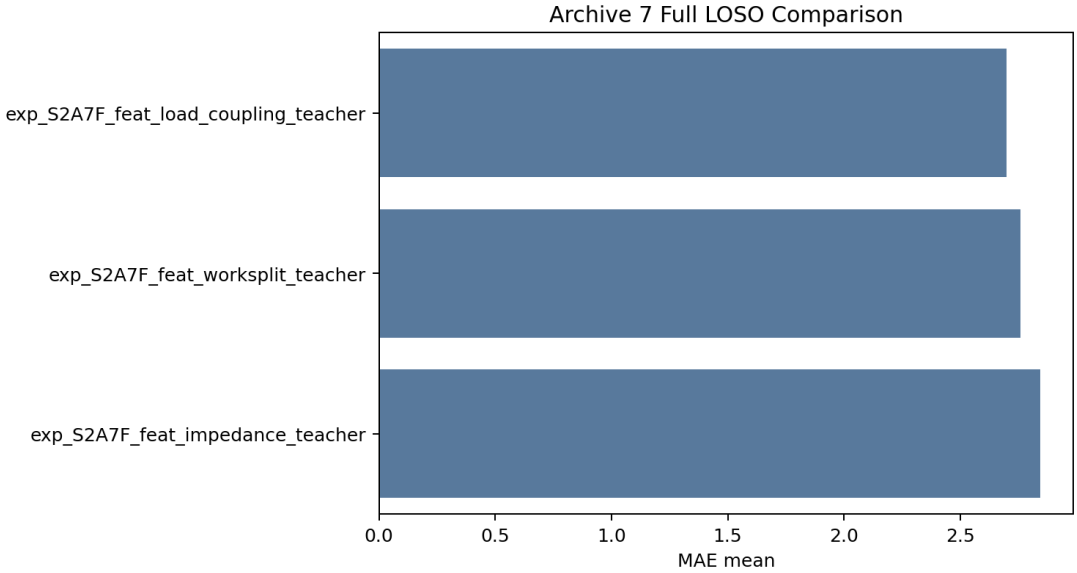

Figure 12: archive 7 full LOSO comparison

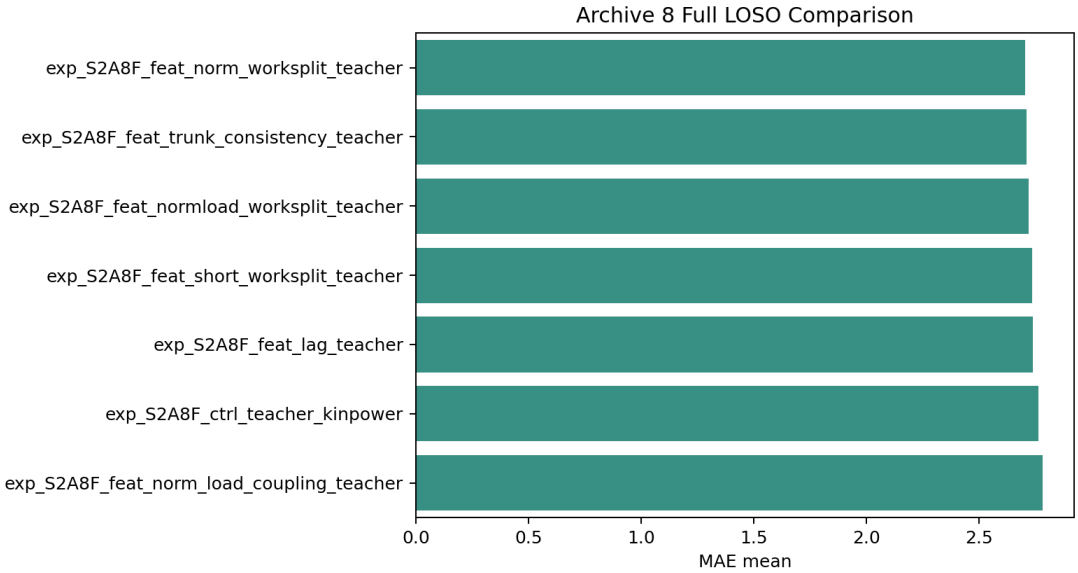

Figure 13: archive 8 full LOSO comparison

모델	MAE mean	MAE std	RMSE mean	Latency(ms)	A8 baseline 대비
teacher + normalized worksplit	2.7028	0.6794	3.6618	2.2697	-0.0615
teacher + trunk consistency	2.7109	0.4954	3.7068	2.1483	-0.0535
teacher + normalized load + worksplit	2.7196	0.5005	3.7217	2.1868	-0.0448
teacher + short-window worksplit	2.7354	0.6026	3.7203	2.2791	-0.0289
teacher + interface lag	2.7379	0.5972	3.7390	1.8998	-0.0264
teacher kinpower baseline	2.7643	0.4888	3.7464	2.3368	baseline
teacher + normalized load coupling	2.7825	0.5578	3.7657	2.4192	+0.0182

Table 15: archive 8 full LOSO 결과 요약

A8 full LOSO의 핵심 해석은 이렇다. physics feature는 분명히 완전히 죽지 않았고, normalized worksplit나 trunk consistency처럼 일부 family는 baseline보다 소폭 개선을 만들었다. 하지만 그 개선은 아직 project-wide strongest baseline(A6 teacher/tiny)을 넘는 수준은 아니다. 즉 physics feature가 완전히 틀린 방향은 아니지만, 지금 단계에서는 strongest final claim으로 쓰기엔 한 단계 부족하다.

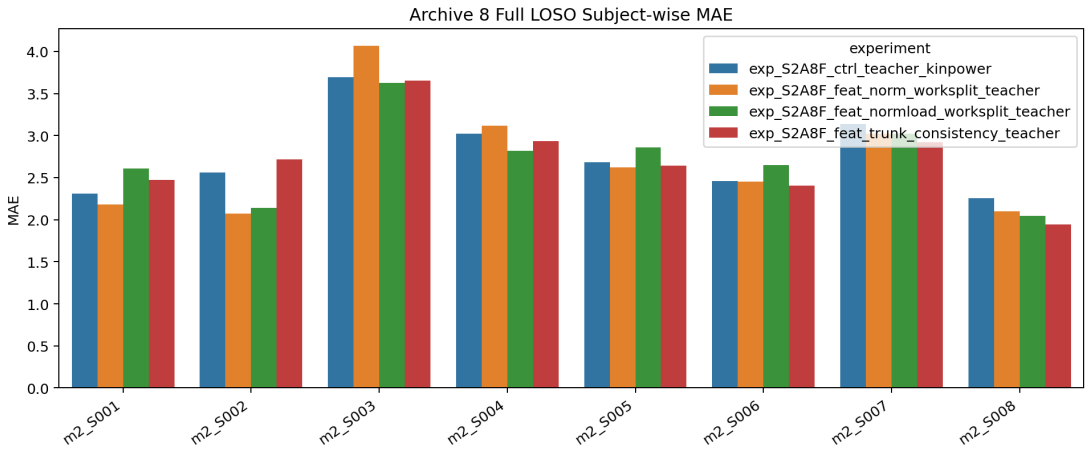

Figure 14: archive 8 full LOSO subject-wise MAE

subject-wise로 보면 A8 physics candidate의 gain은 특정 subject에서 더 강하고, 다른 subject에서는 baseline과 비슷하거나 불리하다. 이런 패턴은 physics feature가 single-LOSO에서 크게 좋아 보이다가 full LOSO에서 average gain이 줄어든 이유를 설명해 준다.

항목	내용
가설	physics feature를 제대로 설계하면 최종 baseline을 넘길 수 있다
실험 설계	worksplit, hysteresis, impedance, lag, trunk consistency를 screening 후 full LOSO 재검증
성공/실패	single LOSO에서는 강한 gain, full LOSO에서는 internal baseline 소폭 개선까지만 확인
판단	physics feature는 가능성이 있으나 strongest project-wide baseline까지는 아직 못 넘음

Table 16: Archive 7-8: 가설-설계-결과-판단

8 Season3 target 재정의 실험

season3는 앞선 season1-2와 문제 정의 자체가 다르다. output을 기존 hip flexion residual에서 human thigh residual로 재정의하고, baseline을 calibrated robot thigh로 두었다. 구체적으로 human thigh는 pelvis₩{}_tilt + hip₩{}_flexion으로 정의했고, 그 위에 physics branch를 분리한 factorized 구조가 유효한지 확인했다.

이 실험군은 절대 성능을 season2와 바로 비교하기보다는, 'physics 정보를 raw branch와 분리했을 때 target 재정의 문제에서 도움이 되는가'를 보는 exploratory stage로 읽어야 한다. 즉 season3는 strongest final model을 만들기보다, season4에서 structure-oriented archive를 설계할 때 어떤 branch가 살아남는지를 보기 위한 bridge 역할에 가깝다.

모델	MAE mean	MAE std	RMSE mean	Latency(ms)	Size(MB)	해석
factorized tiny full	5.3672	0.2447	7.0827	9.0914	0.0713	season3 internal best
tiny thigh baseline	5.4073	0.2758	7.1483	2.3603	0.0867	plain tiny baseline
factorized teacher full	5.4350	0.3880	7.0378	9.8855	0.2017	factorized teacher full
teacher thigh baseline	5.6049	0.1348	7.3501	2.4895	0.8548	teacher baseline
grouped linear physics-only	6.4727	0.6219	8.4320	3.0405	0.0003	linear grouped physics only
factorized teacher physics-only	7.3490	1.5413	9.1741	7.6123	0.1496	physics-only ablation

Table 17: season3 archive_1 요약 (human-thigh target, 3-subject mini-LOSO × 2 seeds)

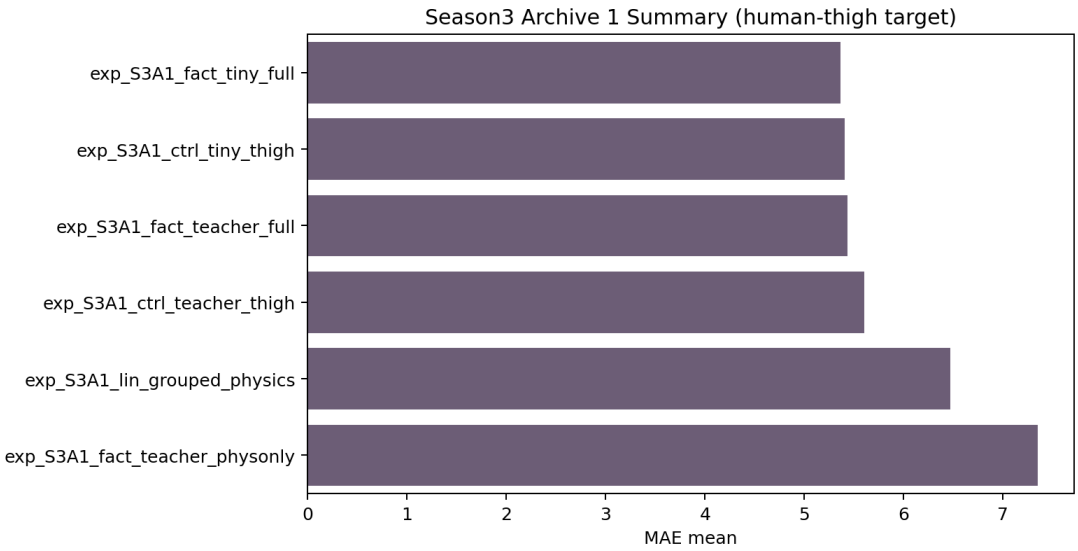

Figure 15: season3 archive_1 summary

season3의 핵심 결론은 세 가지다. 첫째, physics-only 또는 grouped-linear baseline은 시각적으로도 수치적으로도 부족했다. 둘째, factorized full 구조는 plain baseline보다 약간 좋아졌지만 calibrated robot thigh를 충분히 벗어나지는 못했다. 셋째, season3 best인 factorized tiny full조차 season2 strongest baseline보다 절대 수치는 훨씬 뒤진다. 따라서 season3는 최종 모델이 아니라 'physics-aware branch를 어떻게 다뤄야 하는가'에 대한 구조적 시사점으로 사용하는 것이 맞다.

9 대표 trajectory와 정성 분석

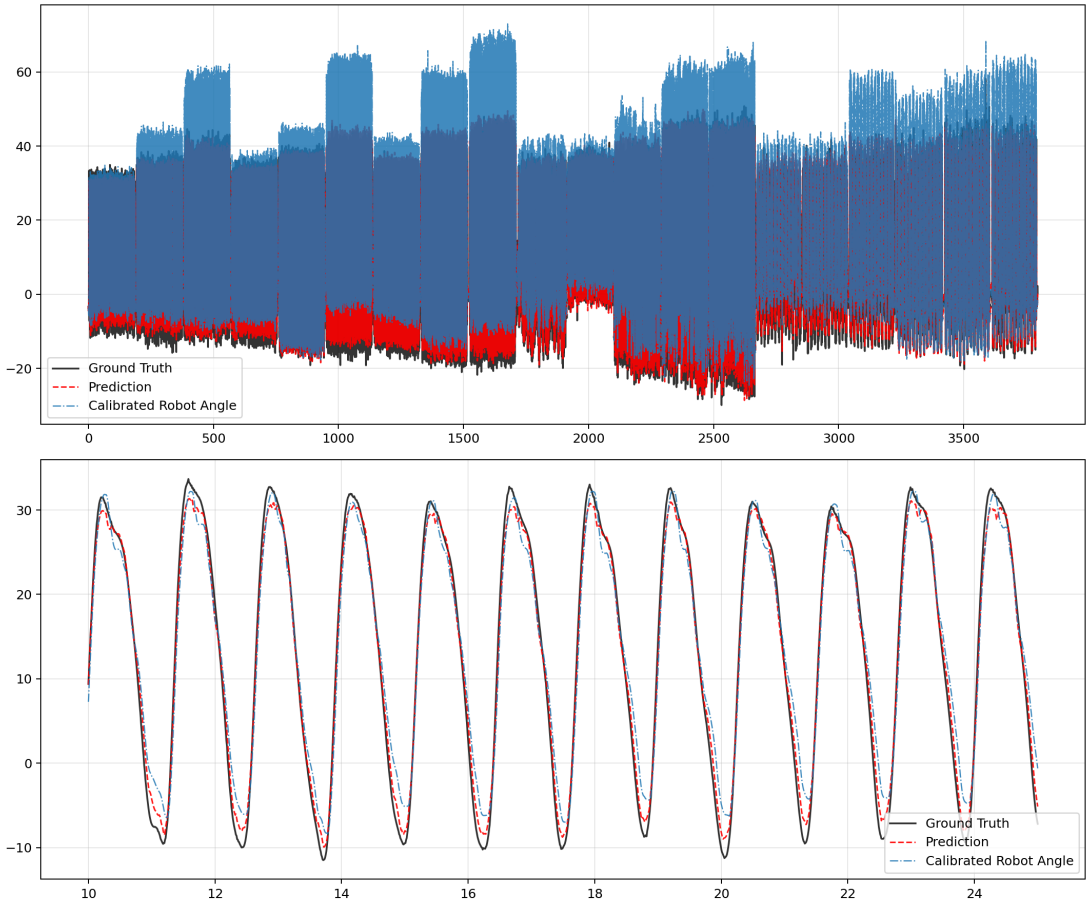

Figure 16: A6 Teacher representative trajectory (prediction / ground truth / calibrated robot angle)

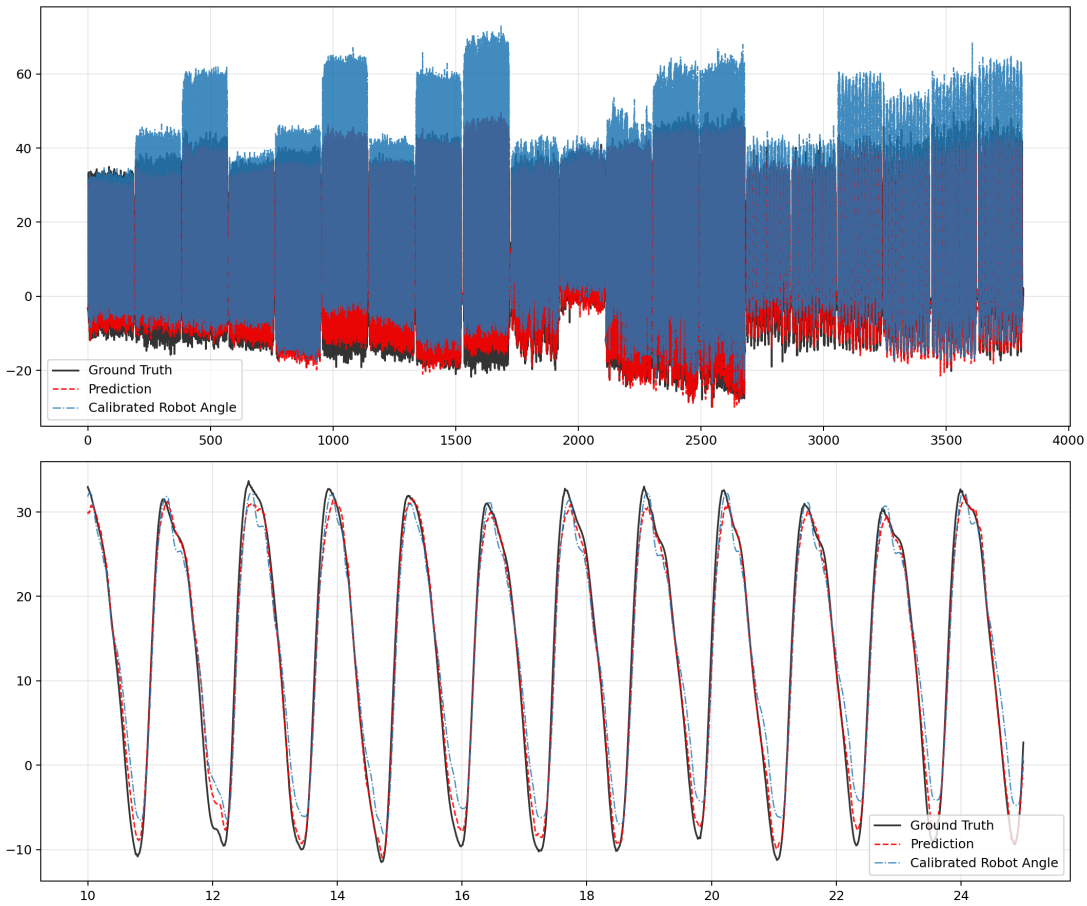

Figure 17: A6 Tiny representative trajectory (prediction / ground truth / calibrated robot angle)

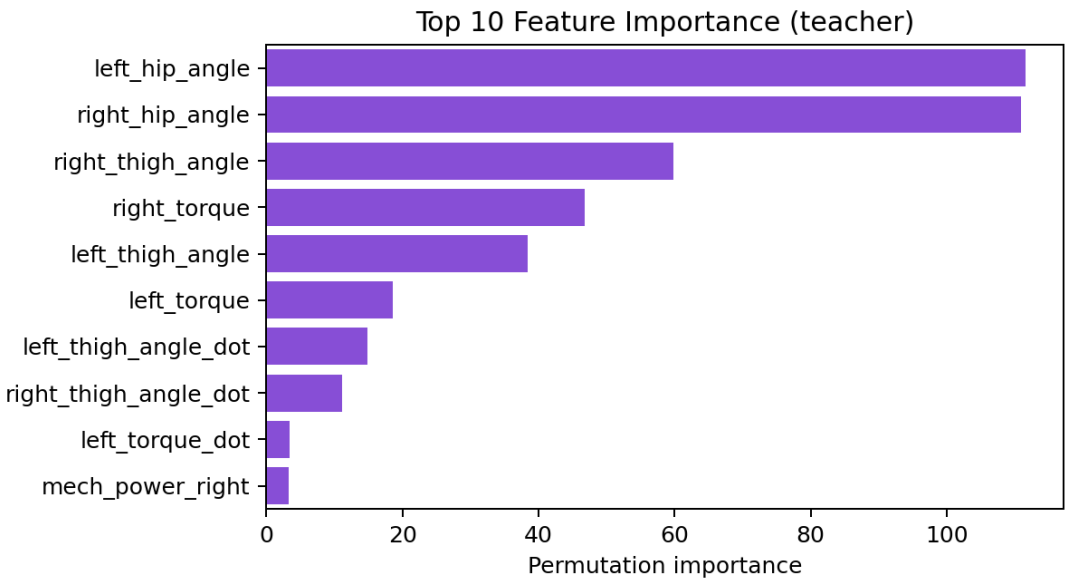

Figure 18: Teacher top-10 feature importance

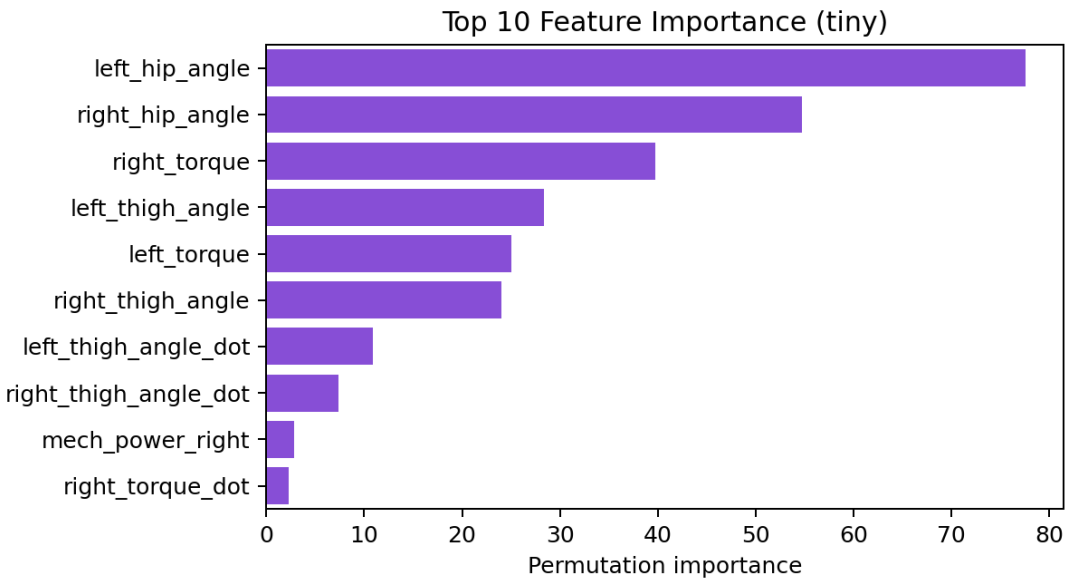

Figure 19: Tiny top-10 feature importance

Teacher와 Tiny의 feature importance는 공통적으로 robot hip angle, torque, thigh angle, derivative, 그리고 일부 orientation 정보를 가장 중요하게 사용하고 있음을 보여준다. 즉 이 문제는 결국 body-frame을 얼마나 정교하게 만들었느냐보다, robot-human interface에서 바로 측정되는 관찰량과 orientation 정보를 얼마나 적절히 보존했느냐의 문제에 더 가깝다.

10 실시간 추론 가능성

본 프로젝트에서 최종적으로 살아남은 모델은 나중에 실시간 inference에 들어가야 한다는 제약 아래 설계되었다. 따라서 전처리부터 모델 추론까지 전체 파이프라인의 계산량이 가벼워야 한다. 최종 tiny와 teacher는 complementary filter Euler, quaternion raw input, derivative, mech_power만 사용한다. 이들은 모두 sample당 O(1) 혹은 짧은 rolling 통계 수준이다.

구성 요소	최종 구현	계산 부담	판단
Euler 추정	Complementary filter	sample당 O(1)	채택
Quaternion 사용	raw quat_wxyz 직접 입력	매우 낮음	채택
Derivative	finite difference + LPF	낮음	채택
mech_power	torque × hip_angle_dot	매우 낮음	채택
body-frame heading	PCA / symmetry yaw	중간~높음	최종 후보 제외
effective impedance	online RLS	중간	research feature로만 사용
Tiny inference	window 100 causal TCN	약 2.10 ms	100 Hz 가능

Table 18: 실시간 추론 가능성 관점의 계산 부담 분석

100 Hz loop를 가정하면 주기당 예산은 10 ms다. tiny의 host latency는 약 2.10 ms이므로 추론만 놓고는 예산의 약 21% 수준이다. 전처리 역시 O(1) 수준이라 sample-by-sample online 구현이 가능하다. 반면 body-frame PCA heading은 고유값 분해가 필요하기 때문에 final online candidate에서 제외한 판단이 타당하다.

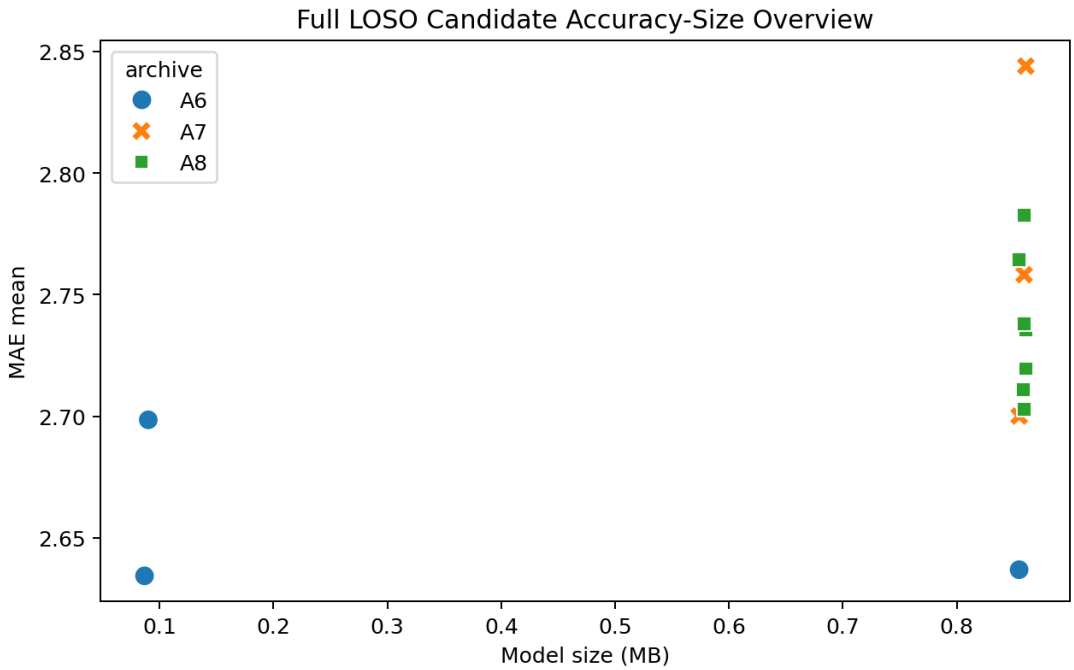

Figure 20: full LOSO candidate accuracy-size overview

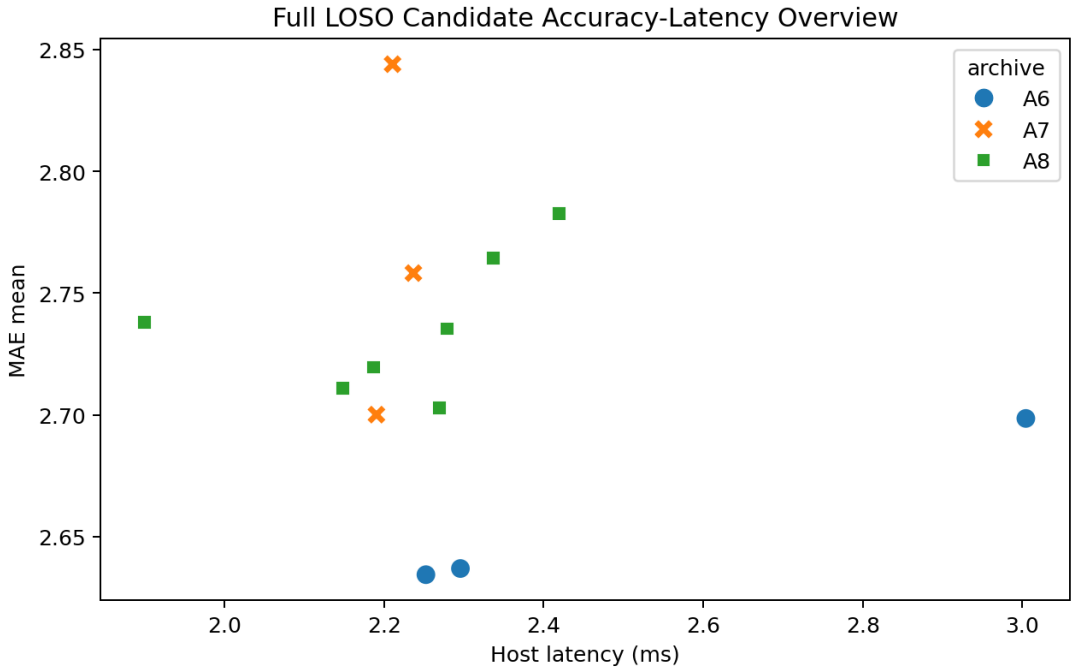

Figure 21: full LOSO candidate accuracy-latency overview

11 논문화 시 contribution과 메시지

지금 결과를 과장 없이 정리하면, 가장 강하게 주장할 수 있는 contribution은 세 가지다. 첫째, wearable hip exoskeleton misalignment compensation을 software-only residual correction

문제로 정식화했다는 점이다. 둘째, orientation-preserving sensor fusion이 aggressive body-frame normalization보다 더 안정적임을 controlled archive 실험으로 보였다는 점이다. 셋째, biomechanics-informed tiny causal TCN이 큰 teacher 모델에 비해 매우 작은 모델 크기와 실시간 배포 가능성을 확보하면서도 상당한 정확도를 유지했다는 점이다.

기여 유형	강하게 주장 가능한 내용	왜 강한가
문제 정식화	software-only residual correction으로 misalignment 보정	프로젝트 전체가 일관되게 이 formulation 위에서 성공/실패를 설명함
representation insight	orientation-preserving fusion > aggressive normalization	A2-A3에서 반복적으로 관찰됨
accuracy-efficiency tradeoff	tiny가 약 90% 모델 축소로도 경쟁력 유지	A6 full LOSO + reproducibility로 검증됨
deployability	전처리와 추론이 online-friendly하게 유지됨	최종 후보가 모두 O(1) 혹은 짧은 rolling 계산 위주

Table 19: 논문화 시 강하게 주장 가능한 contribution

반대로 약하게만 주장해야 하는 contribution도 있다. physics feature가 의미 있는 single-LOSO 신호를 주는 것은 맞지만, 아직 strongest full LOSO baseline을 넘었다고 말할 수는 없다. body-frame superiority나 load-gated final winner 같은 주장도 현재 결과로는 지지되지 않는다.

12 한 페이지 최종 메시지

항목	최종 정리
가장 강한 전체 결론	orientation-preserving + lightweight biomechanical feature가 가장 안정적으로 살아남았다
정확도 기준 strongest validated baseline	Archive 6 Tiny / Teacher full LOSO
physics feature 쪽 핵심 결론	single LOSO strong signal은 있었고, full LOSO에서도 internal baseline 소폭 개선은 확인됐지만 project-wide 최고는 아직 아님
실패한 방향	body-frame 대체, aggressive heading normalization, feature 대량 concat, loadgate final winner
살아남은 입력 구성	robot hip/thigh/torque + quat/euler + derivative + mech_power
배포 관점 결론	Tiny causal TCN이 현재 가장 현실적인 최종 모델
논문 메시지 추천	misalignment compensation의 robust representation과 deployable model design을 밝힌 study

Table 20: 보고서 전체를 한 페이지로 압축한 최종 메시지

따라서 추천 논문 스토리는 다음과 같다. 메인 모델은 teacher가 아니라 tiny로 두고, teacher는 strongest accuracy reference로 둔다. 초반 archive의 negative result(body-frame / normalization 실패), 중반 archive의 feature screening, 후반 archive의 deployability와 full LOSO 검증을 모두 하나의 연속된 탐색 이야기로 묶는다. 즉 이 논문은 '새로운 복잡한 feature를 넣어서 SOTA를 찍은 논문'보다, '어떤 표현과 어떤 경량 구조가 실제 wearable robot misalignment compensation에 살아남는지 밝힌 논문'으로 쓰는 것이 맞다.

13 Archive Season4 설계에 바로 쓸 정리

archive₩{}_season4를 시작할 때는 단순히 '성능이 가장 좋았던 실험' 하나만 가져가는 것이 아니라, 역사적으로 검증된 축과 exploratory하게 signal만 보인 축을 분리해야 한다. 이 보고서 기준으로 season4 설계의 출발점은 A6 Tiny/Teacher를 anchor baseline으로 두고, A8의 physics family와 season3의 factorized 구조를 좁게 결합하는 것이다.

후보	노리는 기여 축	현재까지의 근거	season4에서의 사용 원칙
A6 Tiny kinpower	accuracy-efficiency / deployability	full LOSO 2.6344, 0.0867 MB, 2.25 ms	season4 기본 anchor 후보
A6 Teacher kinpower	accuracy anchor	full LOSO 2.6369, strongest robust reference	새 실험은 모두 이 모델 대비 설명
A8 norm worksplit / trunk consistency	domain-knowledge / interpretability	physics feature가 internal baseline을 소폭 개선	단일 family만 좁게 채택, large concat 금지
S3 factorized tiny full	structure / target reformulation	human-thigh target에서 가장 나았지만 절대 성능은 낮음	season4에서 raw branch 유지형 factorization만 검토

Table 21: season4 설계용 핵심 후보 정리

따라서 season4의 우선순위는 다음처럼 정리된다. 첫째, A6 tiny/teacher 입력 구성을 anchor로 고정한다. 둘째, physics feature는 normalized worksplit 또는 trunk consistency처럼 full LOSO에서 internal baseline 개선을 보인 단일 family만 사용한다. 셋째, season3의 factorized 구조는 raw branch를 유지한 full model에만 한정해 검토하고, physics-only나 grouped-linear baseline은 재시도하지 않는다. 넷째, season4의 메인 목표는 absolute best score보다 'physics-aware structure가 anchor 대비 왜 더 낫거나 덜 나쁜지 설명 가능한 결과'를 만드는 것이다.

A Archive별 실험 인벤토리

아래 표들은 각 archive에서 실제로 학습한 실험들을 결과와 함께 빠짐없이 정리한 것이다. screening과 final full LOSO를 분리해 실었다.

A.1 역사적 전체 single-LOSO 성능 순위

Table 22: season1-season2 shared hip-angle target historical ranking

실험	MAE	RMSE	R2	lag(ms)	MAE change(%)
res noise 001	1.8848	2.3999	0.9823	6.00	-20.30
ctrl quat residual	1.9848	2.5449	0.9801	6.00	-16.07
res dropout 01	2.0432	2.6047	0.9792	6.00	-13.60
bodyframe biomech fusion	2.0595	2.6481	0.9765	-0.36	-12.92
quat dropout 015	2.0625	2.5960	0.9793	1.00	-12.79
res mech power	2.1062	2.6523	0.9784	6.00	-10.94
bodyframe mechpower kinematics	2.1259	2.7245	0.9772	2.50	-10.11
res kin power	2.1363	2.7643	0.9765	1.00	-9.67
feat quat mech kin	2.1385	2.7080	0.9775	2.00	-9.57
quat k7	2.1434	2.7906	0.9761	5.50	-9.37
ctx bodyframe mech kin win300 k7	2.1495	2.7002	0.9776	0.50	-9.11
res k7	2.1578	2.7608	0.9766	4.00	-8.76
mech power	2.1589	2.7509	0.9768	2.50	-8.71
quat dropout 01	2.1706	2.7157	0.9774	6.00	-8.22
feat bodyframe mech kin	2.1789	2.7290	0.9771	1.50	-7.87

실험	MAE	RMSE	R2	lag(ms)	MAE change(%)
residual	2.1808	2.7235	0.9772	5.50	-7.79
res deflection	2.1900	2.6995	0.9776	5.00	-7.40
model bodyframe mech kin small	2.1962	2.7455	0.9769	0.50	-7.13
ctrl hybrid bodyframe quat	2.1963	2.7652	0.9765	5.00	-7.13
quat win300	2.2091	2.7867	0.9762	2.00	-6.59
model bodyframe gated	2.2159	2.7502	0.9768	3.00	-6.30
quaternion	2.2230	2.8388	0.9753	2.50	-6.00
bodyframe core dropout005	2.2366	2.8175	0.9756	3.00	-5.43
pre bodyframe mech kin lpf5	2.2433	2.8774	0.9746	-1.50	-5.14
ctrl bodyframe core	2.2608	2.8561	0.9750	3.50	-4.41
ctrl bodyframe no overground	2.2610	2.8626	0.9748	4.00	-4.39
quat kin motor	2.2659	2.8711	0.9747	0.50	-4.19
bodyframe core	2.2801	2.8753	0.9746	3.50	-3.59
quat motor	2.2829	2.9007	0.9742	3.50	-3.47
kinetics	2.3065	2.9463	0.9733	4.00	-2.47
gated tcn	2.3134	2.8364	0.9753	4.00	-2.18
bodyframe gaitphase asymmetry	2.3641	2.9187	0.9738	2.00	-0.04
full combo	2.3647	2.9785	0.9728	1.50	-0.01
baseline	2.3649	2.9537	0.9732	4.00	0.00
quat kin k7	2.3686	2.9558	0.9732	5.50	0.15
quat noise 001	2.3792	3.0050	0.9723	1.50	0.60
bodyframe core standing weight	2.3828	2.9921	0.9725	2.50	0.76
bodyframe deflection asymmetry	2.4046	3.0228	0.9719	4.00	1.68
model bodyframe gru	2.4065	2.9991	0.9724	-1.50	1.76
motor angle	2.4184	3.0407	0.9716	0.50	2.26
dropout 03	2.4392	3.1628	0.9693	6.00	3.14
quat noise 005	2.4527	3.0584	0.9713	3.50	3.71
dropout 01	2.4779	3.1629	0.9693	4.00	4.78
quat kinetics	2.4802	3.1324	0.9699	1.00	4.87
thigh lowdrop	2.5799	3.3338	0.9659	4.00	9.09
epochs 50	2.6090	3.3306	0.9659	4.50	10.32
win300 k7	2.6306	3.2868	0.9668	4.50	11.23
lr 0005	2.6322	3.3317	0.9659	4.50	11.30
thigh kinetics	2.7531	3.4935	0.9625	0.50	16.41
win300 k7	2.7563	3.4719	0.9630	4.50	16.55
channels wide	2.7707	3.4169	0.9641	4.00	17.16
exp no torque	2.8071	3.4414	0.9636	5.00	18.69
exp full features	2.8195	3.6506	0.9591	2.50	19.22
quaternion	2.8458	3.5767	0.9607	8.50	20.33
motor angle	2.9170	3.6993	0.9580	2.00	23.34
thigh gyro	2.9417	3.6890	0.9582	3.50	24.39
thigh velocity	2.9463	3.7030	0.9579	3.00	24.58
exp gated tcn	2.9494	3.6671	0.9587	3.00	24.71
quat replace euler	3.0006	3.6690	0.9587	5.00	26.88
thigh angle	3.0312	3.7854	0.9560	4.00	28.17
exp euler gyro fusion	3.0343	3.9102	0.9530	5.50	28.30
mech power	3.0401	3.7340	0.9572	4.00	28.55
exp low dropout	3.0530	3.9970	0.9509	5.50	29.09
hip thigh both	3.0719	3.8153	0.9553	2.00	29.89
gyro only	3.0841	3.8516	0.9544	8.00	30.41
exp full imu euler	3.1127	4.0267	0.9502	3.50	31.62
thigh gyro e50	3.1137	3.8878	0.9536	0.50	31.66
exp hip velocity	3.1204	4.0027	0.9508	4.00	31.95
exp euler accel fusion	3.1246	3.9993	0.9509	3.00	32.12
exp large kernel	3.1279	4.0936	0.9485	5.00	32.26
accel only	3.1366	3.9231	0.9527	2.00	32.63
full imu	3.1819	3.9726	0.9515	4.00	34.54
thigh only	3.2636	4.1508	0.9471	4.00	38.00
asymmetry	3.3703	4.1985	0.9459	3.50	42.51
overground accel	3.3796	4.2108	0.9456	4.50	42.90
exp multi head mlp	3.3841	4.4645	0.9388	1.00	43.10

실험	MAE	RMSE	R2	lag(ms)	MAE change(%)
torque dot	3.4280	4.2448	0.9447	3.50	44.95
exp yaw only	3.4329	4.3793	0.9411	7.50	45.16
exp wider tcn	3.4610	4.4355	0.9396	8.50	46.34
exp high wd	3.5062	4.5483	0.9365	5.00	48.26
exp win 300	3.5079	4.5476	0.9365	7.00	48.33
exp gait phase	3.5175	4.5933	0.9352	3.50	48.73
deflection	3.5300	4.1455	0.9472	8.50	49.27
exp roll pitch only	3.5591	4.5826	0.9355	11.00	50.49
exp multi horizon	3.5663	4.5727	0.9358	4.50	50.80
exp tcn bigru	3.5763	4.6174	0.9345	11.00	51.22
exp win 400	3.5780	4.6325	0.9341	7.50	51.29
exp seq output 25	3.6245	4.6686	0.9331	6.00	53.26
exp stride 01	3.6282	4.7278	0.9314	7.00	53.41
exp deeper tcn	3.6403	4.6957	0.9323	4.00	53.93
exp seq output 10	3.6854	4.7155	0.9317	9.00	55.83
exp low lr	3.7023	4.8219	0.9286	6.00	56.55
exp tcn gru	3.7120	4.7508	0.9307	7.50	56.96
exp win 100	3.8106	4.9007	0.9263	6.00	61.13
exp small kernel	3.9209	4.9826	0.9238	2.00	65.79
exp high dropout	3.9329	4.9834	0.9237	13.00	66.30
exp tcn gru deep	3.9356	5.1480	0.9186	12.00	66.42
explicit fusion	5.4711	6.5916	0.8666	7.00	131.34
deflection	5.9875	7.2369	0.8392	-1.00	153.18
exp attention v2	23.8142	29.4265	-1.6590	-2500.00	906.97

A.2 Season3 archive 1 inventory

Table 23: season3 archive_1 human-thigh target inventory

모델	MAE mean	MAE std	RMSE mean	Latency	MaxFreq	MB
factorized tiny full	5.3672	0.2447	7.0827	9.0914	112.6	0.0713
tiny thigh baseline	5.4073	0.2758	7.1483	2.3603	426.0	0.0867
factorized teacher full	5.4350	0.3880	7.0378	9.8855	106.9	0.2017
teacher thigh baseline	5.6049	0.1348	7.3501	2.4895	402.9	0.8548
grouped linear physics-only	6.4727	0.6219	8.4320	3.0405	356.2	0.0003
factorized teacher physics-only	7.3490	1.5413	9.1741	7.6123	131.7	0.1496

A.3 Archive 1 실험 목록

Table 24: Archive 1 experiment inventory

실험	MAE	RMSE	Params	MB	Latency	MaxFreq
bodyframe biomech fusion	1.9862	2.5760	224,266	0.8555	1.7513	571.0
bodyframe mechpower kinematics	2.2165	2.8039	224,072	0.8548	1.7337	576.8
bodyframe core	2.3512	2.9528	222,908	0.8503	2.2359	447.2
bodyframe biomech fusion	2.4641	3.1353	224,266	0.8555	2.3158	431.8
bodyframe gaitphase asymmetry	2.4683	3.0787	223,684	0.8533	1.7485	571.9
bodyframe core dropout005	2.5417	3.1916	222,908	0.8503	1.7961	556.8
bodyframe core standing weight	2.5455	3.2413	222,908	0.8503	1.8102	552.4
bodyframe deflection asymmetry	2.6070	3.2894	223,878	0.8540	1.7280	578.7

A.4 Archive 2 실험 목록

Table 25: Archive 2 experiment inventory

실험	MAE	RMSE	Params	MB	Latency	MaxFreq
feat quat mech kin	2.0297	2.5799	224,072	0.8548	2.1402	467.2
ctrl quat residual	2.0985	2.6566	222,908	0.8503	2.0843	479.8
ctx bodyframe mech kin win300 k7	2.1425	2.7099	305,160	1.1641	2.0645	484.4
model bodyframe mech kin small	2.2489	2.8270	127,168	0.4851	1.8227	548.6
model bodyframe gated	2.2641	2.8352	224,715	0.8572	2.1918	456.2
ctrl hybrid bodyframe quat	2.2977	2.8828	223,684	0.8533	2.2263	449.2
feat bodyframe mech kin	2.3092	2.8918	224,072	0.8548	2.1909	456.4
ctrl bodyframe core	2.4596	3.0811	222,908	0.8503	1.8256	547.8
model bodyframe gru	2.4657	3.0842	257,224	0.9812	1.9067	524.5
ctrl bodyframe no overground	2.4780	3.1075	222,714	0.8496	2.1491	465.3
pre bodyframe mech kin lpf5	2.5305	3.1650	224,072	0.8548	1.7307	577.8

A.5 Archive 3 실험 목록

Table 26: Archive 3 experiment inventory

실험	MAE	RMSE	Params	MB	Latency	MaxFreq
Euler + quaternion reference	2.0336	2.6182	222,908	0.8503	9.1150	109.7
raw trunk IMU 6ch + quat	2.1901	2.7612	223,490	0.8525	5.0208	199.2
gravity-aligned IMU 6ch + quat	2.2349	2.8298	223,490	0.8525	7.1084	140.7
gravity-aligned IMU 6ch	2.3182	2.9122	222,714	0.8496	7.2331	138.2
symmetry-yaw IMU 6ch + quat	2.3628	2.9609	223,490	0.8525	4.8492	206.2
raw trunk IMU 6ch	2.4708	3.1182	222,714	0.8496	3.8119	262.3
PCA body-frame IMU 6ch + quat	2.4869	3.1851	223,490	0.8525	5.3835	185.8
PCA body-frame IMU 6ch	2.5889	3.2153	222,714	0.8496	7.6141	131.3
symmetry-yaw IMU 6ch	2.8175	3.4536	222,714	0.8496	5.6194	177.9

A.6 Archive 4 실험 목록

Table 27: Archive 4 experiment inventory

실험	MAE	RMSE	Params	MB	Latency	MaxFreq
quat + kinematic derivatives	2.0425	2.5945	223,684	0.8533	2.4764	403.8
quat residual noise001 baseline	2.0503	2.6210	222,908	0.8503	2.4219	412.9
quat + mech_power	2.0596	2.6319	223,296	0.8518	1.8473	541.3
quat residual kin+power baseline	2.0624	2.6388	224,072	0.8548	2.8488	351.0
feat quat mech kin asym	2.0630	2.6121	224,654	0.8570	2.2536	443.7
feat quat all biomech	2.1029	2.6183	225,430	0.8599	2.4412	409.6
feat quat asymmetry	2.1147	2.6785	223,490	0.8525	2.4690	405.0
feat quat gait asymmetry	2.1693	2.7381	223,878	0.8540	2.4876	402.0
feat quat deflection	2.3691	2.9523	223,296	0.8518	2.3322	428.8

A.7 Archive 5 실험 목록

Table 28: Archive 5 experiment inventory

실험	MAE	RMSE	Params	MB	Latency	MaxFreq
quat residual kin+power baseline	2.0229	2.5763	224,072	0.8548	2.3553	424.6
quat + load_coupling	2.0637	2.6617	224,072	0.8548	2.5331	394.8
kinpower + load_coupling	2.0805	2.6589	225,236	0.8592	2.2423	446.0
quat residual noise001 baseline	2.1470	2.7273	222,908	0.8503	2.2911	436.5
feat kinpower all misalign	2.1578	2.6966	228,340	0.8710	2.2166	451.1

실험	MAE	RMSE	Params	MB	Latency	MaxFreq
feat quat all misalign	2.1735	2.7404	227,176	0.8666	2.0663	483.9
feat quat compliance	2.2410	2.7943	224,460	0.8562	2.1809	458.5
feat kinpower compliance	2.3369	2.8986	225,624	0.8607	2.5322	394.9
feat quat relkin	2.3449	3.0041	224,460	0.8562	1.7253	579.6
feat kinpower relkin	2.4153	2.9981	225,624	0.8607	2.5133	397.9
feat quat relkin compliance	2.4703	3.1052	226,012	0.8622	2.5004	399.9

A.8 Archive 6 screening 실험 목록

Table 29: Archive 6 screening inventory

실험	MAE	RMSE	Params	MB	Latency	MaxFreq
teacher kinpower baseline	1.9980	2.5475	224,072	0.8548	2.5249	396.1
tiny load-gated kinpower smooth	2.1345	2.7013	23,597	0.0900	2.7353	365.6
tiny kinpower w100	2.1863	2.7833	22,720	0.0867	2.2635	441.8
ultratiny loadgate kinpower w75	2.2590	2.8643	7,641	0.0291	2.1970	455.2
tiny loadgate quat w100	2.3690	3.0067	23,075	0.0880	1.9892	502.7
tiny loadgate kinpower w100	2.4663	3.1174	23,597	0.0900	3.2965	303.4

A.9 Archive 7 screening 실험 목록

Table 30: Archive 7 screening inventory

실험	MAE	RMSE	Params	MB	Latency	MaxFreq
teacher + interface worksplit	1.9660	2.4881	225,236	0.8592	2.3039	434.0
teacher + effective impedance	1.9699	2.5205	225,624	0.8607	1.9065	524.5
teacher + trunk consistency	2.0219	2.5776	225,042	0.8585	2.1424	466.8
teacher + hysteresis	2.0586	2.6198	224,460	0.8562	1.7512	571.0
teacher kinpower baseline	2.0938	2.6439	224,072	0.8548	2.0013	499.7
teacher + phase-locked features	2.0969	2.6771	226,012	0.8622	2.3364	428.0
teacher + interface lag	2.0972	2.6588	226,012	0.8622	2.5540	391.6
tiny kinpower baseline	2.1006	2.6576	22,720	0.0867	1.9815	504.7
teacher + all selected physics	2.1417	2.6995	229,310	0.8747	2.4961	400.6
tiny + phase + trunk consistency	2.1891	2.7792	23,710	0.0904	2.0514	487.5
tiny + selected physics	2.4670	3.1141	24,502	0.0935	1.6641	600.9

A.10 Archive 8 screening 실험 목록

Table 31: Archive 8 screening inventory

실험	MAE	RMSE	Params	MB	Latency	MaxFreq
teacher + short-window worksplit	2.0043	2.5795	225,624	0.8607	2.1828	458.1
teacher + trunk consistency	2.0136	2.5546	225,042	0.8585	1.7621	567.5
teacher + normalized load coupling	2.0310	2.5977	225,236	0.8592	2.0649	484.3
teacher + normalized load + worksplit	2.0311	2.5702	225,624	0.8607	1.8949	527.7
teacher + normalized worksplit	2.0352	2.6308	225,236	0.8592	2.4066	415.5
teacher + interface lag	2.0732	2.6130	225,236	0.8592	2.0151	496.2
teacher kinpower baseline	2.2000	2.7527	224,072	0.8548	2.3274	429.7

A.11 Archive 6 full LOSO inventory

Table 32: Archive 6 full LOSO inventory

모델	MAE mean	MAE std	RMSE mean	Params	MB	Latency	MaxFreq
tiny kinpower w100	2.6344	0.4658	3.6293	22,720	0.0867	2.2525	446.1
teacher kinpower baseline	2.6369	0.5847	3.6068	224,072	0.8548	2.2957	442.4
tiny load-gated kinpower smooth	2.6985	0.5284	3.7292	23,597	0.0900	3.0045	349.3

A.12 Archive 7 full LOSO inventory

Table 33: Archive 7 full LOSO inventory

모델	MAE mean	MAE std	RMSE mean	Params	MB	Latency	MaxFreq
feat load coupling teacher	2.7001	0.6098	3.6952	224,072	0.8548	2.1905	458.4
teacher + interface worksplit	2.7582	0.6188	3.7461	225,236	0.8592	2.2368	451.0
teacher + effective impedance	2.8439	0.6490	3.8347	225,624	0.8607	2.2106	456.0

A.13 Archive 8 full LOSO inventory

Table 34: Archive 8 full LOSO inventory

모델	MAE mean	MAE std	RMSE mean	Params	MB	Latency	MaxFreq
teacher + normalized worksplit	2.7028	0.6794	3.6618	225,236	0.8592	2.2697	443.7
teacher + trunk consistency	2.7109	0.4954	3.7068	225,042	0.8585	2.1483	470.3
teacher + normalized load + worksplit	2.7196	0.5005	3.7217	225,624	0.8607	2.1868	460.5
teacher + short-window worksplit	2.7354	0.6026	3.7203	225,624	0.8607	2.2791	444.1
teacher + interface lag	2.7379	0.5972	3.7390	225,236	0.8592	1.8998	527.5
teacher kinpower baseline	2.7643	0.4888	3.7464	224,072	0.8548	2.3368	431.2
teacher + normalized load coupling	2.7825	0.5578	3.7657	225,236	0.8592	2.4192	414.9