Speed Estimation 논문 방향 제안서

LPF 된 progression speed 를 causal 입력으로 추정하기 위한 모델, feature, 실험 전략

작성 목적: 기존 결과를 바탕으로 논문 contribution 이 살아나는 다음 실험 방향을 정리한 내부 메모

기준 정보: 사용자 설명 + 260325_SpeedEstimation_정리 내부 보고서

핵심 요약

- 최종 목표는 treadmill belt speed 추정이 아니라 common/v_Y_true 에 filtfilt Butterworth LPF(order=4, cutoff=0.5 Hz)를 적용한 저주파 progression speed state 를 causal 입력으로 추정하는 것이다.
- 학습용 label 은 noncausal 전처리를 사용해도 괜찮지만, deployable input feature 와 preprocessing 은 반드시 real-time 으로 계산 가능해야 한다.
- 현재 strongest signal 인 treadmill-aware imu_integrated_speed 는 최종 deployable input 이 아니라 upper bound 또는 privileged teacher 로 재해석하는 편이 더 강한 논문 서사를 만든다.
- 다음 성능 개선의 핵심은 더 큰 네트워크가 아니라 treadmill-independent inertial prior, support-frame/stride progression prior, phase-conditioned interaction power/work 같은 task-aligned biomechanical feature 다.
- 논문 구조는 absolute best accuracy, deployable model, privileged teacher-student transfer 를 분리해 제시하는 방식이 가장 설득력 있다.

작성일: 2026-04-04

1. 문제 재정의: 무엇을 추정해야 하는가

이 프로젝트의 핵심 target 은 treadmill belt speed 자체가 아니다. 실제 target 은 common/v_Y_true 에 대해 filtfilt Butterworth LPF(order=4, cutoff=0.5 Hz)를 적용한 값이며, 해석상 instantaneous speed 보다 저주파 locomotor state 에 가깝다.

```
v_target(t) = LPF_bi( v_Y_true(t) )
LPF_bi = filtfilt Butterworth low-pass, order = 4, cutoff = 0.5 Hz
```

따라서 논문의 중심 질문도 바뀌어야 한다. 지금 필요한 것은 "belt speed 를 맞추는 모델"이 아니라 "실시간으로 측정 가능한 입력만으로 smoothed progression speed state 를 얼마나 잘 복원할 수 있는가"다. 이 framing 은 treadmill 위 보행뿐 아니라 이후의 non-treadmill deployment 목표와도 자연스럽게 이어진다.

여기서 중요한 정렬 원칙은 다음 두 가지다. 첫째, label 생성 과정에서 bidirectional LPF 를 쓰는 것은 허용된다. 이는 ground-truth state 를 정의하기 위한 오프라인 전처리이기 때문이다. 둘째, 입력으로 들어가는 모든 feature 와 전처리는 반드시 causal 해야 한다. 즉 body-frame 변환, leaky integration, causal LPF, gait event 기반 update, stride summary 생성은 가능하지만, filtfilt 나 미래 프레임을 보는 미분/평활은 deployable path 에 직접 들어가면 안 된다.

2. 지금까지의 결과에서 살려야 할 메시지

기존 보고서에서 가장 가치 있는 결과는 단순히 어떤 모델이 최고 MAE 를 기록했는가가 아니다. 더 중요한 메시지는 다음과 같다. 성능 개선은 대체로 더 큰 architecture 에서 나온 것이 아니라 입력 표현을 바꾸는 과정에서 나왔고, 특히 body-frame IMU 와 imu_integrated_speed 계열 prior 가 가장 강한 축이었다. 반면 attention, multiscale, observer, distillation 은 현재 framing 에서는 baseline superior 를 만들지 못했고, fusion 만 일관된 positive signal 을 보였다.

이 결과를 논문적으로 해석하면

- 문제의 병목은 model capacity 가 아니라 feature-target alignment 일 가능성이 높다.
- 저주파 target 에는 저주파 locomotor state 를 직접 반영하는 prior 가 유리하다.
- 따라서 다음 단계의 contribution 도 architecture novelty 자체보다 biomechanics-guided feature 와 structured fusion 에서 나올 가능성이 높다.

다만 그대로 가져가면 약한 부분도 있다. 현재 strongest prior 인 treadmill-aware imu_integrated_speed 는 최종 deployment 에서 treadmill speed 를 모른다는 조건과 충돌한다. 또 mocap 이나 lab-only signal 에 크게 기대는 구성은 sensor-light 일 수는 있어도 wearable-only deployable estimator 라고 부르기 어렵다. 따라서 다음 논문에서는 "무엇을 최종 입력으로 허용할 것인지"와 "어떤 신호를 teacher privilege 로만 쓸 것인지"를 명확히 구분해야 한다.

3. 가장 강한 논문 서사

추천하는 메인 메시지는 다음 한 문장으로 정리된다. "우리는 LPF 된 progression speed 라는 저주파 locomotor state 를 causal biomechanical prior 와 human-robot interaction prior 를 이용해 추정하며, raw sensor end-to-end regression 보다 더 해석 가능하고 더 일반화되는 estimator 를 제안한다."

Contribution 축	핵심 내용	논문 메시지
Task re-framing	belt speed 가 아니라 LPF 된 progression speed state 를 추정 대상으로 정의	문제 정의 자체가 deployment 목표와 맞물린다
Biomechanical priors	inertial propagation, support-frame progression, gait phase 요약, interaction power/work 생성	좋아진 이유를 물리적으로 설명할 수 있다
Structured fusion	propagation branch, stride update branch, interaction correction branch 를 분리	단순 black-box 보다 해석 가능성이 높다
Privileged transfer	treadmill-aware, mocap-rich, noncausal teacher 로 deployable student 를 가르침	lab-only 정보를 논문 contribution 으로 전환할 수 있다

4. 추천 모델 구조: biomechanics-guided dual-timescale estimator

가장 추천하는 형태는 monolithic end-to-end regressor 보다 구조가 보이는 hybrid estimator 다. 연속적 inertial propagation 과 stride/event 기반 biomechanical update 를 분리하고, 여기에 human-robot interaction correction 을 더하는 방식이 좋다.

```
v_hat_t = v_prop_t + K_t * ( v_stride_t - v_prop_t ) + Delta v_int_t
v_prop_t : inertial propagation state
v_stride_t : stride/support 기반 biomechanical update
Delta v_int_t : human-robot interaction correction
K_t : phase 또는 confidence 에 따라 달라지는 learned gain
```

이 구조의 장점은 세 가지다. 첫째, target 이 0.5 Hz LPF state 이므로 stride 마다 천천히 갱신되는 hidden state 와 잘 맞는다. 둘째, 현재까지 유일한 positive signal 이었던 fusion 을 더 해석 가능한 형태로 재구성할 수 있다. 셋째, 이전 observer 계열의 불안정을 피하면서도 state-space 적 해석을 유지할 수 있다. 핵심은 모든 것을 네트워크에 맡기지 않고, propagation 과 correction 의 역할을 분리하는 것이다.

권장 branch 구성

- Branch 1: treadmill-independent inertial propagation
- Branch 2: support-frame / stride progression update
- Branch 3: interaction correction from exoskeleton mechanics
- Small gating network: phase, confidence, contact 상태를 바탕으로 update gain 산출

5. 꼭 만들어볼 feature 들

5.1 Treadmill-independent inertial prior

현재 treadmill-aware imu_integrated_speed 의 강점은 "이미 low-frequency state 로 가공된 prior"라는 점에 있다. 이 철학은 유지하되, final deployment 와 충돌하는 treadmill acceleration 의존성은 제거해야 한다. 즉 body-frame forward acceleration, gravity compensation, leaky integration, causal low-pass, 그리고 stance 또는 mid-stance 기반 bias reset 으로 구성된 treadmill-independent inertial prior 를 새로 만들고, 기존 treadmill-aware prior 는 upper bound 또는 teacher privilege 로 남기는 것이 좋다.

5.2 Support-frame / stride progression prior

현재 model_com_speed 가 약했다고 해서 COM mechanics 자체를 버릴 필요는 없다. instantaneous derivative 기반 구현이 target bandwidth 와 맞지 않았을 가능성이 크다. 다음 구현은 stance foot 기준 COM 또는 pelvis 위치, double support 에서의 blended support anchor, stride displacement proxy, cadence, stance ratio 를 이용해 stride 단위 progression prior 를 만드는 방향이 더 유망하다. 직관적으로는 "지난 1~2 stride 동안 얼마나 전진하는 gait pattern 이 나왔는가"를 저주파 변수로 만드는 것이다.

5.3 Phase-normalized kinematics

고정 길이의 raw window 는 cadence 변화가 크면 의미가 흔들린다. 따라서 phase bin 기반 요약이 좋다. 예를 들어 최근 1~2 stride 를 8 개 정도의 phase bin 으로 나누고, 각 bin 에서 hip/knee/ankle angle mean, range, angular rate, trunk pitch, stance ratio, left-right asymmetry 를 요약하면 subject 와 condition 변화에 더 robust 한 feature family 를 만들 수 있다.

5.4 Human-robot interaction power/work

raw torque 2 채널은 논문 contribution 으로는 약하다. 대신 joint velocity 와 결합한 mechanical power, stride 별 positive/negative work, early stance/late stance/swing 별 phase-conditioned work, interaction impulse 를 생성하는 것이 좋다. 같은 torque 라도 언제 들어가고 joint velocity 가 어떤 방향인지에 따라 progression 에 미치는 영향이 달라지므로, raw torque 보다 power/work 가 훨씬 물리적인 feature 다.

5.5 Dimensionless normalization

cross-subject generalization 을 위해서는 속도, 가속도, power 를 키, 다리 길이, 체중, 중력으로 무차원화하는 것도 강하게 추천한다. 예를 들어 v / sqrt(gL), a / g, P / (m g sqrt(gL)) 형태의 normalized feature 는 단순 height/weight metadata 보다 biomechanical 해석력이 높고, leave-subject-out generalization 에도 유리할 가능성이 있다.

6. Distillation 을 다시 쓰는 방법: privileged biomechanics teacher

기존 distillation 이 큰 이득이 없었더라도 아이디어 자체를 버릴 필요는 없다. 다만 teacher-student 정의를 더 분명히 해야 한다. teacher 는 treadmill-aware prior, mocap-rich signal, 더 정교한 state proxy, 비실시간성 허용 범위 안의 분석용 feature 를 사용할 수 있다. student 는 최종 deployable sensor set 만 사용한다. 이때 teacher 의 scalar output 만 흉내 내게 하지 말고, gait phase, cadence, stride progression prior, confidence 또는 update gain 같은 중간 biomechanical state 도 함께 distill 하는 편이 훨씬 논문답다.

이 접근이 주는 장점

- 현재의 lab-only 강점을 폐기하지 않고 논문 contribution 으로 전환할 수 있다.
- 최종 모델은 causal/deployable 조건을 지키면서도, 학습 시점에는 richer biomechanics 를 활용할 수 있다.
- wearable student 와 privileged teacher 를 분리해 제시하면 결과 해석도 훨씬 선명해진다.

7. 논문용 실험 설계

실험은 단순히 모델 목록을 늘리는 방식보다, contribution 축을 한 단계씩 검증하는 matrix 로 구성하는 것이 좋다. 아래 순서를 추천한다.

단계	실험	핵심 목적	성공 시 메시지
1	Direct deployable baseline	treadmill-independent causal input 만으로 baseline 을 재구축	최종 조건에 맞는 기준선 확보
2	Inertial prior only	새 inertial prior 의 순수 기여도 확인	task-aligned low-frequency prior 가 유효함
3	+ stride/support prior	support-frame progression 정보의 추가 가치 확인	COM/stride mechanics 가 실제로 도움됨
4	+ interaction power/work	human-robot 관계 feature 의 기여도 측정	raw torque 보다 물리량이 낫다는 주장 가능

단계	실험	핵심 목적	성공 시 메시지
5	Structured fusion	propagation, update, correction 분리 구조 검증	구조적 fusion 이 black-box 보다 유리
6	Teacher -> student	privileged biomechanics transfer 효과 검증	lab-rich teacher 가 deployable student 를 향상시킴
7	Full-LOSO	subject 일반화 성능 점검	논문 메인 generalization evidence
8	Leave-condition-out	condition/domain 변화에 대한 강건성 평가	treadmill condition 특이성 완화

8. 평가 지표도 바꿔야 한다

LPF 된 progression speed state 를 다룰 때는 전체 MAE/RMSE 만으로는 부족하다. 동적 조건에서 response quality 를 따로 봐야 한다. accel_sine 에서는 amplitude ratio, phase lag, low-frequency coherence 를 확인하고, stop-and-go 에서는 rise time, settling time, overshoot 를 함께 보는 것이 좋다. 또한 95th percentile error, spike count, signed lag 를 포함하면 rare failure event 를 더 잘 드러낼 수 있다.

추가로 매우 추천하는 분석은 feature-target spectral alignment 다. raw IMU, body-frame IMU, 기존 imu_integrated_speed, 새 inertial prior, support-frame stride prior 각각에 대해 0-0.5 Hz 대역 coherence 와 nuisance high-frequency energy 를 비교하면, 왜 어떤 feature 가 먹히고 어떤 feature 가 약한지를 훨씬 설득력 있게 설명할 수 있다. 이 분석은 "성능이 좋아졌다"를 넘어 "왜 좋아졌는가"를 보여주는 좋은 figure 가 된다.

마지막으로 filter sensitivity 도 꼭 확인하는 편이 좋다. 현재 target 정의는 cutoff 0.5 Hz 에 의존하므로, cutoff 를 조금 바꾸었을 때 ranking 과 핵심 conclusion 이 유지되는지 보여주면 reviewer 의 filter-specificity 우려를 줄일 수 있다.

9. 우선순위 로드맵

1. 최종 deployable sensor set 을 먼저 고정한다. 예: trunk IMU 만 허용하는지, exoskeleton joint encoder/torque 를 사용할 수 있는지, contact 추정이 가능한지부터 확정한다.
2. 기존 treadmill-aware imu_integrated_speed 를 teacher-only feature 로 재분류하고, treadmill-independent inertial prior 를 새로 구현한다.

3. support-frame/stride progression prior 를 만든다. 여기서는 instantaneous derivative 보다 stride summary 를 우선한다.
4. interaction torque 를 power/work/phase-conditioned feature 로 재표현한다.
5. 단일 대형 네트워크 대신 structured fusion 또는 hybrid observer 형태로 재실험한다.
6. teacher-student distillation 을 scalar output 뿐 아니라 중간 state 까지 포함하는 방식으로 다시 설계한다.
7. full-LOSO, leave-condition-out, dynamic metric, spectral alignment figure 를 포함한 논문용 evaluation 패키지를 완성한다.

10. 한 문장 결론

추천 결론 문장

- 다음 논문은 "더 큰 모델로 speed 를 잘 맞췄다"가 아니라, "LPF 된 progression speed 라는 저주파 locomotor state 에 맞춰 causal biomechanical prior 와 human-robot interaction prior 를 설계했더니, 더 해석 가능하고 더 일반화되는 estimator 를 얻었다"로 가는 것이 가장 강하다.

즉, 앞으로의 가장 중요한 실험은 새로운 architecture 탐색 자체가 아니라 feature-target alignment 를 중심으로 한 구조적 재설계다. 이 방향이면 현재까지의 strongest empirical finding 도 그대로 살리고, 논문 contribution 도 훨씬 선명하게 만들 수 있다.

부록. 제목 후보와 바로 확정할 사항

아래 항목은 실제 실험을 시작하기 전에 바로 정해두면 좋은 최소 의사결정이다.

제목 후보

- Causal estimation of smoothed progression speed from biomechanical priors
- Task-aligned biomechanical priors for real-time progression speed estimation
- Human-robot interaction aware estimation of low-frequency locomotor speed state

바로 확정할 사항

- 최종 deployable sensor set
- teacher 에서만 허용할 privileged signal
- full-LOSO 와 leave-condition-out 의 최종 평가 세팅