260325_SpeedEstimation_정리

SpeedEstimation 프로젝트 종합 내부 보고서 개정판

Repository: /home/chanyoungko/IIT/SpeedEstimation

Date: 2026-03-26

이 문서는 SpeedEstimation 프로젝트에서 진행한 season1 후기 실험과 season2 archive_1부터 archive_6까지의 모든 주요 설계, 입력 feature 생성 방식, 모델 구조, 학습 방법론, 실패한 가설, 성공한 가설, 정량 결과, 실시간 추론 가능성, 그리고 archive_6 추가 evaluation 결과를 한 번에 정리한 내부 보고서다.

핵심 결론은 다음과 같다. 절대 정확도 기준 최강 모델은 archive_2의 body-frame IMU + imu_integrated_speed 조합이다. 이후의 residual, delta, observer, distillation 실험은 이 baseline을 넘지 못했다. 반면 fusion 계열은 유일하게 일관된 positive signal을 보였고, archive_6에서는 sensor-light 및 초경량 real-time 모델이라는 논문형 contribution 후보를 확보했다.

1. 프로젝트 목표와 평가 설정

프로젝트의 목적은 다중 biomechanics 센서 환경에서 treadmill belt speed를 causal하게 추정하는 것이다. 최종 모델은 나중에 실제 실시간 inference에 배치할 수 있어야 하므로, 모델 자체뿐 아니라 전처리, derived feature 계산, sliding window 구성까지 모두 온라인 수행 가능해야 한다.

- 데이터 구조: HDF5 내부가 Subject / Condition / Level / Trial 계층으로 구성된다.
- 주요 피험자: milestone2 기준 m2_S001 ~ m2_S008.
- 주요 조건: level_075/100/125mps, accel_sine, decline_5deg, incline_10deg, stopandgo.
- 샘플링 주파수: 100Hz.
- 주요 평가 설정: season2는 대부분 single-LOSO로 m2_S008을 held-out subject로 사용했다.
- 주요 지표: MAE, RMSE, lag, parameter count, host latency.

single-LOSO는 절대적인 generalization 주장을 위한 최종 세팅은 아니지만, archive 간 상대 비교와 아이디어 screening에는 충분히 유효했다. 따라서 이 보고서의 해석은 현재 held-out subject 설정에서 어떤 아이디어가 살아남았는가를 중심으로 읽어야 한다.

2. 코드베이스와 전체 파이프라인

코드베이스는 크게 data, core, training, configs, compare_results.py, train.sh / eval_server.sh 로 나뉜다. 실제 실행 경로는 raw HDF5 trial을 읽고, loader에서 on-the-fly derived feature를 만든 뒤, dataset에서 sliding window로 자르고, normalization을 적용한 뒤, causal model이 speed를 출력하는 구조다.

- data/loader.py: H5 로딩, derived feature 계산, trial-level cache.
- data/body_frame.py: quaternion 기반 body frame 변환.
- data/model_com_speed.py: COM speed / imu integrated speed 계산.
- core/datasets.py: windowing, stride, target transform.
- core/models.py: TCN_GRU, AttentionTCN, MultiScaleTCN, FusionTCN_GRU 등.
- training/trainer.py: optimizer, scheduler, early stopping, metrics export.
- compare_results.py: eval, plot, ablation summary, archive별 compare_result 저장.

중요한 구현 요소는 trial-level cache다. LOSO 실험은 동일 trial을 여러 번 재사용하므로, first-pass에서 미리 derived feature를 계산해 캐시에 넣고 이후 fold에서는 해당 subject만 걸러 쓰는 구조로 시간을 줄였다.

3. 입력 feature와 생성 방식

이 프로젝트의 input feature는 단순 센서 나열이 아니라, raw biomechanical signal을 speed estimation에 맞게 task-aligned feature로 바꾸는 과정이 핵심이었다. 특히 season2에서 성능 개선을 만든 것은 더 큰 모델보다 입력 표현 변경이었다.

```
Input groups used in final study:
mocap/kin_q (18ch), derived/body_frame_imu (7ch), derived/imu_integrated_speed (1ch), derived/model_com_speed (1ch), exoskeleton torque (2ch), forceplate GRF+contact (8ch), sub_info height/weight (2ch).
Final sensor-light model C2 removes both torque and GRF, keeping mocap + body-frame IMU + imu_integrated_speed + sub_info.
```

그림 1. 최종적으로 고려한 입력 그룹 요약. sensor-light 모델은 여기서 GRF와 torque를 제거한 형태다.

3.1 Mocap kinematics

기본 kinematic feature는 mocap/kin_q의 left/right hip flexion, knee angle, ankle angle이며, 각 변수의 1차 미분과 2차 미분까지 포함해 총 18채널을 사용했다. 즉 원각도, 각속도, 각가속도 조합이다. 코드상 _dot, _ddot는 np.gradient() * fs로 생성되므로 완전히 causal하지는 않지만, 실제 배포 시에는 backward difference 기반 근사로 대체 가능하다.

3.2 Body-frame IMU

body-frame IMU는 raw trunk IMU 축을 그대로 쓰는 대신, quaternion을 이용해 몸 기준 축으로 정렬한 표현이다. accel과 gyro를 body-aligned frame으로 투영하고, 전방축 가속도를 별도로 만든다. speed estimation처럼 전방 이동이 핵심인 문제에서는 sensor-axis보다 body-axis가 물리적으로 더 해석 가능하다.

이 변환 자체만으로 무조건 좋아지는 것은 아니었지만, imu_integrated_speed와 결합될 때는 가장 좋은 표현으로 작동했다. 즉 body-frame 변환은 좋은 최종 답이라기보다 좋은 speed prior를 만들기 위한 전처리 축으로 더 중요했다.

3.3 IMU-integrated speed

imu_integrated_speed는 raw IMU 적분이 아니다. 먼저 body-frame 전방 가속도에 treadmill acceleration을 더해 overground-equivalent forward acceleration을 만든 뒤, leaky integration과 causal low-pass filtering을 거쳐 속도 prior를 만든다. season2 전체에서 가장 강한 physics-inspired prior였다.

3.4 Model-based COM speed

model_com_speed는 관절각 기반 forward kinematics와 stance/contact 정보를 이용해 발목 대비 COM의 상대 속도를 추정하는 방법론이다. 물리적으로는 매력적이지만, 현재 구현과 현재 feature set에서는 imu_integrated_speed보다 consistently weaker했다.

3.5 Torque, GRF, subject info

robot torque 2채널과 forceplate GRF 및 contact 8채널도 실험적으로 사용했다. season2 후반부에는 이들 채널 없이도 성능을 유지할 수 있는지 보는 sensor-light 실험이 중요해졌다. subject info는 height, weight만 사용했고, common/assist_level은 어떤 실험에서도 쓰지 않았으며 앞으로도 금지다.

4. 전처리와 online inference 부담

공통 전처리 설정은 window size 300, training stride 5, evaluation stride 1, output delay 5 frame, standard normalization이었다. season2 후반에는 deployability를 위해 window 200, 150, 120도 시험했다. 100Hz 기준 300-step window는 약 3초 history이고, output delay 5는 약 50ms future target이다.

계산량 관점에서 보면 derived feature 생성은 모두 O(T) causal 연산이다. body-frame 변환은 quaternion 기반 투영, imu_integrated_speed는 scalar 누적 적분, GRF contact는 thresholding, model_com_speed도 feed-forward kinematics와 상태 판정으로 구성된다. 따라서 전처리 자체가 transformer급 연산을 추가하지 않는다.

- A5 baseline: 409,793 params, host latency 약 4.09 ms.
- A6 A4 fusion softprior: 410,117 params, host latency 약 2.82 ms.
- A6 C2 sensor-light: 142,364 params, host latency 약 2.63 ms.
- A6 B3 tiny: 74,293 params, host latency 약 2.68 ms.

100Hz online inference에서 한 스텝 예산은 대략 10ms다. 위 host latency는 대략 2.6~4.1ms 수준이므로, 모델 추론 자체는 예산 안에 들어온다. 가중치 메모리도 410k params는 fp32 기준 약 1.6MB, 142k params는 약 0.54MB, 74k

params는 약 0.28MB 수준이다. 즉 연산과 메모리 모두 실시간 배포 가능한 범위로 해석할 수 있다.

다만 eval 파이프라인은 plot 생성과 large-window sweep 때문에 CPU/IO 병목이 컸다. 이는 연구용 compare_results.py의 문제이지, 실시간 deployment path의 문제와는 구분해야 한다.

5. 모델 구조와 학습 방법론

baseline 구조는 TCN encoder 뒤에 GRU head를 붙인 causal regressor다. 이 구조는 archive_2 이후 끝까지 가장 강한 기준선으로 남았다. 이후 attention-enhanced TCN, multiscale TCN, causal smooth branch, observer model, fusion model, distillation, delta target, soft prior 등을 차례로 시도했다.

- Attention/Multiscale/Causal smooth: 구조를 더 복잡하게 했지만 baseline을 넘지 못했다.
- Hard residual skip: 크게 실패했다. base estimate를 직접 더하는 구조가 y_delay와 맞지 않으면서 동적 구간에서 무너졌다.
- Delta target: hard residual보다 안전했지만 baseline superior까지는 못 갔다.
- Soft prior loss: 약한 규제로는 positive signal이 있었다.
- FusionTCN_GRU: learned estimate와 causal prior를 명시적으로 가중 융합하는 구조로, season2 후기의 유일한 강한 positive signal이었다.
- Observer/KalmanNet-inspired 구조: 논문적으로 매력적이었지만 empirical result는 불안정했다.
- Distillation: student만 남는 real-time 조건은 지켰지만, 현재 setup에서는 이득이 없었다.

공통 학습 설정은 AdamW, Huber loss, 30 epoch, batch size 128, AMP, cosine scheduling, early stopping이다. season2 후반에는 prior_loss_weight, target_transform, residual_skip, teacher_path 같은 실험용 옵션도 trainer에 반영했다.

6. archive별 연대기와 해석

archive는 단순 버전 번호가 아니라, 각 단계에서 어떤 가설을 검증했는지의 기록이다. 아래 해석은 무엇이 성공했고 무엇이 실패했는가를 중심으로 정리했다.

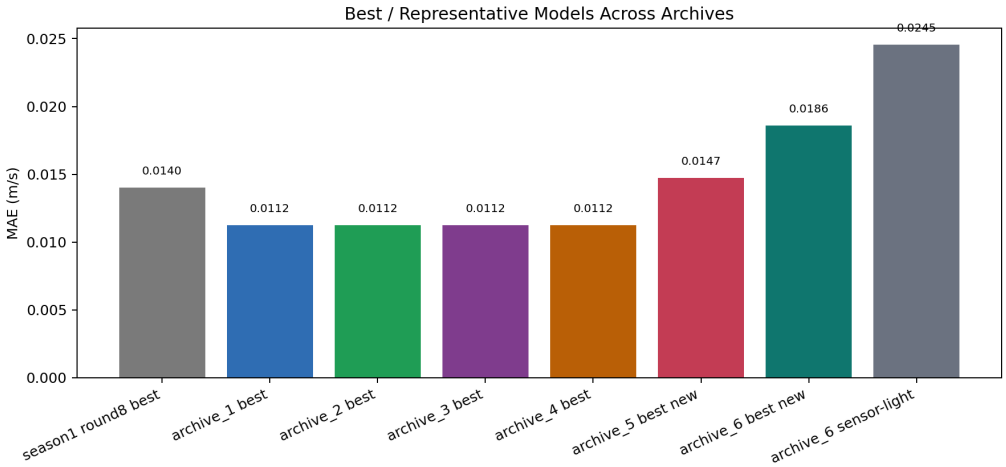

그림 2. 프로젝트 타임라인에 따른 representative MAE 변화. absolute best는 archive_2 baseline이며, archive_5와 archive_6은 deployability 쪽 signal을 만든 단계다.

6.1 Season1 후기

late season1은 raw IMU 표현을 유지한 채 LPF, augmentation, TTA를 붙이는 접근이었다. 최고 성능은 대략 MAE 0.0140 수준이었다.

6.2 archive_1

archive_1은 body-frame IMU와 physics-inspired speed prior를 처음 도입했다. 여기서 body-frame 자체보다 더 중요했던 것은 imu_integrated_speed였다.

6.3 archive_2

archive_2는 핵심 ablation archive다. raw IMU, body-frame IMU, legacy raw vel_forward, imu_integrated_speed, model_com_speed를 거의 factorial하게 분리해 비교했고, body-frame IMU + imu_integrated_speed가 승자였다.

6.4 archive_3

archive_3는 residual 아이디어를 강하게 민 archive였다. 대부분의 residual variant가 크게 붕괴했고, baseline 재현만 살아남았다.

6.5 archive_4

archive_4는 delta target과 soft prior regularization을 도입했다. archive_3보다는 훨씬 나아졌지만 archive_2 baseline superior는 아니었다.

6.6 archive_5

archive_5는 observer, confidence-weighted fusion, distillation을 같이 시험했다. observer는 실패했고 distillation도 이득이 없었다. fusion만 분명한 positive signal을 보였다.

6.7 archive_6

archive_6은 accuracy track과 deployability track을 함께 본 archive다. baseline을 넘지는 못했지만, sensor-light 모델과 tiny Pareto point를 만들었다.

- archive_2 best: MAE 0.011247, RMSE 0.030389, params 409793
- archive_5 best new fusion B1: MAE 0.014742, params 409892, latency 2.5825 ms
- archive_5 lightweight fusion B4: MAE 0.021535, params 143973

7. 최종 정량 결과

모델	MAE	RMSE	Params	Latency(ms)	의미
archive_2 A5 best	0.011247	0.030389	409793	2.4362	절대 최고 정확도
archive_5 B1 fusion	0.014742	0.039590	409892	2.5825	최고 성능 신형 fusion
archive_6 A4 fusion+softprior	0.018599	0.040187	410117	2.8162	최종 accuracy-oriented fusion
archive_6 C2 sensor-light	0.024539	0.053608	142364	2.6270	GRF/torque 제거
archive_6 B3 tiny	0.040261	0.075030	74293	2.6813	초경량 Pareto

정량 결과를 종합하면, 절대 성능 최강은 여전히 archive_2 A5다. 그러나 archive_6 C2는 GRF와 torque를 모두 제거하고도 MAE 약 0.0245를 유지했으며, B3는 파라미터를 약 82% 줄인 초경량 모델로 남았다. 따라서 논문 관점에서는 최고 정확도 모델과 실시간 배포 최적 모델을 분리해 제시하는 전략이 더 설득력 있다.

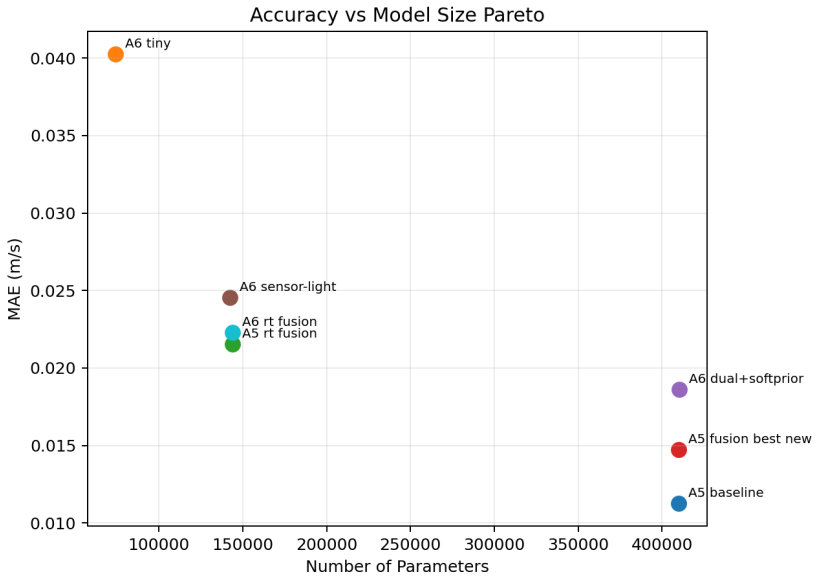

그림 3. 대표 모델들의 MAE-parameter Pareto. 정확도는 baseline이 최고지만, C2와 B3는 deployability 측면에서 뚜렷한 위치를 가진다.

그림 4. 대표 실험들의 학습 곡선. baseline 재현성과 후반 fusion 계열의 수렴 특성을 비교할 수 있다.

8. Feature importance 해석

season2 전 archive를 동일 조건에서 다시 모두 feature importance로 재평가하지는 않았다. fast evaluation과 plot generation의 계산 부담 때문에, season2 해석은 주로 ablation 기반 importance로 정리하는 것이 더 정확하다.

- 가장 중요한 feature 축: body-frame IMU + imu_integrated_speed
- 보조적 또는 조건부 가치: model_com_speed
- sensor-light 가능성: GRF와 torque는 제거해도 완전히 붕괴하지 않음
- 사용 금지 / 비사용: common/assist_level

즉 이 프로젝트에서 importance는 permutation score보다는 아카이브별 제거 실험과 input-group 비교로 해석하는 편이 맞다. 그런 의미에서 imu_integrated_speed가 가장 강한 prior이고, body-frame IMU가 그 prior를 뒷받침하는 핵심 표현이라는 것이 season2 전체의 가장 안정적인 결론이다.

9. archive_6 추가 evaluation 결과

보고서 개정판을 위해 archive_6에서 정성 plot을 다시 생성했다. 처음에는 A4와 C2를 stride=1 full eval로 재실행했지만, compare_results.py가 whole-trial window를 한꺼번에 다루는 과정에서 메모리 부족으로 실패했다. 이후 stride=3로 낮춰 재평가했고, A4와 C2 모두 trajectory plot을 성공적으로 얻었다.

중요한 주의점이 하나 있다. compare_result/archive_season2/archive_6/final_ablation_summary.csv는 archive-wide multi-config summary가 아니라, 마지막 single-config eval 결과만 반영한 파일이다. 따라서 archive_6 전체의 정량 비교는 계속 experiments/*/metrics.json을 기준으로 읽어야 한다. 반면 아래 plot들은 정성 비교용으로는 충분히 유효하다.

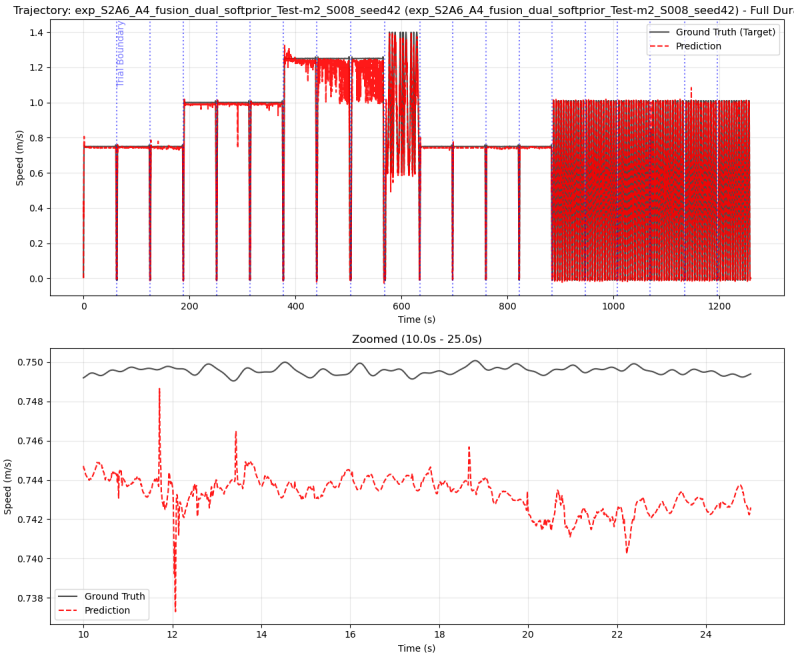

그림 5. archive_6 A4 fusion_dual_softprior의 trajectory plot. baseline 대비 절대 성능은 낮지만, soft prior와 dual fusion의 효과로 동적 구간을 비교적 안정적으로 따른다.

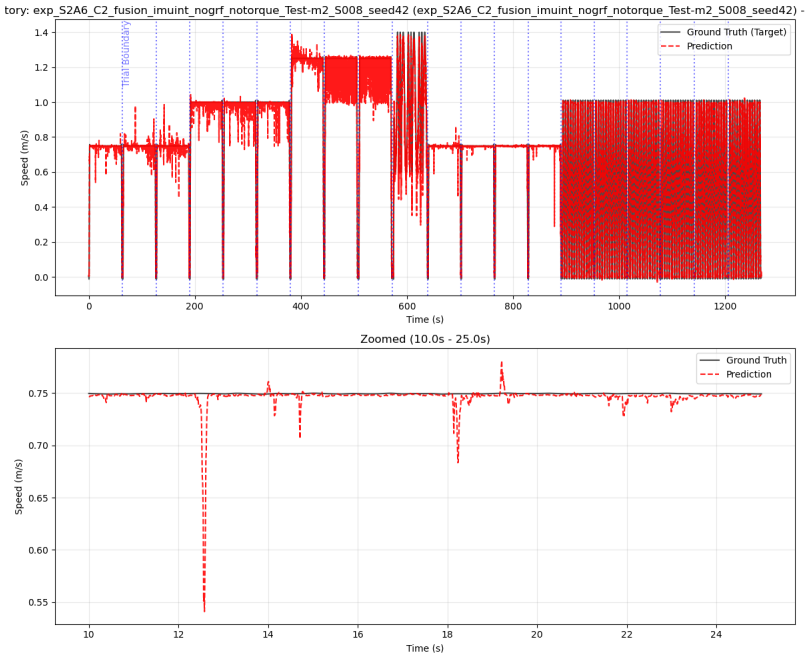

그림 6. archive_6 C2 sensor-light 모델의 trajectory plot. GRF와 torque를 제거한 상태에서도 전체 profile을 유지하며, deployable sensor set의 가능성을 보여준다.

10. 최종 결론과 논문 서사

이 프로젝트의 최종 메시지는 단순히 새 모델이 baseline을 이겼는가로 정리되지 않는다. 실제로 absolute best는 여전히 archive_2의 body-frame IMU + imu_integrated_speed baseline이다. 하지만 후속 archive는 무엇이 안 되는지와 무엇이 deployability 측면에서 유의미한지를 분명히 해 주었다.

- 논문용 best-accuracy 모델: archive_2 A5 bodyframe_plus_imuint
- 논문용 best new family: archive_5 / archive_6 fusion 계열
- 논문용 best sensor-light 모델: archive_6 C2 fusion_imuint_nogrf_notorque
- 논문용 best ultra-light Pareto point: archive_6 B3 fusion_dual_tiny120

따라서 논문은 absolute best accuracy와 real-time deployable estimator를 분리해 제시하는 것이 적절하다. 예를 들어, A5를 upper-bound reference로 두고, C2를 실사용 모델로 제시하면 성능 손실은 일부 있지만 입력 센서 구성과 계산 비용 면에서 훨씬 현실적인 장점이 있다. 이 framing은 baseline보다 약간 낮은 정확도도 contribution으로 살릴 수 있게 해 준다.

후속 full-LOSO 검증이 남아 있지만, single-LOSO 기준 내부 결론은 충분히 선명하다. 속도 추정에는 body-aligned inertial representation과 imu_integrated_speed prior가 핵심이며, 이후 개선은 더 큰 모델이 아니라 더 나은 fusion과 더 현실적인 deployment tradeoff에서 나온다.