Speed Estimation 고속·고보조 구간 오차 저감 전략

특히 level_100mps, level_125mps 의 lv4 / lv7 plateau offset 을 줄이기 위한 feature·model·training·evaluation 제안서

대상 packet: archive_season3/archive_2 | **작성일:** 2026-04-11

이 보고서는 첨부된 archive packet 과 최근 보행/웨어러블/도메인적응 문헌을 함께 읽고, **"왜 level_100mps·level_125mps 의 lv4/lv7 에서 거의 일정한 offset 형태의 오차가 남는지"**를 중심으로 다음 archive 에서 바로 실행할 수 있는 우선순위를 정리한 것이다. **핵심 판단은 "이 문제는 fast dynamics 실패보다 regime-dependent calibration bias 에 가깝다"**는 점이다. 따라서 더 많은 raw assist 신호를 빠른 경로에 집어넣기보다, 절대속도 anchor 를 강화하고 assist 를 느린 보정 문맥으로 다루는 것이 더 유망하다.

핵심 결론 6 개

- 현재 packet 의 overall best 는 P6 이지만, 사용자가 정확히 줄이고 싶어하는 target region(level_100mps/level_125mps, lv4/lv7 plateau alignment)만 놓고 보면 P4 가 가장 좋은 출발점이다.
- 오차 패턴은 transition 타이밍만의 문제가 아니라 steady plateau 에서의 절대 레벨 calibration 문제다. 즉, "속도 변화는 어느 정도 따라가지만 절대값이 밀리는" 형태다.
- 다음 archive 의 1 순위는 P4 를 기반으로 절대속도 anchor + nominal residual + assist slow calibrator + persistent bias state 를 결합한 hybrid 구조다.
- 사용자가 제안한 "보조력 구간을 학습에서 빼고 lv4/lv7 를 평가"하는 실험은 반드시 해볼 가치가 있다. 다만 이것은 최종 운영모델보다 domain-gap 진단용 benchmark 로 보는 편이 맞다.
- 가장 가치가 큰 추가 feature 는 phase-conditioned cadence/step-length anchor, anchor disagreement·confidence, time-since-assist, multi-stride duty cycle·work, 좌우 비대칭 및 trunk-joint coherence 다.
- 빠른 승부를 원하면 P4 계열에 hard-case sampling, symmetric plateau bias loss, assist-feature dropout on fast path, 그리고 R1 식 느린 bias state 를 먼저 붙이는 것이 좋다.

한 줄 의사결정

- "아카이브 전체 점수"를 먼저 올리고 싶으면 P6 를 baseline 으로 계속 유지하되,
- "level_100mps·level_125mps lv4/lv7 offset"을 정말 줄이고 싶으면 다음 실험의 중심은 P4 계열로 옮기는 것이 맞다.
- 논문용 story 또한 현재 상태의 P6 보다 P4 기반 hybrid 가 더 해석 가능하고 설득력 있다.

1. Packet 에서 먼저 확인되는 정량적 사실

보고서의 모든 수치 해석은 packet 에 포함된 summary CSV, condition-level summary, focus table, plot 을 기반으로 했다. 다만 현재 handoff packet 은 held-out subject m2_S008 기준의 archive 검토 자료이므로, 아래 결론은 "이 archive 에서 무엇이 먹혔는가"에 대한 강한 실무 지침으로 읽는 것이 적절하다.

표 1. overall metric 과 target region focus metric 을 함께 본 비교

모델	overall MAE	overall RMSE	latency (ms)	focus steady plateau MAE	핵심 해석
P6	0.05223	0.08372	5.33	0.01234	overall best, 그러나 focus plateau 는 P4 보다 나쁨
P4	0.05604	0.08756	5.06	0.01015	focus plateau best, latency 도 낮음
R1	0.05769	0.08654	15.96	0.01194	focus 는 좋지만 latency 가 3 배 이상
P7	0.05732	0.08875	5.23	0.01265	mixture 는 가능성 있으나 calibration 이 더 거칠다
P8	0.06261	0.09183	8.99	0.02033	full split 는 routed/shared 구조보다 불리

packet 기준으로 **overall MAE 최저는 P6(0.05223)**이고, **target region(level_100mps/level_125mps, lv4/lv7)의 평균 steady plateau MAE 최저는 P4(0.01015)**다. 즉, 전체 평균 점수와 사용자가 실제로 해결하고 싶은 문제의 winner 가 다르다. P4 는 P6 보다 overall MAE 는 약 6.8% 높지만, focus steady plateau MAE 는 약 17.8% 낮다.

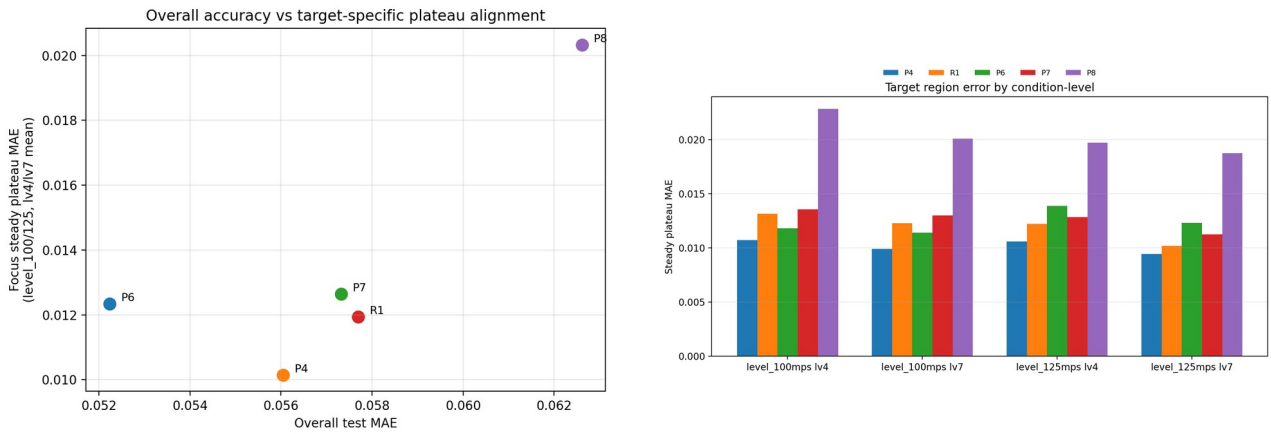

그림 1-2. 왼쪽: overall score 와 target-specific plateau alignment 는 동일한 순위를 주지 않는다. 오른쪽: lv4/lv7 의 핵심 4 개 cell 만 보면 P4 가 가장 낮은 plateau error 를 보인다.

특히 P6 는 level_100mps 와 level_125mps 사이에서 steady plateau signed bias 의 부호가 크게 바뀌는 반면, **P4 는 훨씬 더 0 에 가깝게 유지된다.** 이는 switch head 가 전체 평균 점수에는 유리했더라도, 사용자가 문제로 지적한 절대 레벨 calibration 에는 아직 불안정성이 남아 있음을 시사한다.

2. 왜 level_100mps / level_125mps, 특히 lv4·lv7 에서 offset 이 남는가

2.1 이 문제는 “assist 가 gait-speed mapping 자체를 바꾸는” 문제일 가능성이 크다

최근 hip exoskeleton 문헌은 보조력이 속도를 높일 때 cadence 만 바꾸는 것이 아니라 step length 도 함께 바꾸고, 일부 조건에서는 hip ROM 까지 바꾼다고 보고한다 [8]. 또한 treadmill 에서는 step length 와 cadence 를 overground 처럼 동시에 올리기 어렵기 때문에 adaptation mechanism 이 달라질 수 있다 [8].

당신의 target 은 belt speed 가 아니라 **LPF(common/speed_y)**다. 따라서 같은 nominal condition 이라도 보조력이 들어오면 trunk/robot kinematics 와 실제 target 사이의 함수가 바뀔 수 있다. **이때 모델은 transition 은 따라가면서도 plateau absolute level 만 밀리는 형태의 오차를 내기 쉽다.**

2.2 packet 의 승리 패턴은 “assist 를 빠른 예측변수로 쓰는 것”이 아니라 “느린 calibration context 로 쓰는 것”이다

key findings 를 종합하면 assist-related information 은 여전히 유용하지만, fast path 에서 직접 speed 를 예측하는 shortcut 보다 **calibration / routing context** 로 쓸 때 더 효과적이다. 이 해석은 다음 세 가지 사실과 잘 맞는다:

- P4(assist-on bias corrector)는 구조가 단순한데도 사용자가 걱정하는 plateau offset 에 가장 강했다.
- R1(persistent bias state)는 느린 calibration state 만으로도 focus metric 을 개선하지만 latency penalty 가 크다.
- P8(full assist off/on split)는 오히려 성능이 떨어졌다. 즉, hard split 자체가 답은 아니다.

2.3 P6 는 유효한 구조이지만, 현재 형태는 부분적으로 regime-specific shortcut 일 가능성이 있다

P6 는 overall MAE 기준으로 archive winner 다. 그래서 버릴 모델은 아니다. 다만 현재 packet 이 해결하려는 target issue 만 보면 P4 보다 못하다. 이 차이는 “shared representation + switched head”가 고속·고보조 구간에서 regime ID 를 이용해 평균적으로는 맞추지만, 절대 수준 calibration 은 충분히 고정하지 못했다는 해석과 잘 맞는다. 논문 관점에서도 P6 는 자칫 “조건별 shortcut”으로 보일 위험이 있다.

2.4 절대속도 anchor 와 confidence feature 가 아직 약하다

현재 입력에는 이미 imu_integrated_speed, speed_anchor_geom, pseudo_speed_robot, step_length_proxy 가 있다. 즉 anchor 가 전혀 없는 문제는 아니다. 하지만 현재 packet 에서 빠져 있는 것은 “어느 anchor 를 지금 얼마나 믿어야 하는가”를 알려주는 confidence 와 disagreement feature 다. **보조력이 들어오면 cadence·ROM·trunk dynamics 의 mapping 이 바뀌기 때문에, anchor 자체보다 anchor 간 불일치와 그 지속시간**이 plateau bias 를 줄이는 데 더 직접적인 단서가 된다.

2.5 데이터 분포 관점에서도 high-speed assisted plateau 는 hard case 다

웨어러블 센서 모델은 사용자·디바이스·환경 차이로 domain shift 를 강하게 받는다 [5]. real-world walking speed pipeline 도 gait complexity, bout duration, speed 에 따라 오차가 달라진다고 보고되었다 [4]. 즉, level_100mps / level_125mps 의 lv4/lv7 는 단지 “assist on”이 아니라, distribution shift 가 가장 센 regime 일 수 있다.

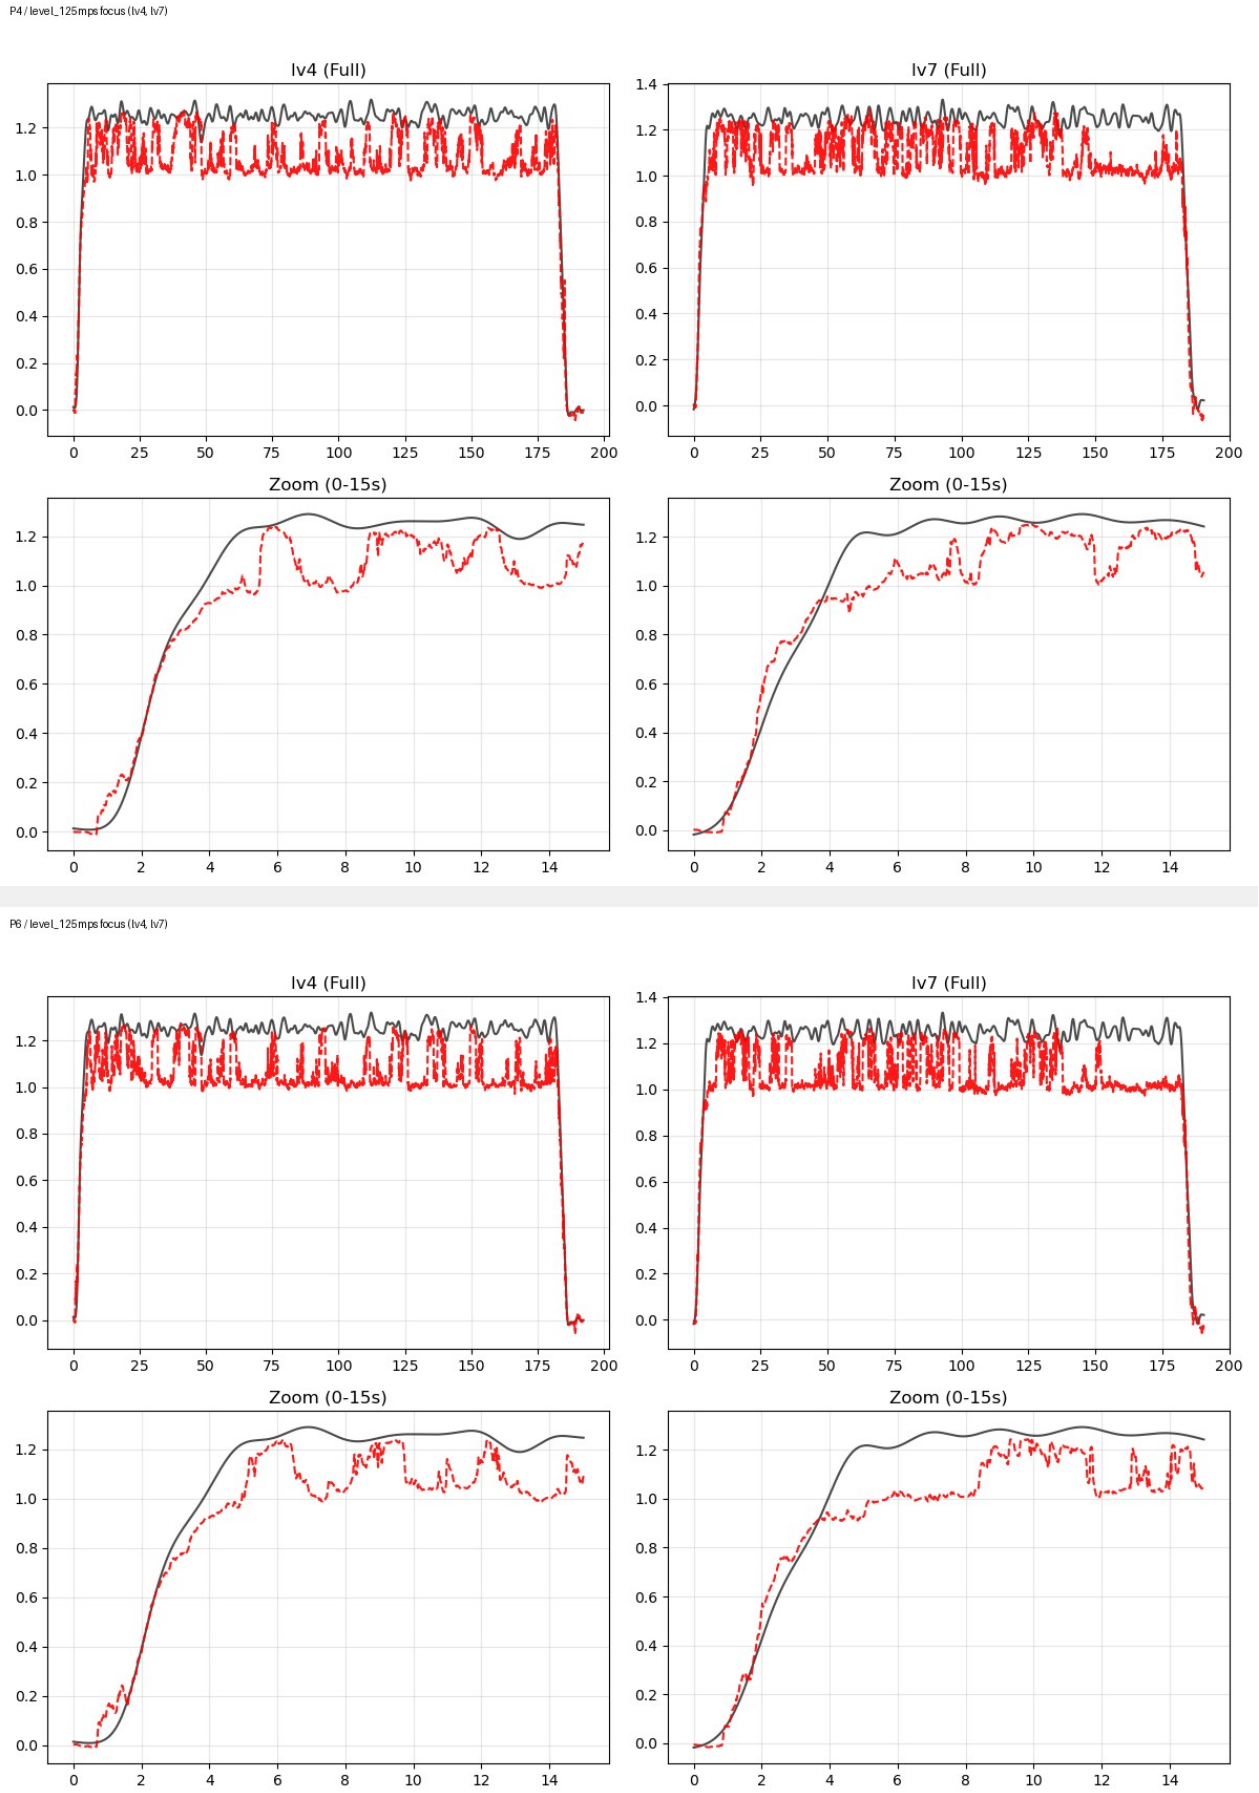

그림 3. level_125mps 의 lv4/lv7 focus crop. P4 도 완벽하지는 않지만, P6 보다 절대 plateau alignment 가 덜 흔들리는 쪽으로 해석하는 것이 타당하다.

3. 앞으로 어떤 input feature 를 더 쓰는 것이 좋은가

원칙은 단순하다. **feature 를 더 넣더라도 fast path 에 raw assist shortcut 을 늘리기보다,** (1) 절대속도 anchor 를 강화하고, (2) assist 가 mapping 을 얼마나 느리게 바꾸는지 보정하는 feature 를 추가해야 한다. 아래 표는 우선순위와 기대효과를 같이 정리한 것이다.

표 2. 추천 feature 후보와 우선순위

우선순위	feature family	왜 도움이 되는가	기대효과
A	Phase-conditioned cadence × step-length anchor	연속 gait phase, time-since-heel-strike, stance/swing ratio 를 이용해 step_length_proxy 를 phase-conditioned 하게 분해. speed = cadence × step length 의 해석력을 높임.	매우 높음
A	Anchor disagreement / confidence	anchor_diff = imu_integrated_speed - speed_anchor_geom, rolling std, cadence spectral confidence, phase confidence, anchor agreement duration. "지금 어떤 anchor 를 믿어야 하는가"를 모델에 알려줌.	매우 높음
A	Time-since-assist-on / off	보조력 인가 직후와 steady assist 구간을 분리. 현재 오차가 거의 일정한 offset 이면 이 feature 가 특히 잘 듣는다.	높음
A	Multi-stride assist duty cycle + cumulative work	최근 1·3·5 stride 의 assist_active duty cycle, cumulative positive work, work/step, work/cadence. "지속적으로 얼마만큼 보조를 받았는가"를 느린 bias proxy 로 사용.	높음
A	Normalized work / excursion ratios	positive work ÷ cadence, positive work ÷ hip excursion, torque impulse ÷ step time. 동일 보조량이라도 gait regime 이 달라질 때 mapping 변화를 더 잘 설명함.	높음
A	Left-right asymmetry + phase-specific asymmetry	hip/thigh excursion, power, step time, stance ratio 의 좌우 차이와 위상별 차이. 보조력이 특정 limb pattern 을 더 바꿀 때 plateau bias 와 연결되기 쉽다.	중~높음
B	Trunk-joint coherence / harmonic stability	cadence 와 2×cadence 주변 harmonic energy, trunk_pitch·gyro 와 hip/thigh angle 의 coherence. 보행 리듬이 바뀌었는지 여부를 빠르게 잡아줌.	중간
B	Expected-vs-observed excursion residual	현재 anchor speed 에서 기대되는 hip/thigh excursion 과 실제 excursion 의 residual. assistance-induced mapping shift 를 직접 측정하는 proxy.	중간
B	Separate anthropometrics	leg_length_mean/diff 대신 leg_length_l/r, stride-normalized anthropometric scaling. P9-P11 config 방향은 이 점에서 타당하다.	중간

우선순위	feature family	왜 도움이 되는가	기대효과
B	Plateau confidence	abs(dy), cadence confidence, anchor agreement, low jerk 를 묶어 "bias state 를 업데이트 해도 되는가"를 점수화. loss 와 online update 의 gating 에 공통 사용 가능.	높음
C	OOD / novelty score	현재 feature distribution 이 train regime 에서 얼마나 벗어났는지 점수화. calibration head 또는 fallback logic 에 사용.	탐색
C	Synthetic gait pretraining / domain randomization	물리 기반 synthetic gait 로 다양한 cadence-step length-rotation 조합을 미리 학습 [9]. 데이터가 부족한 high-assist regime generalization 에 도움.	탐색
C	추가 하드웨어(가능한 경우)	insole/foot-contact, motor current/voltage, EMG. 특히 gait event 와 phase confidence 를 매우 안정화할 수 있다. 다만 현재 프로젝트 제약에서는 장기 옵션.	탐색

개인적으로 가장 먼저 넣을 6 개만 고르라면: **(1) anchor disagreement/confidence, (2) time-since-assist, (3) multi-stride duty cycle, (4) cumulative positive work normalized by cadence, (5) phase-conditioned step-length anchor, (6) 좌우 비대칭 + trunk-joint coherence** 순서다. 이 조합은 "assist 가 speed mapping 을 얼마나, 얼마나 오래 바꿨는가"를 표현해 준다.

4. "보조력 구간을 학습에서 빼고 lv4/lv7 를 평가"하는 아이디어는 해볼 가치가 있는가?

결론부터 말하면 **반드시 해봐야 한다**. 다만 그 목적은 "최종 배포모델 만들기"보다 **domain-gap 진단과 representation 품질 검사**에 가깝다.

- **왜 좋은가:** 현재 모델이 assist proxy 를 shortcut 으로 쓰는지, 아니면 assist 가 없어도 유지되는 invariant locomotion-speed mapping 을 배웠는지 구분할 수 있다.
- **왜 최종모델로는 위험한가:** 실제 운영 환경에 assist 가 들어가는데 train 에서 그 domain 을 완전히 빼면 의도적으로 covariate shift 를 만든다. plateau bias 가 더 커질 수도 있다.
- **그래서 가장 좋은 쓰임:** lv0-only training 을 baseline diagnostic 으로 두고, 그 위에 "assist 는 slow calibrator 만 본다"는 구조적 제약이 실제로 이 gap 을 얼마나 줄이는지 비교하는 것.

표 3. 사용자가 제안한 방향을 포함한 추천 실험 매트릭스

실험	구성	보고 싶은 것	판정
E0	현재 P4 baseline	현 상태의 기준선 확보	focus plateau MAE / bias / onset·decay / latency
E1	Train: lv0 only Eval: lv4, lv7	assist domain gap 의 크기 자체를 측정. 성능이 크게 무너지면 assisted data 를 완전히 빼는 전략은 최종안으로 부적절.	diagnostic 전용
E2	Train: all data But fast path 에서 assist proxy masking	shortcut 의존성 검사. 성능이 유지되면 assist 는 느린 보정 경로로만 보내는 것이 맞다는 증거.	P4/P6 직접 비교

실험	구성	보고 싶은 것	판정
E3	Train: lv0 + low-assist backbone Freeze backbone Fine-tune only assist calibrator	사용자 아이디어의 가장 실용적인 형태. invariant backbone 과 assisted calibration 을 분리.	강력 추천
E4	Train: all data + assist-feature dropout/noise	assist proxy 과의존을 줄이고, 보조력 문맥은 남긴다.	강력 추천
E5	Curriculum: lv0 → low-assist → high-assist	mapping shift 를 서서히 배우게 하여 plateau bias state 를 안정화.	추천
E6	Leave-one-assist-level-out (train lv0+lv4, test lv7 / 반대도)	lv4 와 lv7 사이의 extrapolation 능력 평가.	추천
E7	Few-shot subject calibration (초반 30~60 초만 사용)	subject-specific assisted response 가 큰 경우 가장 즉효성 있는 방법.	운영 옵션
E8	Train without assisted windows Eval with post-hoc calibrator only	가장 공격적인 사용자 아이디어의 변형. backbone 은 assist 를 보지 않고, 마지막 작은 calibrator 만 assist feature 사용.	논문용 ablation 으로 좋음

내 판단은 다음과 같다. **"보조력 구간을 학습에서 완전히 제외"는 최종안보다 diagnostic 으로 매우 좋다.** 실전용으로는 **"backbone 은 lv0/low-assist 중심으로 학습하고, assisted data 는 작고 느린 calibrator 에만 쓰는 방식"**이 훨씬 유망하다.

5. 내가 가장 추천하는 차기 모델: P4 + persistent bias state + anchor residual

사용자의 목표가 명확하기 때문에 다음 archive 의 중심 baseline 은 P6 가 아니라 **P4** 로 옮기는 것이 맞다. 여기에 R1 의 장점인 **persistent slow bias state** 를 그대로 전체 모델에 넣기보다, **assist-on slow calibrator 에만 한정해서 붙이는 hybrid** 를 추천한다.

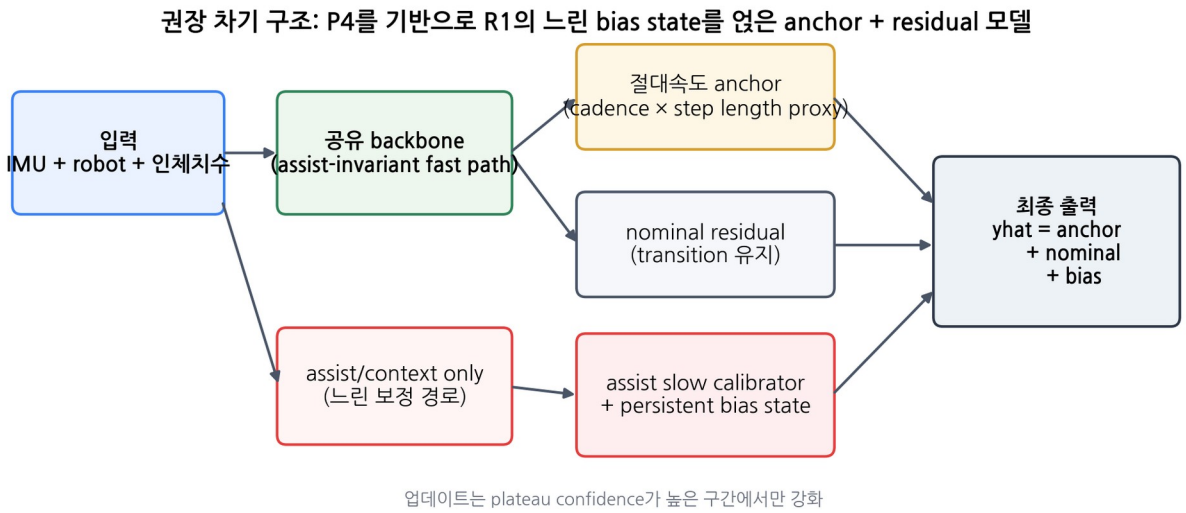

그림 4. 권장 차기 구조. shared backbone 은 assist-invariant 하게 유지하고, assist proxy 는 느린 보정 경로와 bias state 에만 강하게 연결한다.

핵심 아이디어는 다음 식으로 요약할 수 있다.

```
anchor_t   = f_anchor(cadence, step_length_proxy, imu_prior, anthropometrics)
nominal_t  = f_fast(shared_backbone(x_t_without_direct_assist))
bias_t     = λ · bias_{t-1} + (1-λ) · g_assist(z_t_slow) · plateau_conf_t
yhat_t     = anchor_t + nominal_t + bias_t
```

- **왜 이 구조가 좋은가:** fast dynamics 는 shared backbone + nominal residual 이 잡고, 고속·고보조에서 밀리는 절대 레벨은 느린 bias state 가 잡는다.
- **왜 P6 보다 논문 story 가 좋은가:** assist 를 직접 route 하는 것보다 “shared speed representation + slow calibration”이 더 해석 가능하고 일반화 논리를 세우기 쉽다.
- **왜 R1 보다 실용적인가:** persistent state 를 전체 모델에 걸지 않고 calibrator 에만 두면 latency 와 drift risk 를 줄일 수 있다.
- **가장 중요한 제약:** bias state update 는 plateau confidence 가 높을 때만 강하게 허용하고, transition 이나 assist onset 직후에는 leak 를 크게 해서 오래 남지 않게 해야 한다.

6. 학습·loss·sampling 에서 꼭 바꿔볼 것

표 4. 다음 archive 에 바로 넣을 training / loss / sampling 변경점

#	변경점	실행 메모
1	Hard-case sampling 강화	speed bin 을 level_100mps / level_125mps 중심으로, assist quantile 은 lv4/lv7 대응 고구간으로 묶어 oversample. subject-balanced mini-batch 필수.
2	Plateau bias loss 를 symmetric 하게	P4 의 under_only=true 는 간단한 fix 였지만, P6 에서처럼 speed bin 에 따라 signed bias 부호가 달라질 수 있다. 다음 archive 에서는 under_only 단독 사용을 멈추고 symmetric bias penalty 또는 speed-bin-specific weighting 을 권장.
3	Anchor supervision 재도입	P9 config 가 시도했던 anchor supervision 은 방향이 맞다. 다만 switch-head family 보다 P4 family 에 얹어야 한다. plateau confidence 가 높은 구간에만 weight 를 주는 방식이 적합.
4	Assist-feature dropout / noise on fast path	assist proxy 가 backbone shortcut 이 되는 것을 막는다. calibrator 경로에는 남기되, shared backbone 입력에는 masking/noise 를 주는 방식이 좋다.
5	Domain invariance regularization	shared backbone feature 에서 lv0 와 assisted regime 의 separation 을 줄이는 penalty(CORAL/MMD/GRL 류)를 작게 추가. 단, calibrator 는 예외.
6	Auxiliary task	cadence, step time, gait phase, step-length proxy 를 auxiliary target 으로 예측시켜 representation 을 더 물리적으로 묶는다.
7	Bias state anti-drift	assist off 또는 transition 에서 bias state 가 빠르게 0 으로 복귀하도록 regularizer 추가. update gate 는 plateau confidence 로 제한.
8	Group DRO / worst-bin weighting	P9/P11 의 group-DRO 방향은 유효하다. 다만 P4 hybrid 에서 “speed bin × assist bin × steady/non-steady” 그룹으로 다시 설정하는 것이 좋다.

표 4 (계속). training / loss / sampling 변경점

#	변경점	실행 메모
9	Few-shot calibration 옵션	운영 단계에서 subject-specific 첫 30~60 초 데이터로 작은 calibrator 만 업데이트하는 옵션을 별도로 준비.
10	Regression test-time adaptation 은 optional	회귀 TTA 문헌 [6][7]은 참고할 가치가 있으나, 현재 프로젝트에서는 우선 작은 bias state update 부터 시작하는 것이 더 안전하다.

7. 바로 실행 가능한 우선순위 로드맵

표 5. 추천 실행 순서

우선순위	실험	왜 먼저 해야 하는가
P0	P4 를 새 기준선으로 확정	overall best 는 P6 지만 target issue winner 는 P4. 실험 관리 기준을 둘로 분리 (overall / focus).
P1	P4 + new feature 6 종	anchor disagreement/confidence, time-since-assist, duty cycle, cumulative work normalized, phase-conditioned anchor, asymmetry/coherence 추가.
P1	P4 + symmetric plateau bias loss + hard-case sampling	특히 level_100mps / level_125mps 의 lv4/lv7 를 과대표집.
P1	P4 + assist-feature dropout on fast path	shortcut 의존을 줄이고 calibrator 경로만 유지.
P2	P4 + persistent bias state hybrid	R1 아이디어를 calibrator 에만 넣고 leak 0.97~0.995 범위를 sweep.
P2	Diagnostic matrix E1~E8 실행	사용자 아이디어의 진짜 효용을 정량화.
P3	Optional online calibrator / few-shot subject adaptation	실제 배포를 생각하면 가장 큰 체감 성능 개선이 여기서 나올 수 있음.
P3	Synthetic pretraining or domain randomization pilot	데이터 부족이 확인될 때만 탐색.

내가 당신이라면 첫 1~2 주 안에 다음 네 묶음을 끝낸다: **(A) P4 기반 새 feature, (B) hard-case + symmetric plateau loss, (C) fast-path assist masking/dropout, (D) lv0-only diagnostic + calibrator-only fine-tune**. 이 네 개만 해도 왜 오차가 남는지 원인을 상당히 분해할 수 있다.

8. 논문 기여 관점에서는 무엇이 가장 강한가

현재 packet 그대로 논문을 쓴다면 P6 는 "overall accuracy-best archive model"로는 좋지만, **핵심 기여 모델로는 P4 계열 hybrid 가 더 강하다**. 이유는 세 가지다.

- 문제 정의와 구조가 정렬되어 있다: plateau offset 이라는 failure mode 에 정확히 대응한다.
- shared backbone + slow calibrator + anchor 라는 구조는 해석 가능성이 높고 reviewer 에게 설명하기 쉽다.
- P6 는 성능은 좋지만 switch head 가 regime-specific shortcut 으로 보일 위험이 있다. 반면 P4 hybrid 는 "assist 는 context, speed 는 shared representation"이라는 메시지가 분명하다.

논문 framing 예시는 다음과 같다: **"Causal Anchor-Residual Calibration for Exoskeleton-Assisted Gait Speed Estimation"** 또는 **"Assist-Invariant Speed Representation with Slow Bias Calibration"**. 이 framing 은 recent regression adaptation / synthetic gait generalization literature [6][7][9]와도 잘 연결된다.

9. 해볼 수 있는 모든 가능성 체크리스트

아래는 우선순위와 무관하게 “시도 가능한 모든 레버”를 category 별로 정리한 checklist 다. 이미 표에서 언급한 항목도 중복 포함했다. 실험 설계 시 빠뜨리지 않기 위한 용도다.

9.1 Feature

- phase-conditioned step length anchor
- continuous gait phase / time-since-event
- anchor disagreement / confidence / agreement duration
- assist onset/off elapsed time
- assist duty cycle over 1·3·5 strides
- cumulative positive / negative work per stride
- work normalized by cadence / excursion / step time
- left-right asymmetry and phase-specific asymmetry
- trunk-joint coherence / harmonic energy / spectral entropy
- expected-vs-observed excursion residual
- plateau confidence
- OOD / novelty score
- leg_length_l/r separate scaling
- step-to-step variability and irregularity
- optional insole / foot-contact / EMG / motor current

9.2 Model

- P4 + persistent bias state hybrid
- anchor + residual decomposition
- calibrator-only state update
- soft gate with hysteresis instead of hard switch
- shared backbone + small expert calibrators
- domain-invariant backbone + assist-only calibrator
- uncertainty-aware output / heteroscedastic regression
- post-hoc residual calibrator on top of current best model
- few-shot subject adapter
- optional parameter-efficient online adapter

9.3 Data / label / curation

- high-speed high-assist long plateau data 추가 수집
- assist schedule randomization 으로 speed 와 assist correlation 약화
- subject 별 repeated trial 확보
- label synchronization 재점검
- zero-phase LPF target 와 causal attainability 의 차이 점검
- train/val/test 에서 regime coverage 시각화
- hard-case bin density 확인
- synthetic gait / domain randomization pilot

9.4 Loss / training / optimization

- symmetric plateau bias loss
- speed-bin-specific bias weighting
- hard-case sampling by speed × assist × steady
- subject-balanced mini-batch
- assist-feature dropout / noise
- anchor supervision
- multi-task auxiliary heads
- group DRO / worst-bin weighting

- curriculum lv0 → low-assist → high-assist
- backbone pretrain + calibrator fine-tune

9.5 Evaluation / diagnostics

- lv0-only train → lv4/lv7 eval
- assist masking ablation
- leave-one-assist-level-out
- per-speed / per-level Bland-Altman style analysis
- residual vs assist intensity continuous plot
- feature-space separation (lv0 vs assisted)
- anchor-alone vs model residual contribution analysis
- subject adaptation curve
- latency / stability / fallback logic 평가

References

[1] Seo, K. et al. Real-Time Estimation of Walking Speed and Stride Length Using an IMU Embedded in a Robotic Hip Exoskeleton. ICRA, 2023.

[2] Choi, S., Ko, C., & Kong, K. Walking-Speed-Adaptive Gait Phase Estimation for Wearable Robots. Sensors, 2023.

[3] Zadka, A. et al. A wearable sensor and machine learning estimate step length in older adults and patients with neurological disorders. npj Digital Medicine, 2024.

[4] Kirk, C. et al. / Mobilise-D consortium. Mobilise-D insights to estimate real-world walking speed in multiple conditions with a wearable device. Scientific Reports, 2024.

[5] Li, J. et al. DWLR: Domain Adaptation under Label Shift for Wearable Sensor. IJCAI, 2024.

[6] Liu, J. et al. Test-time Adaptation for Regression by Subspace Alignment. ICLR, 2025.

[7] Liu, J. et al. Q-PART: Quasi-Periodic Adaptive Regression with Test-time Training for Pediatric Left Ventricular Ejection Fraction Regression. CVPR, 2025.

[8] Livolsi, C. et al. Bilateral hip exoskeleton assistance enables faster walking in individuals with chronic stroke-related gait impairments. Scientific Reports, 2025.

[9] Ota, M. et al. Utility of synthetic musculoskeletal gaits for generalizable healthcare applications. Nature Communications, 2025.

[10] Arens, P. et al. Real-time gait metric estimation for everyday gait training with wearable devices in people poststroke. Wearable Technologies, 2021.

마지막 요약: 당장 level_100mps / level_125mps 의 lv4·lv7 오차를 줄이려면 P6 를 더 복잡하게 만들기보다, P4 를 중심으로 절대속도 anchor 와 느린 assist calibration 을 강화하는 쪽이 더 빠르고, 더 해석 가능하며, 더 논문화하기 좋다.