Robot + Trunk IMU 기반
실시간 Speed Estimation 전략 메모

대상 target: LPF(common/speed_y)

입력 제약: robot 센서 + trunk IMU + anthropometrics 만 허용

목표: level_100 / level_125 의 lv4, lv7 에서 반복되는 steady offset 을 근본적으로 줄이는 것

> **핵심 한 문장**: 지금 문제의 본질은 "속도 변화는 어느 정도 잡는데, high-assist steady plateau 의 절대 speed level 을 고정해 주는 anchor 가 약하다"는 것이다. 따라서 fast inertial process, absolute-speed anchor, assist-conditioned slow calibration, streaming memory 를 분리하는 방향이 가장 유망하다.

1. 이번 메모에서 고정하는 문제 정의

- 학습 target 은 treadmill belt speed 가 아니라 common 폴더의 speed_y semantics 에 해당하는 속도 reference 이며, 실제 학습에는 bidirectional LPF 를 적용한 값을 사용한다.
- 실시간 제약은 label 이 아니라 입력 feature 와 모델에 걸린다. 즉 학습용 reference 가 offline zero-phase 여도, 실제 estimator 는 causal 이면 된다.
- 허용된 raw input 은 robot 센서, trunk IMU, subject 의 weight/leg length/height 등 anthropometric 정보뿐이다.
- mocap, GRF, treadmill speed direct input, treadmill speed 에서 유도된 feature 는 입력 feature 로 사용하면 안 된다.
- 예외적으로 trunk 진행방향 가속도에 treadmill acceleration 을 더해 overground-equivalent trunk acceleration 을 만드는 것은 허용된다. 이는 treadmill speed 를 직접 넣는 것이 아니라 overground 환경을 모사하기 위한 전처리로 해석한다.

2. 반드시 지켜야 할 입력 원칙

허용	금지
robot/back_imu accel, gyro, quaternion	mocap 기반 모든 feature
robot left/right: hip_angle, thigh_angle, motor_angle, torque	GRF/contact 기반 모든 feature
sub_info: height, weight, leg length 등	treadmill speed direct input
causal derivative, EMA, causal LPF, leaky integration	future sample 참조, filtfilt, zero-phase input filter
forward_accel_overground = trunk 진행방향 acc + treadmill acceleration	treadmill speed 를 새는 우회 feature

3. lv4/lv7 에서 offset 이 반복되는 근본 원인

- steady plateau 에서는 absolute speed observability 가 약하다. level_100 / level_125 의 steady 구간에서는 trunk 가속 평균이 거의 0 에 수렴하므로, 적분형 prior 는 변화량 추적에는 좋지만 절대 속도 level anchor 로는 부족해진다.
- high assist 는 speed proxy 를 흐린다. 같은 target speed 라도 assistance 가 커지면 trunk oscillation, 관절 excursion, human effort 가 달라져 모델이 speed 대신 motion amplitude 를 배우면 under-estimate 가 생긴다.
- raw torque 를 instantaneous feature 로 fast path 에 넣으면 phase-locked confounding 이 생긴다. torque 는 speed 자체의 직접 관측치보다 context 또는 calibration cue 에 가깝다.
- 윈도우 독립 추론은 slow bias 를 놓친다. lv4/lv7 offset 은 몇 초 이상의 느린 state 일 수 있는데, 매 window 를 거의 독립적으로 보면 이 bias 를 붙잡기 어렵다.

4. 지금까지의 package 에서 읽히는 가장 유의미한 signal

최근 robot-light package 의 season2 archive_2 structured run 들을 보면, **E2_remove_raw_torque_fast** 가 전체 MAE 와 problematic plateau bias 의 균형이 가장 좋다. **E5_assist_proxy_aux** 도 plateau bias 관점에서는 긍정 signal 이 있지만 overall 은 E2 보다 약하다. 반면 naive fast-slow split, subject calibration probe, regime-balanced sampling 은 현재 구현 그대로는 근본 해결로 이어지지 않았다.

실험	Overall MAE	문제 구간 mean |plateau bias|	해석
E2 remove_raw_torque_fast	0.0584	0.0026	현재 가장 균형 좋음. raw torque 는 fast path 에서 빼는 방향이 맞음
E5 assist_proxy_aux	0.0611	0.0019	assist summary/context 신호는 유효. 다만 nominal 추정기를 망가뜨리지 않는 방식 필요
E1 fastslow_split	0.0715	0.0026	fast/slow 아이디어 자체는 맞아도 현재 구현은 anchor 가 약함
E8 subject calibration	0.0700	0.0032	subject affine 만으로는 plateau offset 의 본체를 못 잡음

5. 최우선으로 추천하는 상위 8 개 방향

#	방향	왜 유망한가

1	Adaptive complementary estimator	fast inertial estimate, absolute-speed anchor, slow assist calibration 을 분리해 가중 융합한다. transition 에서는 fast 를, steady plateau 에서는 anchor 를 더 믿게 만든다.
2	Cadence × Step-Length decomposition	speed 를 단일 회귀가 아니라 cadence 와 step length 의 곱으로 추정한다. cadence 는 robust 하고, step length 는 geometry/anthropometry 로 anchor 를 만든다.
3	Assist-invariant nominal branch + assist-calibration branch	같은 speed 인데 assist 가 다르다고 nominal latent 가 바뀌지 않게 하고, assist 관련 정보는 slow correction 으로만 사용한다.
4	Persistent slow bias state	몇 초 이상 유지되는 plateau offset 을 느리게 움직이는 bias state 로 추적한다.
5	Stateful streaming model	window 독립 추론보다 hidden state 를 carry 하는 GRU/LSTM/SSM 이 slow operating-point drift 를 더 잘 잡는다.
6	Step-token / per-step model	bilateral thigh phase 기반 pseudo gait event 를 잡고 step 요약 token sequence 를 추적해 phase confounding 을 줄인다.
7	Speed-mode classification + residual	level_075 / 100 / 125 를 operating mode 로 먼저 인식하고, 그 위에 residual 을 예측해 absolute speed anchor 를 강화한다.
8	Frozen nominal model + tiny bias corrector	명목 추정기와 slow bias corrector 를 분리해 안정적으로 fine-tune 한다. 실무적으로 구현 난도가 낮고 실패 확률이 적다.

6. Absolute-speed anchor 를 만들기 위한 feature 후보

- cadence_l / cadence_r / cadence_mean
- bilateral thigh excursion RMS
- bilateral hip excursion RMS
- thigh_l - thigh_r separation amplitude
- hip_l - hip_r separation amplitude
- phase rate variability / stride time / duty proxy
- trunk pitch, pitch rate, gait-band power
- trunk harmonic ratio
- pseudo step length = f(leg length, bilateral excursion, trunk geometry)
- Froude-like normalization and leg-length-normalized features

7. Assist / interaction context feature 후보

- torque_abs_ema_fast_sum / torque_abs_ema_slow_sum
- torque_signed_ema_slow_sum
- assist_proxy_sum, torque_stride_impulse_sum
- deflection magnitude / RMS / velocity
- motor power, signed joint power, propulsion / braking power
- effective stiffness proxy: torque / deflection
- effective damping proxy: torque / deflection velocity
- assist work per step, late-stance assist work
- power asymmetry
- torque timing relative to gait phase, motor-human phase lag

8. IMU prior 와 anthropometric feature 강화 후보

- actual left/right leg length 를 직접 사용
- height, weight 외에 average leg length 와 좌우 차이를 포함
- normalized excursion by leg length
- multi-timescale imu_integrated_speed (fast leak + slow leak)
- phase-aware leaky integration
- step-reset integration
- forward_accel_overground 의 causal HP/LP dual decomposition
- jerk / jerk RMS, orientation-stabilized trunk pitch velocity
- running confidence feature for inertial prior
- robot-only pseudo_speed prior 의 재설계

9. 후보군을 아주 많이 뽑으면 - 구조/학습 아이디어 풀

A. 구조적 모델

- complementary anchor model
- cadence×step-length baseline
- structured slow-fast + persistent bias state
- stateful streaming GRU
- step-token GRU
- speed-mode + residual
- frozen nominal + tiny bias corrector
- assist-invariant encoder + correction decoder
- uncertainty-gated fusion
- dual-timescale state-space model

B. 추가 구조 실험

- mixture-of-experts by regime
- phase-conditioned experts
- steady/transient dual-head
- long-context downsampled slow branch (8-12s)
- causal SSM / Mamba 류 경량 state model
- MDN / quantile regression head
- retrieval/prototype correction
- online calibration token from first 10s
- subject-conditioned calibration using anthropometry
- trial-memory bias adapter

C. loss / objective

- running-mean bias loss
- steady plateau signed bias loss
- low-frequency consistency loss
- error-assist decorrelation penalty
- same-speed different-assist contrastive loss
- GroupDRO / worst-group minimization
- speed-bin classification auxiliary
- cadence auxiliary
- step-length auxiliary
- transition-preserving derivative loss

D. sampling / curriculum

- level_100/125 lv4/lv7 oversampling

- steady/transient 분리 샘플링
- assist-balanced sampler
- subject-balanced sampler
- curriculum: lv0 -> lv4 -> lv7
- curriculum: low speed -> high speed
- phase-balanced sampling
- hard-window replay buffer
- counterfactual torque scaling augmentation
- ROM compression augmentation

E. calibration / adaptation

- first-10s online calibration
- test-time stat adaptation
- prototype-based calibration by morphology
- session embedding
- temperature scaling for speed mode head
- uncertainty-aware smoothing
- meta-learning for quick subject adaptation
- memory-augmented calibration
- sticky speed-mode regularization
- subject embedding calibration

10. 지금은 우선순위를 낮춰야 할 것

- 더 큰 raw TCN / 더 깊은 end-to-end 만 반복하는 것
- raw torque 를 fast path 에 다시 넣는 것
- global affine calibration 하나로 offset 을 해결하려는 것
- pointwise steady bias loss 만 세게 거는 것
- subject calibration 만으로 plateau bias 의 본체를 해결하려는 것
- treadmill speed 를 우회적으로 새는 feature
- 복잡도만 큰 observer 를 바로 올리는 것
- strict robot+trunk-only 제약을 흐리는 privileged feature 혼입

11. 실제 실행 우선순위 - training wave 제안

Wave 1 - 가장 먼저 돌릴 것

- adaptive complementary estimator
- cadence×step-length baseline
- structured slow-fast + persistent bias state
- stateful streaming GRU
- assist-invariant nominal branch + slow calibration branch
- speed-mode classification + residual
- frozen nominal + tiny bias corrector

Wave 2 - feature heavy

- actual leg length 기반 anchor 강화
- trunk pitch / harmonic feature 추가
- stiffness / damping / deflection interaction feature
- phase-specific work feature
- counterfactual torque augmentation
- running-mean bias loss
- GroupDRO / worst-group training
- confidence-gated fusion

Wave 3 - 논문형 / moonshot

- learned observer with explicit cadence-steplength-bias state
- step-token model
- per-step speed / step-length head
- same-speed different-assist contrastive learning
- assist-invariant representation learning
- trial-memory bias adapter
- test-time calibration
- online calibration token

12. 이번 라운드에서 반드시 보고해야 할 평가 지표

지표	왜 중요한가	특히 볼 조건
overall MAE / RMSE	전체 성능의 기본 축	전체 held-out subject
steady plateau signed bias	네가 실제로 가장 싫어하는 offset 을 직접 측정	level_100/125 x lv4/lv7
steady plateau MAE	plateau 절대 오차를 분리	level_100/125 x lv4/lv7
onset / decay error	transition 성능을 따로 봐야 plateau	stopandgo, accel_sine

	bias 와 trade-off 를 구분 가능	
trough error p05	phase-locked deep dip 여부를 직접 반영	level + stopandgo
latency / params	실시간 deployability 보장	best 3 models

13. 최종 판단

가장 먼저 밀어야 할 단일 방향은 **adaptive complementary estimator** 다. 즉 fast inertial process, absolute-speed anchor, assist-conditioned slow calibration, streaming memory 를 분리하는 구조다. 그다음 축은 **cadence×step-length decomposition** 과 **assist-invariant nominal branch** 다. lv4/lv7 offset 은 단순히 더 큰 모델을 올린다고 닫히는 종류가 아니라 관측 구조와 calibration 구조를 바꿔야 닫힌다.

14. Agent 에게 바로 보낼 수 있는 실행 지시문

첨부한 PDF 기준으로 이번 라운드는 실험을 개별 확인하지 말고 한 번에 큐에 올려서 실행해줘.

고정 전제:
1) 최종 target 은 treadmill speed 가 아니라 LPF(common/speed_y)다.
2) 입력 raw source 는 robot 센서, trunk IMU, subject anthropometrics 만 허용한다.
3) mocap, GRF, treadmill speed direct input, 그리고 그것들을 조금이라도 새는 feature 는 금지한다.
4) 단, trunk 진행방향 acc + treadmill acceleration 으로 만든 overground-equivalent accel 은 허용한다.
5) 입력 feature 생성과 모델 추론은 반드시 causal / online-feasible 해야 한다.
6) common/assist_level 은 inference input 으로 쓰지 않는다.

이번 라운드의 핵심 목표:
- level_100 / level_125 의 lv4, lv7 에서 반복되는 steady offset 을 근본적으로 줄이는 것
- fast dynamics 는 유지하면서 high-assist plateau absolute speed level 을 더 정확히 고정하는 것

가장 먼저 돌릴 핵심 실험군:
A) adaptive complementary estimator
B) cadence×step-length decomposition baseline
C) assist-invariant nominal branch + slow assist-calibration branch
D) persistent slow bias state / stateful streaming model
E) speed-mode classification + residual
F) frozen nominal + tiny bias corrector

feature 후보는 PDF 에 정리된 범위 안에서 폭넓게 생성해도 되지만, 다음 원칙을 지켜줘:
- raw torque 는 fast / nominal path 에 직접 넣지 말고, slow context 나 calibration path 위주로 써라.
- absolute speed anchor 를 만들기 위해 cadence, step-time, bilateral excursion, trunk pitch/harmonic, leg-length-normalized geometry feature 를 적극 사용해라.
- assist 관련 정보는 power / work / deflection / timing / stiffness-like proxy 같은 interaction summary 로 만들어라.
- short-window 독립 추론만 고집하지 말고 streaming hidden state 또는 persistent bias state 를 포함해라.

학습 전략:
- 가능한 모델을 많이 동시에 돌려도 된다.
- 다만 단순히 더 큰 end-to-end 모델을 반복하는 건 우선순위를 낮춰라.
- same-speed different-assist contrastive, GroupDRO, running-mean bias loss, hard-case oversampling 도 함께 시도해라.
- lv4/lv7 high-assist plateau bias 를 직접 줄이는 방향으로 설계하되 transition 성능을 망가뜨리면 안 된다.

필수 평가 지표:
- overall MAE / RMSE
- steady plateau signed bias
- steady plateau MAE
- onset error / decay error
- trough error p05
- latency / parameter count

필수 보고 조건:
- 특히 level_100 / level_125 의 lv4, lv7 를 별도로 분리해서 표와 trajectory plot 을 내라.
- 어떤 실험이 overall 만 좋은지, 어떤 실험이 plateau offset 을 실제로 줄였는지 분리해서 해석해라.
- 최종적으로 accuracy-best, offset-best, deployable-best 를 각각 추천해라.

최종 질문에 답할 수 있게 정리해줘:
1) absolute-speed anchor 를 추가하면 lv4/lv7 steady offset 이 실제로 줄어드는가?
2) raw torque 를 fast path 에서 제거하는 것이 계속 유효한가?
3) cadence×step-length decomposition 이 robot+trunk-only 제약에서 통하는가?
4) streaming bias state 가 plateau level 보정에 도움이 되는가?
5) 논문 contribution 으로 가장 강한 구조와 feature insight 는 무엇인가?

복사해서 바로 보내기 쉽게 같은 내용을 별도 TXT 파일로도 함께 저장했다.