SpeedEstimation_wo_grf 최고 성능 모델 보고서

archive_season1 / archive_2 | 대표 권장 결과 raw_full_w200_cmp_clamp07

생성일: 2026-04-15

이 보고서는 프로젝트 목적, 데이터 구성, 최고 성능 plateau의 의미, 대표 결과 모델의 구조와 학습 방법, 정량 지표, 정성 plot, feature importance, 직접 입력과 derived input의 계산 방식, 그리고 실제 사용 관점의 해석까지 한 문서 안에서 이해할 수 있도록 다시 정리한 종합 보고서다. 신경망이나 보행 속도 추정이 익숙하지 않은 독자도 따라올 수 있도록 설명형 문장 위주로 작성했다.

대표 result	공식 MAE
Clamp07	0.0260 m/s
recommended deployment result	test subject S008

공식 RMSE	모델 크기
0.0374 m/s	1.55 MB
큰 오차에 더 민감한 지표	407,489 parameters

호스트 지연	예측 horizon
2.39 ms	+50 ms
same learned body as ref/clamp20	입력 history 2.0 s

핵심 요약: archive_2의 learned body는 한 개의 독립 winner라기보다 동일한 정량 성능을 보이는 plateau 형태였다. 그 후 같은 weight를 유지한 clamp sweep을 추가로 비교했을 때, clamp07이 noise 억제와 성능 보존의 균형이 가장 좋다고 판단되어 이 보고서에서는 clamp07을 대표 권장 결과로 설명한다.

1. 프로젝트 목적과 문제 정의

이 프로젝트의 목표는 트레드밀에서 외골격을 착용한 사람의 corrected walking speed를 실시간에 가깝게 추정하는 것이다. 중요한 점은 이 프로젝트가 treadmill belt speed 자체를 그대로 맞히려는 것이 아니라, 프로젝트 내부 target인 common/v_Y_true를 맞히는 문제라는 점이다.

입력에서는 force plate GRF를 쓰지 않는다. 대신 모션캡처 관절운동학, back IMU, 외골격 torque, 피험자 기본 정보만으로 speed를 추정한다. 즉 힘판 없이도 deploy 가능한 방향을 겨냥한 GRF-free speed estimation 문제라고 볼 수 있다.

왜 spike 억제가 중요한가? 평균 오차가 낮더라도 예측 speed가 순간적으로 튀면, 제어기나 피드백 로직이 불안정해질 수 있다. 따라서 이 프로젝트에서는 '평균적으로 맞는가'와 함께 '곡선이 자연스럽고 덜 튀는가'도 주요 품질 기준이다.

프로젝트 처리 흐름

단계	무엇을 하는가	왜 필요한가
1	센서 입력 수집: 관절각, back IMU, torque, 키/몸무게	힘판 없이도 사용 가능한 정보만 사용한다.
2	최근 2.0초(200 sample)를 하나의 입력 window로 구성	보행은 시계열 패턴이 중요하므로 짧은 순간값보다 시간 흐름을 같이 본다.
3	TCN이 시간축 패턴을 추출	주기성, 속도 변화, 좌우 패턴 같은 temporal structure를 읽는다.
4	GRU head가 window 정보를 요약	직전 정보와 앞선 패턴을 섞어 미래 speed를 안정적으로 예측한다.
5	50 ms 미래의 corrected speed를 출력	즉 현재값이 아니라 아주 가까운 미래를 예측한다.
6	Clamp07 후처리로 과도한 순간 가속을 제한	너무 급격하게 튀는 예측을 줄여 정성적으로 더 안정적인 곡선을 만든다.

쉽게 말하면, 모델은 '최근 2초 동안 몸이 어떻게 움직였는지'를 보고 '50 ms 뒤 속도'를 내다본다. 그리고 clamp07은 마지막 단계에서 너무 급한 변화는 잘라내는 안전장치 역할을 한다.

2. 데이터와 평가 protocol

모델은 S008을 전혀 보지 않은 상태에서 학습되고, S008의 여러 조건에서 generalization이 얼마나 잘 되는지로 평가된다. 따라서 여기서 말하는 최고 성능은 '새로운 피험자 S008에 대한 hold-out 성능'이다.

항목	내용
데이터 파일	combined_data.h5
피험자	m2_S001 ~ m2_S008
조건	level_075mps, level_100mps, level_125mps, accel_sine, decline_5deg, incline_10deg, stopandgo
샘플링	100 Hz
입력 길이	200 samples = 2.0 s
출력 정의	50 ms 미래의 corrected speed
평가 split	test = m2_S008, validation = m2_S007
중요한 해석	이 보고서의 성능은 전체 평균이 아니라 S008 hold-out fold 기준이다.

지표	비전공자용 의미
MAE	평균적으로 몇 m/s 틀리는지
RMSE	큰 실수를 더 강하게 벌주는 오차
R^2	예측이 전체 변동성을 얼마나 잘 설명하는지
Lag	예측이 시간적으로 늦거나 빠른 정도
Smoothness	예측 곡선이 얼마나 덜 들쑥날쑥한지 보는 참고 값

3. archive_2 plateau와 권장 결과 clamp07

archive_2에서는 여러 variant가 완전히 같은 MAE와 RMSE를 보이며 최고 성능 plateau를 형성했다. 이 plateau는 learned body 자체가 거의 같은 수준이라는 뜻이다. 이후 같은 weight에 대해 clamp 강도만 바꾼 post-hoc sweep을 비교했을 때, clamp07이 정성적으로 가장 덜 튀고 정량 손실도 거의 없는 결과를 보여 권장 deployment 결과로 채택했다.

가장 중요한 사실: ref, clamp20, ema03, fp1e4, fp3e4, gp1e3dv015의 checkpoint state_dict는 실제로 동일했다. 즉 이 이름들은 서로 전혀 다른 learned network를 뜻한다기보다, 저장된 결과물 기준으로는 같은 본체 혹은 같은 plateau의 결과를 다른 방식으로 표시한 변형이라고 보는 것이 맞다.

variant	무엇이 다른가	공식 MAE / RMSE	ref와 weight
raw_full_w200_base_ref	기본 평가 설정. 후처리 없음.	0.0260 / 0.0375	동일
raw_full_w200_base_clamp20	평가 단계에서 최대 가속도 2.0 m/s^2 clamp를 적용한 결과.	0.0260 / 0.0375	동일
raw_full_w200_base_ema03	평가 단계에서 EMA alpha=0.3 smoothing을 적용한 결과.	0.0260 / 0.0375	동일
raw_full_w200_base_fp1e4	학습 config에 frequency penalty 1e-4가 표기된 variant.	0.0260 / 0.0375	동일
raw_full_w200_base_fp3e4	학습 config에 frequency penalty 3e-4가 표기된 variant.	0.0260 / 0.0375	동일
raw_full_w200_base_gp1e3dv015	학습 config에 gradient penalty 1e-3, max dv 0.015가 표기된 variant.	0.0260 / 0.0375	동일

clamp sweep	MAE	RMSE	Lag	해석
clamp20	0.0260	0.0375	0.0 ms	비교군
clamp07	0.0260	0.0374	-0.5 ms	권장
clamp08	0.0260	0.0374	-0.5 ms	비교군
clamp06	0.0260	0.0374	-1.0 ms	비교군

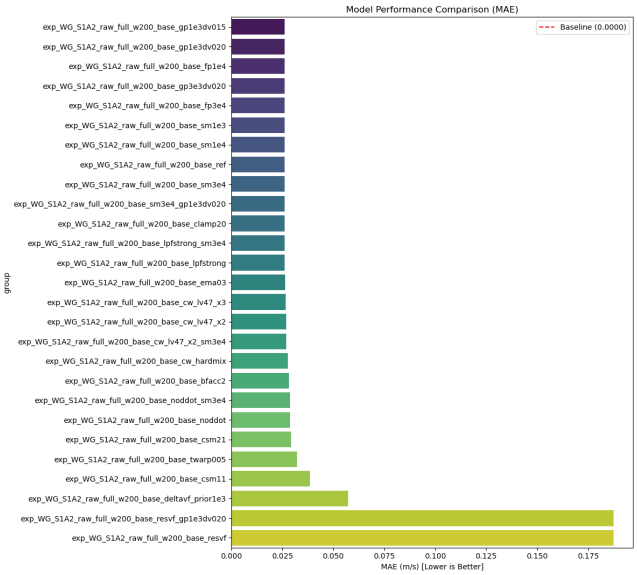

Figure 1. archive_2 전반의 MAE 비교. 상위 구간이 겹치며 plateau를 이룬다.

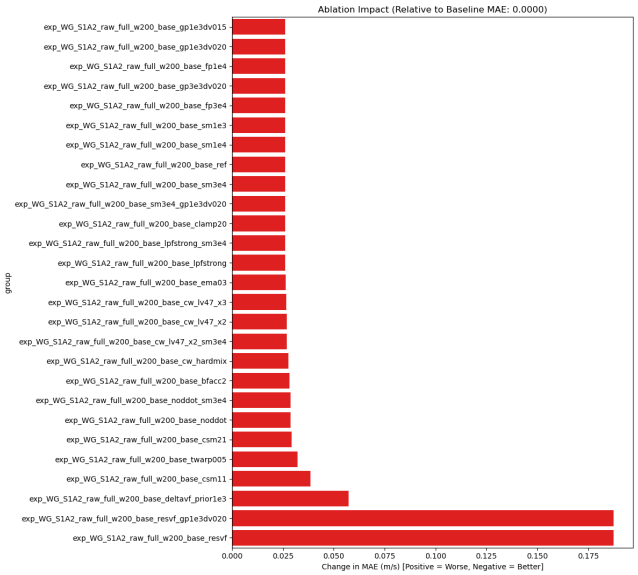

Figure 2. baseline 대비 MAE 변화. 최고 구간은 거의 차이가 없다.

실무적으로는 이렇게 이해하면 된다. ref가 기본 network 본체이고, clamp07은 그 본체의 output에 더 강한 biomechanical clamp를 붙여 예측 곡선을 더 안정적으로 만든 권장 배포형 결과물이다.

4. 대표 최고 성능 모델의 구조와 실제 입력

raw_full이라는 이름은 특수 prior 그룹보다 관절운동학, 단순 back IMU state, torque, subject info branch를 넓게 넣는 방향을 뜻한다. 사용자가 earlier review에서 이 계열을 더 자연스럽다고 느낀 이유와도 일치한다.

항목	설정
모델 타입	TCN_GRU
TCN channels	[32, 32, 64, 64, 128, 128]
kernel size	5
GRU hidden	32
head hidden	[64]
dropout	0.2 / head 0.5
정규화	use_input_norm=True, input_norm_type=instance, model_norm=batch
입력 차원	26
출력 차원	1

feature group	채널 수	설명
hip/knee/ankle angle	6	좌우 고관절, 무릎, 발목 각도
joint angular velocity	6	관절 각도의 시간 변화율. 현재 데이터셋에는 없고 loader가 on-the-fly로 만든다.
joint angular acceleration	6	관절 각도의 2차 미분 정보. 역시 현재 데이터셋에는 없고 loader가 만든다.
back IMU state	4	roll, pitch, yaw, vel_forward. 현재 데이터셋에는 이름 그대로 저장돼 있지 않아 loader가 raw accel/gyro에서 계산한다.
exo torque	2	좌우 토크
subject info	2	height, weight

입력 묶음	데이터 출처	어떻게 얻는가
joint angle	H5 trial-level direct (169/169)	mocap/kin_q의 hip, knee, ankle angle을 그대로 읽는다.
joint _dot / _ddot	H5 missing in all trials (0/169 and 0/169)	loader가 angle에 np.gradient()와 LPF를 적용해 on-the-fly로 만든다.
roll / pitch / yaw / vel_forward	H5 missing in all trials (0/169)	현재 combined_data.h5에서는 해당 이름의 채널이 없어서 loader가 raw accel/gyro와 treadmill belt acceleration을 사용해 계산한다.
torque	H5 trial-level direct (169/169)	robot/left, robot/right torque를 그대로 사용한다.

입력 묶음	데이터 출처	어떻게 얻는가
height / weight	subject-level datasets exist (8/8, 8/8)	데이터셋에는 값이 있지만, 현재 loader의 sub_info branch는 attrs만 읽기 때문에 이번 run에서는 기본값 1.70, 70.0이 broadcast되었다.

구성요소	비전공자용 설명
TCN	시간축 convolution으로 최근 2초 안의 local temporal pattern을 읽는 부분
GRU head	window 전체 맥락을 요약해서 미래 속도를 안정적으로 내는 부분
Clamp07	학습 구조가 아니라 평가 후처리. 너무 급한 순간 변화는 잘라낸다.

중요한 구분: 이 top model은 derived/*라는 특수 prior 그룹은 쓰지 않지만, 그렇다고 모든 입력이 H5에서 그대로 들어오는 것은 아니다. 현재 combined_data.h5 기준으로는 관절 각도와 torque만 직접 읽고, joint_dot/_ddot와 roll/pitch/yaw/vel_forward는 loader가 계산한다.

5. Derived input feature는 어떻게 계산되는가

헷갈리기 쉬운 지점이 있다. top model은 derived/* prior를 쓰지 않지만, 현재 데이터셋에서는 일부 입력을 loader가 계산해서 채운다. 따라서 아래 설명은 '이번 최고 성능 모델이 실제로 소비한 값이 H5에 있느냐'와 'repo가 어떤 derived feature를 계산할 수 있느냐'를 분리해서 읽는 것이 중요하다.

5-1. back IMU 입력의 실제 출처

back IMU 채널	현재 데이터셋에서의 실제 상태	코드상 계산 또는 의미
roll	169/169 trial에서 원본 채널 없음	loader가 accel tilt와 gyro_x를 섞는 complementary filter로 계산한다.
pitch	169/169 trial에서 원본 채널 없음	loader가 accel tilt와 gyro_y를 섞어 계산한다.
yaw	169/169 trial에서 원본 채널 없음	loader가 gyro_z를 시간 적분해 누적 회전을 만든다.
vel_forward	169/169 trial에서 원본 채널 없음	loader가 pitch로 중력 성분을 보정한 전후방 가속도를 적분하고 high-pass filter로 drift를 줄여 계산한다.

데이터 감사 결과, combined_data.h5의 169개 trial 중 roll/pitch/yaw/vel_forward가 저장된 trial은 0개였다. 반면 raw accel/gyro/quaternion과 좌우 belt speed는 169/169, 169/169 trial에서 모두 존재했다. 즉 현재 보고서의 대표 모델은 이 4개 IMU state를 H5에서 직접 읽는 것이 아니라, raw back IMU를 바탕으로 loader가 매번 계산한 값을 입력으로 사용한다.

5-1b. 현재 구현의 back IMU 계산식

단계	현재 구현의 계산식 또는 규칙
축 보정	subject prefix가 m1_이면 a_x <- -a_x, m2_이면 a_z <- -a_z
기본 상수	dt = 1 / fs, alpha = 0.98
roll용 accel tilt	r_acc[t] = atan2(a_y[t], a_z[t])
pitch용 accel tilt	p_acc[t] = atan2(-a_x[t], sqrt(a_y[t]^2 + a_z[t]^2))
roll update	roll[t] = alpha * (roll[t-1] + g_x[t] * dt) + (1-alpha) * r_acc[t]
pitch update	pitch[t] = alpha * (pitch[t-1] + g_y[t] * dt) + (1-alpha) * p_acc[t]
yaw update	yaw[t] = yaw[t-1] + g_z[t] * dt
belt acceleration	a_belt[t] = gradient(speed_leftbelt)[t] * fs
gravity-compensated forward accel	a_lin[t] = a_x[t] + 9.81 * sin(pitch[t]) + a_belt[t]
forward velocity	vel_forward[t] = highpass_filter(cumsum(a_lin) * dt, cutoff=0.1 Hz, order=2)

이 구현은 quaternion 기반 자세추정기가 아니라, roll/pitch는 accel tilt + gyro 적분을 섞는 간단한 complementary filter이고 yaw는 gyro_z 누적 적분이다. 또 vel_forward는 body-frame 추정이 아니라 x축 가속도에서 pitch로 중력 성분을 보정한 뒤 적분한 speed-like state다. 구현상 angle 상태는 rad 스케일로 해석하는 것이 자연스럽다.

5-2. 프로젝트가 계산할 수 있는 주요 derived input

이 5-2 표의 feature groups는 프로젝트가 계산할 수 있는 option들이다. 하지만 현재 권장 결과 clamp07이 공유하는 learned body의 input_vars에는 이 derived/* 그룹들이 하나도 포함되지 않는다. 즉 5-2는 '이번 권장 결과가 실제로 쓴 입력' 목록이 아니라 'repo가 지원하는 다른 파생 feature 후보' 목록이다.

derived group	어떻게 계산하는가	왜 쓰는가
derived/body_frame_imu	quat canonicalization → sensor frame을 global-like frame으로 회전 → 서 있는 구간의 중력으로 up축 추정 → 수평면 가속도의 sliding PCA로 forward축 추정 → body frame(right, forward, up) 재구성 → 중력 제거 후 accel/gyro 투영	센서를 몸 기준 축으로 정렬해 조건이 바뀌어도 일관된 IMU 표현을 만들기 위해
forward_accel_overground	body-frame forward accel에 treadmill belt acceleration을 더해 overground와 비슷한 전진 가속도로 변환	트레드밀 위에서도 overground형 속도 prior를 만들기 위해
derived/imu_integrated_speed	forward_accel_overground를 leaky integrator로 적분하고 causal LPF를 적용	전진 속도의 저주파 prior를 만들기 위해
derived/imu_speed_causal	treadmill acceleration을 0으로 둔 body-frame forward accel만 적분	트레드밀 정보에 덜 의존하는 causal inertial prior를 만들기 위해
derived/model_com_speed_nogrf	height 기반 thigh/shank/pelvis 길이 비율을 두고, pelvis tilt + hip - knee chain으로 좌우 COM velocity를 만든 뒤, phase 또는 kinematics 또는 IMU-fusion support probability로 좌우 값을 causal blending	인체 모델 기반 속도 prior를 GRF 없이 만들기 위해
derived/contact_estimate	hip phase, joint kinematics, body-frame IMU energy를 조합해 좌우 contact probability를 causal하게 추정	접지 상태를 확률 형태로 나타내기 위해
derived/interaction_power / stride_progression	torque와 causal joint velocity, 좌우 hip excursion과 cadence proxy를 조합해 계산	외골격 상호작용과 보행 진행 상태를 요약하기 위해

특히 body_frame 계열은 단순 좌표변환이 아니다. quaternion 정규화, standing gravity 기반 up축 추정, sliding-window PCA 기반 forward축 추정, gravity removal, treadmill acceleration 보정까지 포함한 단계적 처리다. 그래서 derived/body_frame_imu, imu_integrated_speed, imu_speed_causal은 모두 같은 body-frame 계산 체인을 공유한다.

6. 왜 model-based COM velocity는 빠졌고, clamp07은 무엇인가

사용자가 물었던 'joint angular velocity × segment length 조합의 model based COM velocity는 왜 빠졌는가'에 대한 답은 간단히 말해 성능과 가정의 균형 때문이다. 프로젝트에는 그 prior를 계산하는 코드가 있지만, 실제 최고 성능 family는 그 prior를 넣지 않은 raw_full 쪽에서 나왔다.

6-1. model_com_speed_nogrf가 대표 top model에 포함되지 않은 이유

비교 대상	archive_1 대표 실험	MAE / RMSE	의미
best raw_full	raw_full_w200_base_none	0.0260 / 0.0375	특수 prior 없이 구성한 raw_full family
best model_com phase	bf_modelcom_phase_w150_compact_none	0.0633 / 0.0991	관절 phase 기반 support blending
best model_com fusion	bf_modelcom_fusion_w150_base_none	0.0725 / 0.1112	IMU-fusion support blending

구분	내용
확인된 사실	archive_1에서 raw_full_w200 계열이 model_com 계열보다 MAE와 RMSE 모두 훨씬 낮았다. archive_2 최고 plateau도 raw_full family에서 나왔다.
구조적 차이	model_com_speed_nogrf는 height 기반 segment length, pelvis tilt/yaw, joint angle chain, gradient 기반 chain velocity, soft support blending을 모두 가정한다. raw_full은 이런 인체모델 prior 대신 단순 IMU-state와 관절운동학 패턴을 학습한다.
가능한 해석	segment length 근사, pelvis 회전 오차, gradient 민감도, support blending heuristic이 누적되면 prior가 오히려 noise source가 될 수 있다. 반면 raw_full의 simple IMU-state + joint kinematics 조합은 더 단순하고 데이터 적합적으로 작동했을 가능성이 크다.

따라서 archive_2에서 model_com prior를 고집하지 않은 것은 기능이 없어서가 아니라, 이미 archive_1 결과가 '특수 prior를 넣은 model_com보다 raw_full family가 더 낫다'는 방향을 보여줬기 때문이다. 보고서의 대표 모델이 raw_full인 이유도 여기에 있다.

6-2. clamp07 상세 설명

항목	clamp07의 의미
설정 위치	post-hoc sweep variant: biomech_clamp_max_acc = 0.7
적용 시점	학습 후 evaluation 단계. overlap fusion 뒤, trial별 prediction에 적용된다.
수식	100 Hz이므로 max_dv = 0.7 / 100 = 0.007 m/s/sample. 한 샘플에서 다음 샘플로 speed jump가 이보다 크면 clip한다.
바뀌는 것	출력 trajectory의 순간 변화율만 제한된다.
바뀌지 않는 것	checkpoint weight, train loss, feature extractor, parameter 수는 전혀 바뀌지 않는다.
실무적 의미	평균 오차를 거의 유지하면서 speed curve의 spike를 줄이는 권장 deployment stabilizer다.

가장 중요한 해석: clamp07은 '더 좋은 새 네트워크'가 아니다. ref/clamp20과 동일한 learned weight를 유지한 채, 출력 speed가 사람 보행에서 너무 비현실적으로 급변하지 않도록 max acceleration 0.7 m/s^2 제한을 건 evaluation recipe다. 즉 사용자가 본 덜 튀는 곡선은 모델 본체와 clamp07 postprocess가 함께 만든 결과다.

7. 학습 방식과 수렴 양상

학습 로그를 보면 validation loss 최저점은 epoch 11에서 나왔고, 이후 큰 개선이 없어서 epoch 21에서 종료됐다. 즉 이 모델은 오래 끌어가며 억지로 얻은 결과가 아니라, 비교적 안정적으로 수렴한 2초 window 기반 network다.

항목	값
loss	Huber, delta=0.1
learning rate / wd	0.001 / 0.001
scheduler	cosine restart, T0=10, eta_min=1e-05
batch / val batch	128 / 256
AMP	True
augmentation noise	0.03
early stop	patience=10, warmup=10, min_delta=1e-4
실제 종료 epoch	21
best epoch	11
best val loss	0.016389
총 학습 시간	1.81 h (6530.6 s)
epoch 평균 시간	311.0 s

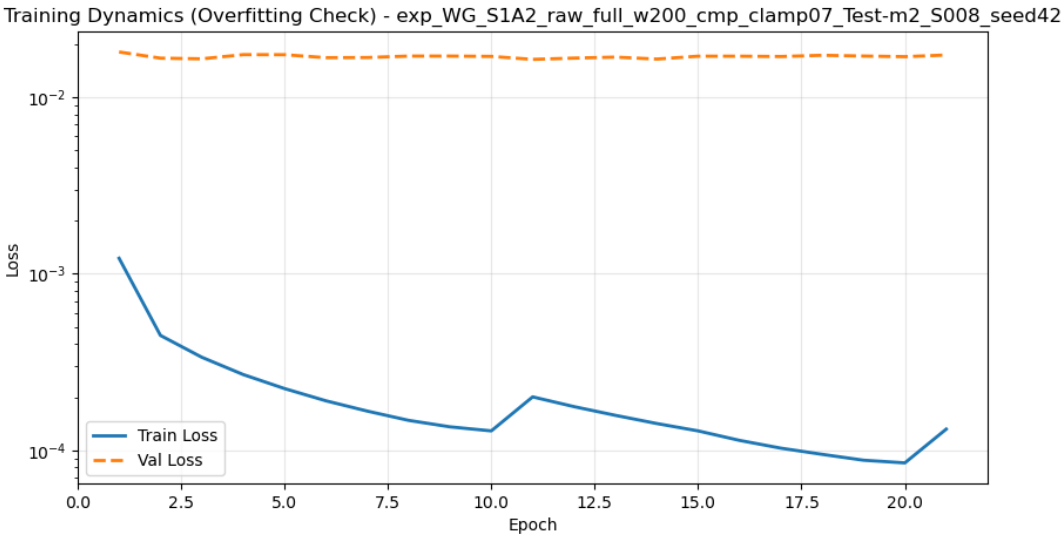

Figure 3. training curve. epoch 11 부근에서 validation loss가 가장 낮고 이후 큰 개선이 없다.

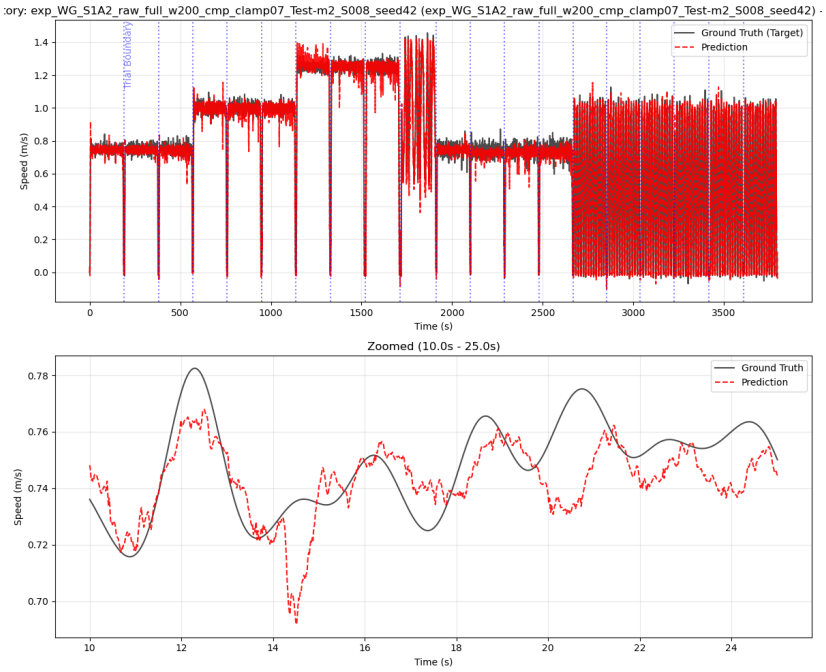

Figure 4. 전체 trajectory plot. 전체 시간 구간에서 prediction이 ground truth를 전반적으로 안정적으로 따라간다.

8. condition별 정성 결과

다음 페이지들은 테스트 subject S008에 대해 condition별로 speed ground truth와 모델 prediction을 비교한 그림들이다. 여기서는 MAE보다도 spike/noise 억제가 얼마나 잘 되었는지에 주목해서 보는 것이 좋다.

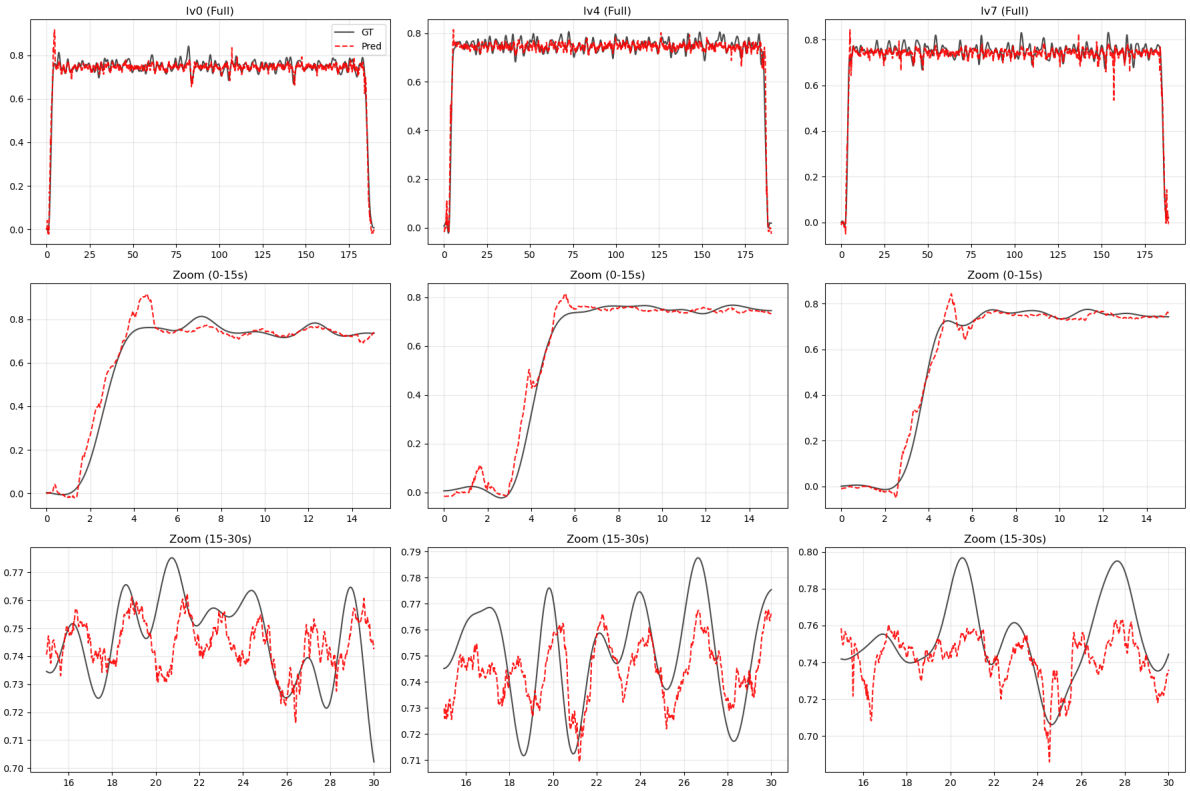

Figure 5. level_075mps. 대표 wide condition plot.

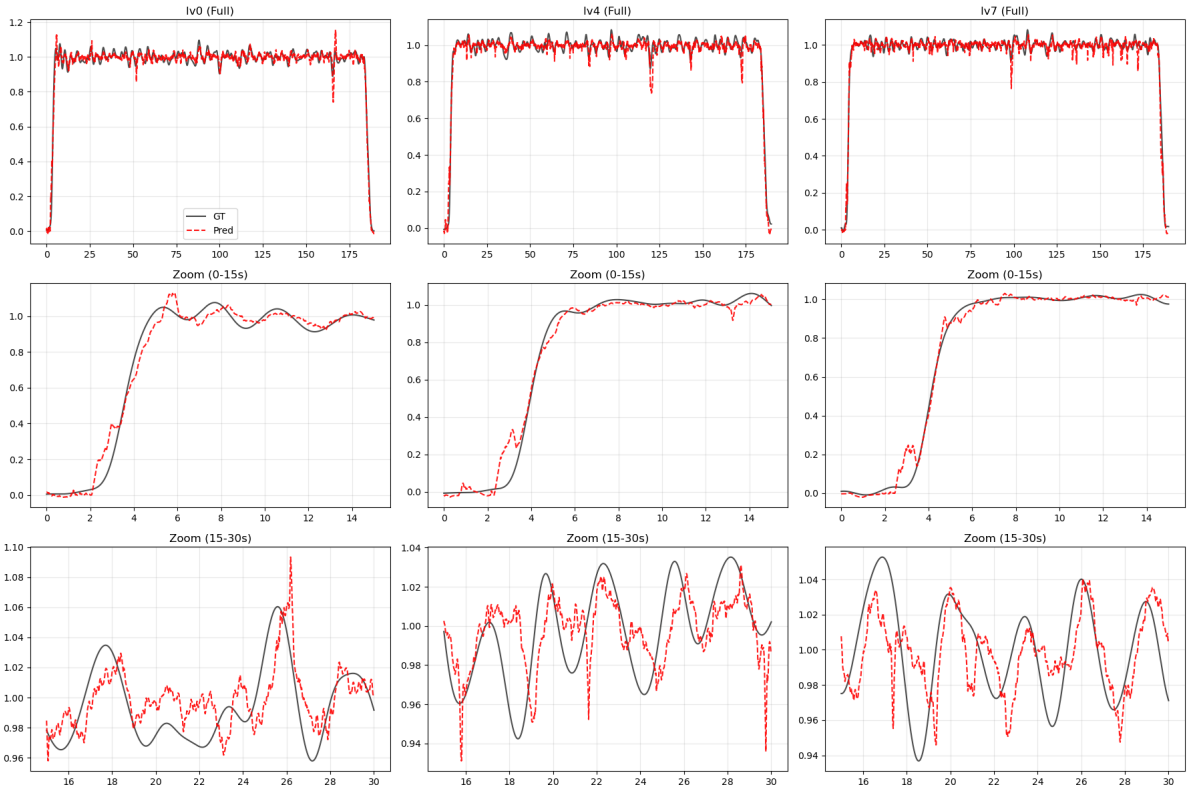

Figure 6. level_100mps. 대표 wide condition plot.

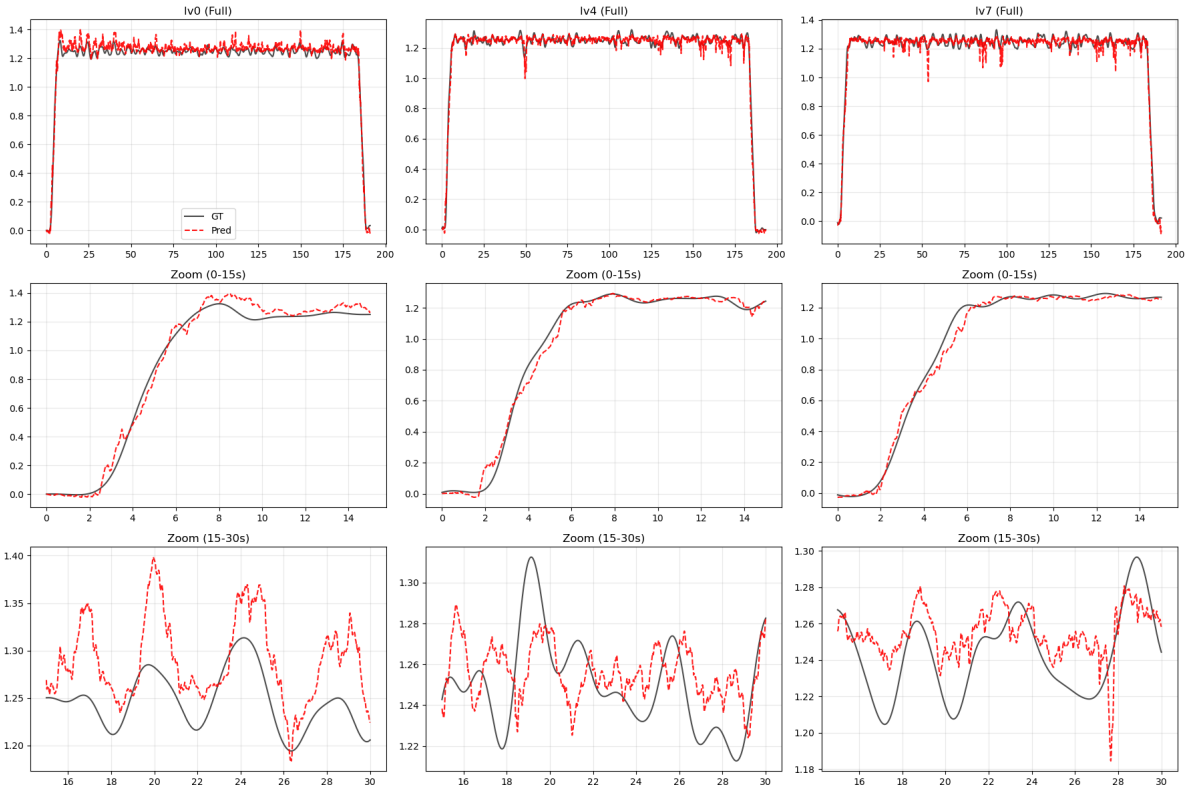

Figure 7. level_125mps. 대표 wide condition plot.

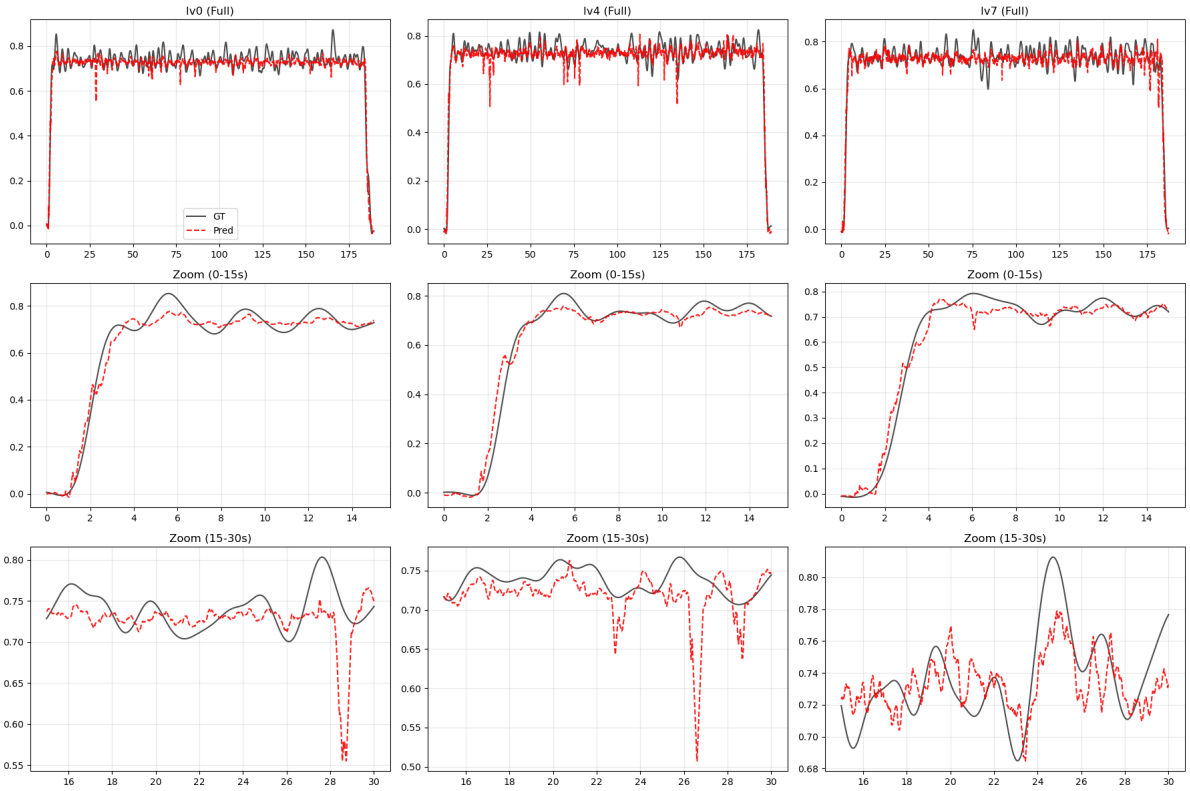

Figure 8. incline_10deg. 대표 wide condition plot.

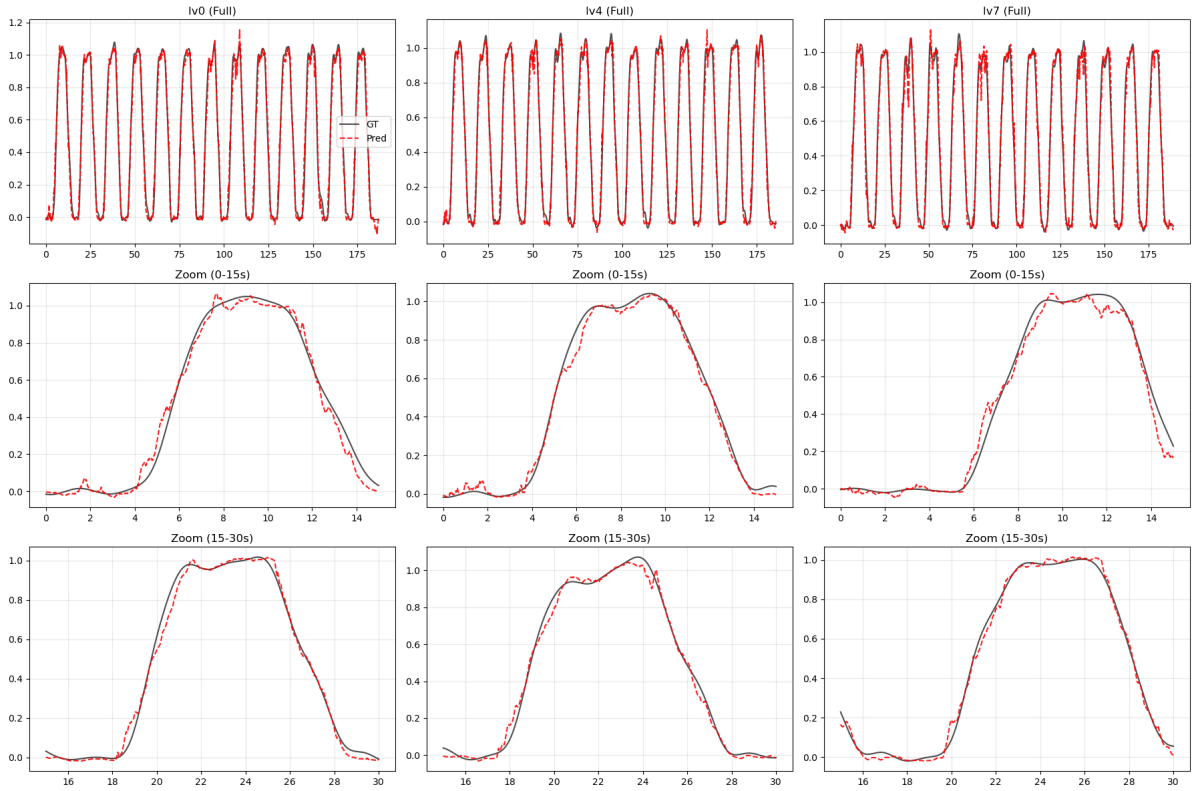

Figure 9. stopandgo. 대표 wide condition plot.

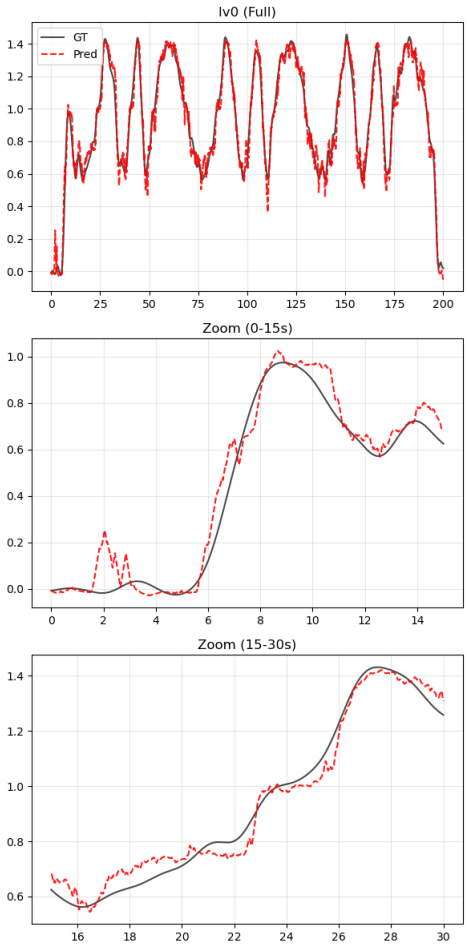

Figure 10. accel_sine

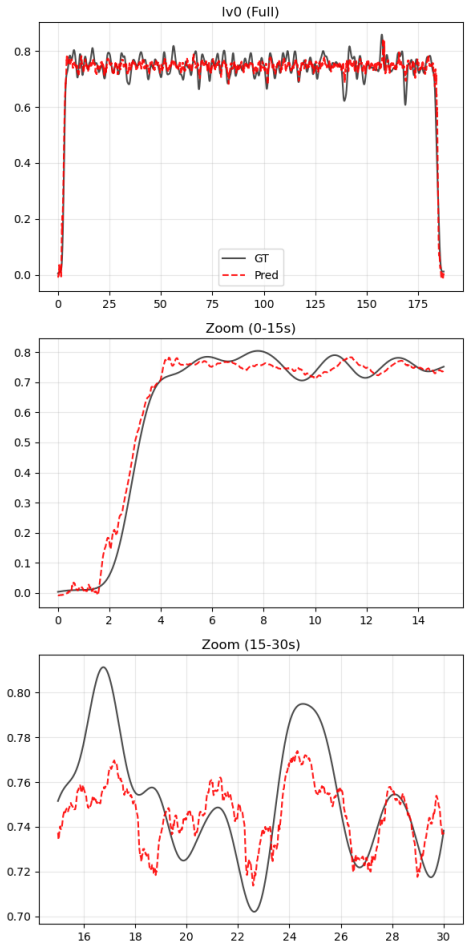

Figure 11. decline_5deg

9. Feature importance

Permutation feature importance는 각 입력을 하나씩 섞었을 때 error가 얼마나 증가하는지를 보는 방법이다. 값이 클수록 그 feature를 잃었을 때 모델 성능이 더 나빠진다는 뜻이다. 이번 계산은 메모리 제한 때문에 importance용 stride를 12로 키운 상태에서 수행했다.

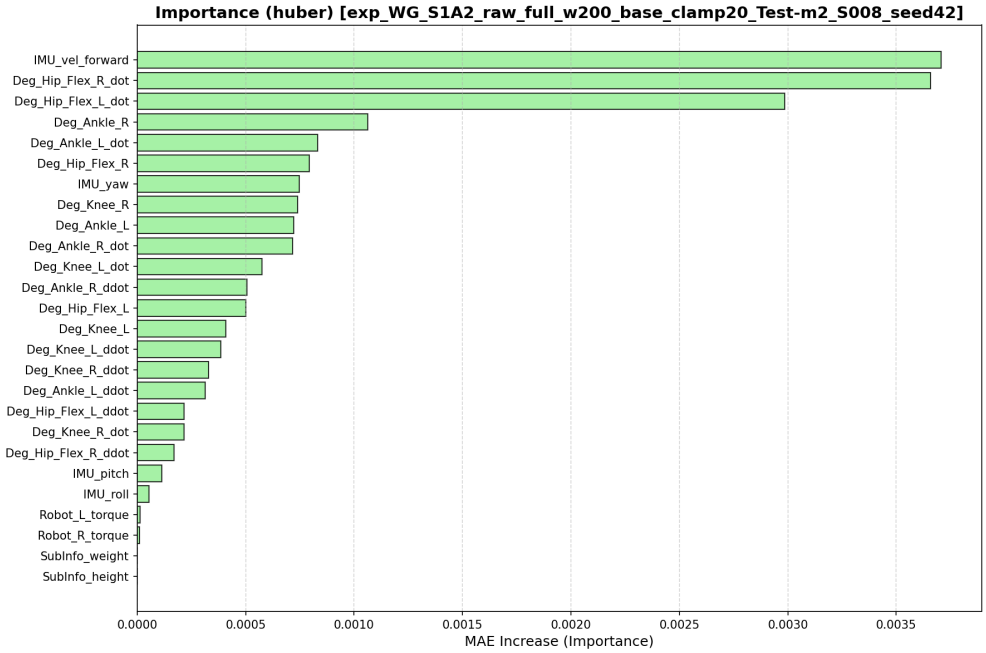

Figure 12. 같은 learned body를 공유하는 ref/clamp20/clamp07 계열의 permutation feature importance.

상위 feature	importance
IMU_vel_forward	0.003708
Deg_Hip_Flex_R_dot	0.003657
Deg_Hip_Flex_L_dot	0.002985
Deg_Ankle_R	0.001064
Deg_Ankle_L_dot	0.000833
Deg_Hip_Flex_R	0.000793
IMU_yaw	0.000748
Deg_Knee_R	0.000739
Deg_Ankle_L	0.000721
Deg_Ankle_R_dot	0.000717

하위 feature	importance
IMU_roll	0.000055
Robot_L_torque	0.000014
Robot_R_torque	0.000012

하위 feature	importance
SubInfo_height	0.000000
SubInfo_weight	0.000000

해석 포인트: 가장 중요한 입력은 IMU vel_forward와 hip angular velocity였다. 반대로 torque와 subject info는 이번 test fold에서 거의 중요하지 않았다. 다만 subject info의 경우 현재 loader 경로가 실제 subject dataset 대신 기본값 상수를 넣고 있으므로, importance 0을 '키와 몸무게가 원래 불필요하다'고 해석하면 안 된다. 보다 안전한 해석은 이 top result가 back IMU와 주요 joint motion에서 직접적인 속도 단서를 강하게 읽는다는 것이다.

10. 이 모델이 왜 덜 튀어 보였는가?

사용자가 earlier review에서 중요하게 본 것은 단순 MAE보다도 lv4, lv7 같은 까다로운 조건에서 추정값이 얼마나 덜 튀는지였다. 이번 대표 결과를 그 관점에서 정리하면 다음과 같다.

첫째, importance 상위가 IMU vel_forward와 hip angular velocity라는 점은 모델이 비교적 직접적이고 저주파적인 속도 단서에 무게를 둔다는 의미다.
둘째, clamp07은 본체를 바꾼 것이 아니라 같은 network output에 더 강한 biomechanical clamp를 더한 결과다.
셋째, model_com 같은 가정 기반 prior보다 raw_full family가 더 잘 먹혔다는 점도 noise 억제 측면의 힌트다.

넷째, 따라서 사용자가 체감한 자연스러움과 덜 튀는 성질은 raw_full family 선택과 후처리 안정화 전략이 함께 만든 결과라고 해석하는 것이 타당하다.

비전공자용 한 줄 요약

이 모델은 복잡한 센서 융합으로 억지로 성능을 얻은 모델이 아니라, 비교적 직접적인 speed 단서를 잘 읽고, 마지막에 너무 급한 변화는 잘라내는 방식으로 안정적인 곡선을 만든다.

주의할 점

- 최고 성능은 S008 hold-out fold 기준이다.
- top plateau variant들은 저장된 checkpoint 기준으로 동일한 weight였다.
- feature importance는 메모리 제약 때문에 stride 12에서 계산했다.
- 현재 repo의 일부 입력 미분량은 offline gradient 기반이므로 완전 causal pipeline과는 차이가 있다.

최종 결론

현재 권장 대표 결과는 raw_full_w200_cmp_clamp07이다. 그러나 더 정확히 말하면 가장 좋은 learned 본체는 raw_full_w200_base_ref와 동일한 network이며, 사용자가 선호한 덜 튀는 곡선은 clamp07 후처리가 더해진 결과였다. 또한 프로젝트가 계산할 수 있는 여러 derived prior 중 model_com_speed_nogrf는 이번 대표 top result의 핵심이 아니었다. 따라서 앞으로의 방향은 raw_full_w200 본체를 유지하되, spike suppression을 학습 손실이나 배포 후처리에서 더 명시적으로 다루는 것이다.

이 보고서에 포함된 핵심 산출물

범주	포함 내용
프로젝트 설명	문제 정의, target 의미, GRF-free 제약, split 방식
정량 결과	MAE, RMSE, R^2, latency, parameter count, plateau 해석
정성 결과	training curve, trajectory, condition별 plot
해석 자료	feature importance, top/bottom feature tables, spike 해석